

01 什么是世界模型？

作者 NILUSHANAN KULASINGHAM

阅读约 28 分钟 · 可交互

自 2018 年起，这个词至少涵盖五种不同的机器，而人们很少说清自己指的是哪一种。这是给这五种的一份指南：各自从哪里来，以及能把它们分开的那一个测试。

本章的图都是可交互的。请到 worldmodels101.com/zh/chapters/what-people-mean 在线按一按、拖一拖。

最近只要在时间线上待一会儿，你多半就刷到过类似下面这样的短片。有人正用方向键在一片风景里行走，说明写着这是生成出来的，不是搭出来的。它看起来像一款没人做过的电子游戏。底下的回复叫它世界模型，于是你去查了查这个词。




FIG. 1.1 这幅画面里没有一帧是录像。每一帧都是根据你站在哪里、朝着哪个方向现算出来的，画面背后并没有存着一片风景。拖动可以四处看看，也可以点一下画面，用方向键走走看。

十分钟以后，你开了五个标签页，它们描述的是五台不同的机器。一台生成你可以用方向键操控的视频。一台把几何结构，也就是三维形状和它们各自的位置，导出到三维建模软件 Blender 里。还有一篇论文讲的是预测嵌入向量，也就是一串代替图像的数字，而它从头到尾没给你看过一段视频。

我得说，这个词也困扰了我很久。网上那些解释都挺有帮助，但往往是挑五台机器里的一台，然后当成故事的全部去讲。我当时想要的是这么一页东西：把五台并排摆开，再说清楚它们是怎么共用上一个名字的。这一章就是那一页。如果你和当初的我一样困惑，希望它派得上用场。

这团乱是有来历的，而这段来历比你那几个标签页整齐得多。大约在 2018 到 2024 年之间，四条传统从四个方向走到了同一个词上。它们分别是强化学习与控制、自监督表征学习（教网络给图像和视频写摘要）、生成式视频与空间模型，以及可解释性，也就是研究一个训练好的模型内部在发生什么。每一方说的都是真实存在的东西，而且谁也不必去核对别人指的是什么。



一段 DeepMind 的演示，有人用方向键走过一片生成出来的风景。

[Genie 3 · Google DeepMind](#) ↗

其实属于

渲染器

<https://deepmind.google/blog/genie-3-a-new-frontier-for-world-models/>



一篇 Meta 的论文，讲的是预测视频嵌入向量，而它从头到尾没给你看过一段视频。

[V-JEPA 2 · Meta AI](#) ↗

其实属于

表征模型

<https://ai.meta.com/blog/v-jepa-2-world-model-benchmarks/>



一个可以直接加载进 Blender 的三维环境。

[Marble · World Labs](#) ↗

其实属于

仿真器

<https://www.worldlabs.ai/blog/marble-world-model>



2018 年的一个强化学习结果，讲的是赛车游戏里的一辆车。

[World Models · David Ha & Jürgen Schmidhuber](#) ↗

其实属于

动力学模型

<https://worldmodels.github.io/>



一场主要靠嗓门进行的争论，争的是一个从没见过棋盘的语言模型是不是照样在内部有一个。

[Emergent World Representations · Kenneth Li et al.](#) ↗

其实属于

FIG. 1.2 看看这五个结果，它们来自五类不同的系统。每一个都被造出它的人称作世界模型。

到了 2026 年，各家实验室开始出版词典。目前在用的定义有五种，每一种都出自自己的传统、自己的年份。有一个四秒钟的测试，照理说能把它分开，而我们等下会看到，它做不到。

五种定义

我们先把这五种过一遍。把这些类别当作合同，而不是物种。每一种描述的是一个系统承诺交给你什么。现代的工作经常在它们之间来回跨越，英伟达的 Cosmos 和 Meta 的 V-JEPA 2 马上就会让你看到这一点。



FIG. 1.3 其中四种是你运行的系统，按被预测对象的抽象程度排列。第五种本身不是一个系统，而是关于另一个系统的断言，所以它落在这条轴之外。

渲染器预测观测，通常就是像素。GameNGen 来自 Google 的 Dani Valevski 等人（2024），它画的是电子游戏 DOOM 的画面。每一帧都由它前面的那些帧和玩家的输入算出来。它在单块 TPU 芯片上能跑到每秒二十帧左右，这个速度已经够拿来玩了。

来自 DeepMind 的 Genie 3，据报道能以 720p、每秒 24 帧生成可交互视频。据称它能连贯好几分钟，你一路走动，场景也不散架。它还能在会话中途接受大白话的指令：换个天气，加一群鸟。

Sora 也属于这一类，只是没有动作输入：它预测的是你没法操控的观测。这个区别请记住，因为「动作会不会改变预测」正是这一章末尾那三个问题之一。

所以持久性是存在的，也就是东西会留在你离开时的位置。但它是通过生成学出来的，而不是由存下来的几何结构保证的。






				
预测像素	预测几何与物理	预测紧凑状态	预测嵌入向量	不在这条轴上
渲染器	仿真器	动力学模型	表征模型	内隐模型
一帧，然后是下一帧。产出的是给你看的東西；房间之所以还在，只是因为它一直画得前后一致。	别的程序能打开的几何结构。有用来渲染的表面，下面还有给物理引擎去碰撞的碰撞网格。	一个短向量，以及在你正考虑的动作下的下一个向量。没有人给这些数字起名字，它只需要能往前推。	缺失部分的摘要，被预测成嵌入空间里的一个点，然后就丢掉了。它从不重画像素。	根本不是一种输出。探针在一个从没被给过棋盘的网络里找到了棋盘状态，这是关于「里面长出了什么」的论断，而不是一个你能运行的东西。


FIG. 1.4 同样这五种，这次按各自交给你的东西来画。每一格里标出被预测对象的都是朱红色，也就是那种橙红。从左到右和上面那张地图是同一条轴：先是一张画面，然后是一个结构，然后是一个紧凑状态，然后是一个摘要，最后是一个根本算不上输出的东西。

仿真器预测可查询的结构，也就是你能对着提问的三维形状。Marble 来自 World Labs，这家创业公司的联合创始人里有那位做出 ImageNet 的斯坦福研究者。ImageNet 就是那个引爆了深度学习热潮的图像数据集。Marble 接收文字、一张图或者一个粗糙的三维布局，然后一次返回两样东西。

高斯泼溅(几百万个彩色斑点, 渲染起来便宜, 但没有任何东西可以撞上去)负责外观。三角网格负责结构。所谓网格, 就是用许多小三角形拼出来的一层表面。那就是普通的三维几何, 其中也包括碰撞网格(物理引擎真正会撞上去的那层看不见的形状)。

World Labs 在 2025 年 11 月把 Marble 放进了限量测试, 2026 年 2 月对所有人开放。英伟达在 2025 年 1 月开源了 Cosmos。它生成有物理感的视频, 是专门当作机器人和自动驾驶的训练数据来造的。

渲染器 / 预测观测



GOOGLE DEEPMIND Genie 3: Creating dynamic worlds that you can navigate in real-time

仿真器 / 预测结构



WORLD LABS Introducing Marble by World Labs


FIG. 1.5 我会把这张图读成两份承诺之间的比较，而不是一场及格与不及格的考试。Marble 交给你的几何结构，别的程序可以打开，你自己就能核实。Genie 3 的连贯性是造它的实验室报告出来的，这个你核实不了。

英伟达自己把 Cosmos Predict，也就是生成视频的那一部分，称为生成式视频。真正的三维仿真器是 Omniverse，那是英伟达另一款产品。要是你把整个东西都归到「仿真器」名下，就等于把这条分界对自己藏了起来。

平台不是一个类别。一个产品可以同时对外提供一个像素预测器、一个三维仿真器和一个以动作为条件的模型。以动作为条件的意思很简单，就是它把你的动作当输入。该问的是他们卖给你的是其中哪一个，以及你即将对着哪一个接口开发。

动力学模型预测在动作条件下的紧凑状态，往往还一并预测回报。紧凑的意思是一小串数字，而不是一张画面。它是四种可运行类别里最老的一种。从 Schmidhuber 一路到 Dreamer 的那条线，也就是下面讲历史时我们要走一遍的那条，一直在朝它建。

DeepMind 的 Julian Schrittwieser 等人做的 MuZero 就是证据。它的模型只预测回报、价值和可能的走法，从不预测棋盘。就靠这些，它在围棋、国际象棋和将棋上追平了它那位有名的前辈 AlphaZero。而它从来没有被告知过规则。



当前局面



MuZero 的模型



奖励

0



价值



输

赢

策略



从未画出

搜索树



访问的节点

0

读出的数

0

画出的棋盘

0


FIG. 1.6 MuZero 的模型就在中间。先别动开关，让它停在「三个数字」上，按一下「搜索」，走一小棵树：每个节点要的都是回报、价值和策略，右边那块棋盘从头到尾没被画出来。现在把开关拨到「下一个棋盘」，看着每个节点都要为一张画面付账，而搜索从这张画面里什么也没读。数字仅作示意。

后面讲历史时你会正式认识的两个系统，PlaNet 和 Dreamer，用它的方式不一样。PlaNet 在这样一个模型里做规划，每一步都重新搜索一遍。Dreamer 则从穿过这样一个模型想象出来的未来里学出行为。定义这一类的是「你能不能在模型里面做搜索」，而不是它的预测看起来有多真。


表征模型预测嵌入向量(一串代表一张图或一段片子的数字，排列方式使得相似的东西彼此靠近)，然后把预测扔掉。I-JEPA (2023) 是 Mahmoud Assran 等人做的图像版本，它遮住图像的一部分，预测缺失那块的嵌入向量。它从不把像素重画出来。

V-JEPA 2 (2025) 是视频版本，它在超过一百万小时的视频上做预训练，全程不涉及动作。第二阶段再在它上面训练出一个以动作为条件的变体。那个变体是为模型预测控制的(规划几步，执行一步，再重新规划)。Meta 报告说，它能在一个训练时从未见过的实验室里驱动一只 Franka 机械臂。

图像，遮住一块



训练后留下的



预测目标

缺失的像素

损失

像素误差

解码器

造了，然后扔掉


FIG. 1.7 先选好要让网络为那个被遮住的块预测什么，再按「预测」。目标是像素时，解码器必须把预测变回一张画面，而对一个它看不见的块，它能做到的最好结果就是一团模糊。目标是摘要时，没有任何东西被变回像素。看最下面那一行，那是训练结束后留下来的东西：两种情况都留下了编码器，而只有其中一种曾经造过解码器。

Meta 还报告说，它的规划速度比 Cosmos 快约 30 倍。这个数字要当心：它比的是两份不同的合同，而不是在给它们排名次。

注意，第二阶段接收动作、能往前推演、还能在上面做搜索。那就是动力学模型合同，只不过是另一头抵达的。我把这叫做迁移：一个系统从它被训练的那个类别出发，在上面长出另一个类别的机器。这些类别描述的是一个训练目标，而不是一种固定身份。

内隐模型完全是另一种性质的断言。它是五种里演示最少、争论最多的一种，因为根本没有东西可以运行：这个断言讲的是一个网络的内部。

Othello-GPT 是一个小语言模型，只被训练来预测黑白棋里的合法走法。黑白棋是一种用两面颜色不同的棋子下的棋。它从来没有被展示过棋盘。训练它的 Kenneth Li 等人（2022）在《Emergent World Representations》里报告说，棋盘还是出现在了它的内部。



已下的着法

d3 c5 f6 f5 e6

接下来的合法着法，轮到白方

c2 d2 e3 f3 d7 f7




网络



探针



小网络



未曾给出
只能读出

棋盘	探针	合法着法数
空白	小网络，按黑白来问	6

FIG. 1.8 Othello-GPT 见过的东西，只有左边那条带子上那样的走法 token。按一下「读出棋盘」，一个探针就会从网络的激活值里画出一块 8 乘 8 的棋盘，而没有人往里面放过棋盘。把这块内部棋盘上的某一格翻一下，看着下一步合法走法的清单跟着变，Li 等人就是这样说明模型确实在照着它下棋的。然后切到「我的和对方的」，那是 Nanda 换的一种说法，这时探针可以只是一条直线。

一个探针(一个小分类器，训练它从网络的激活值里读出某一个具体事实)可以把它读出来；当他们手动改动那块内部棋盘，模型接下来走的棋也跟着变了。Neel Nanda 等人（2023）做了后续，论文叫《Othello-GPT has a linear emergent world representation》：只要你问的是「我的」和「对方的」，而不是黑和白，那块棋盘就以朴素到连最简单的探针都读得出来的形式待在那里。

Wes Gurnee 和 Max Tegmark 在 2023 年把这个说法推得更远，论文叫《Language Models Represent Space and Time》。在一个大语言模型上，探针读出了接近地点经纬度的东西，也读出了事件的日期。没有人给这两个模型任何一个叫做 `world_model` 的函数。关于这个词的争论，就在这里吵得最凶：这样一个断言，说的是别的系统内部长出了什么，而不是一个你能运行的接口。

NVIDIA 的 Jim Fan 当时就反对那篇讲空间与时间的论文：一个能读出坐标的探针做的是分类，你没法对它做干预，也没法围着它闭合一个决策回路。Othello 那边的例子更硬，因为把读出来的棋盘翻一格，模型接下来下的棋就变了。碰到这类结果，该问的是：给你看的到底是哪一种。

一个方程，六十年

接下来说这个词是从哪儿来的，因为它确实起于一个很具体的地方。之后的一切，要么从那个起点长出来，要么是在顶着它走。那个起点是控制理论，也就是让一台机器保持在预定轨迹上的工程数学：自动驾驶仪、恒温器、火箭。

后来它进了强化学习(让一个智能体去行动，看会发生什么，再对管用的行为给奖励，以此来训练它)。在那里，世界模型指的是一个学出来的转移函数，也就是智能体从经验里摸出来的一条「接下来会怎样」的规则。给它一个状态和一个动作，它给你下一个状态。我说状态的时候，指的是对某一个时刻情况如何的一份描述。写下来是这样：

$$p(\underline{s}_{t+1} \mid \underline{s}_t, \underline{a}_t)$$

在给定 接下来会发生什么 和 你现在在哪里 的条件下，
你做了什么

FIG. 1.9 下面每一个系统，在 s 的位置上该放什么这件事上都做了不同的选择。可以是像素，可以是三维几何，可以是一小串数字，也可以是一个嵌入向量。这个选择就是五种定义分道扬镳的主轴，所以请记住在心里。

最老的祖先是 1960 年的卡尔曼滤波器。匈牙利出生的工程师 Rudolf Kalman 在《A New Approach to Linear Filtering and Prediction Problems》里把它写了出来。这里说的滤波器，是一段把带噪声的读数清理干净的数学。你把雷达打在一架飞机上的回波喂给它，它就会一路维持一个关于「飞机在哪里、飞多快」的最佳猜测。

不到十年，它就飞进了阿波罗的制导计算机。今天 GPS 接收机里的数学仍然是它。我会说，这就是一个世界模型所做的事情的一半：存在一个你永远不会直接看到的隐藏状态，而活儿就是从你看得见的东西里把它估出来。在底下，它同时保留着两套关于飞机在哪里的说法，一套来自物理，一套来自雷达，再把它们混成一个比任何一套都更锐利的猜测。这个混合我会在第 5 章拆开讲；在这里，要紧的是形状。





FIG. 1.10 一架飞机沿着一条平滑的航迹飞行，雷达每隔两秒报一次它的位置，上面带着噪声。卡尔曼滤波器一路维持着一个关于飞机在哪里、飞多快的猜测。拖动时间或者按播放，看着回波一个个到来时，估计值周围那条带子收紧。把雷达噪声调大，估计值仍然比回波更贴近飞机。让回波中断一段，它就靠自己的动力学滑行，同时那条带子张开。增益那一栏读数，是它在每一步上朝雷达倾斜了多少，这个数字第 5 章会拆开讲。那个灰掉的控件才是我想让你注意的地方：滤波器可以把你交给它的一次转弯往前推，但这里没有任何东西在学动力学，也没有任何东西在把两次转弯放在一起比较。距离仅作参考。

它没做的是另一半。你可以给卡尔曼滤波器一个已知的控制输入，比如一次你已经决定要做的转弯，它会把这个输入往前推，所以它能告诉你这次转弯会把飞机带到哪里。但状态怎么变化，那些规则是工程师写进去的，不是学出来的，而且它里面没有任何东西会把两次转弯拿来比较，好挑一个出来。

另一半花了三十年，还换了一个领域。到 1990 年，神经网络，也就是那种从例子里学、而不是从谁敲进去的规则里学的程序，重新流行起来。同一年里有三组人伸手拿了同一个设计，我们一个一个来看。

当时还在慕尼黑做研究的年轻人 Jürgen Schmidhuber，造了一个分成两部分的系统。他 1990 年那份技术报告的标题，大概只有他自己喜欢得起来：《Making the World Differentiable: On Using Self-Supervised Fully Recurrent Neural Networks for Dynamic Reinforcement Learning and Planning in Non-Stationary Environments》。一个网络学着预测世界接下来会做什么。另一个网络挑选动作，而前一个告诉它每一种选择会带来什么。



世界模型

$s, a \rightarrow s'$

每步一格。知道墙在哪里，不知道地面的异常。



选择器

在模型里规划路线，走出第一步。

还没有跑完一圈。抵达目标即完成一圈，圆点回到起点。

圈数

1

本圈步数

0

本圈意外

0

已持有的修正

0

FIG. 1.11 这是 1990 年那个设计的缩小版。把鼠标指向一个箭头，世界模型就会画出它认为你会落到哪里。按下去，由世界来回答。这个模型知道墙在哪里，却不知道地上那些区块：冰会带着你继续滑，漂移和上抬会把你推离原来那一行。现在打开「从错误中学习」，按三次「跑一圈」。你应该会看到意外一圈比一圈少，因为挑选动作的那一半现在是在一个认得路的模型里做规划。然后按「忘掉」，把学习关掉，再跑三圈：每一圈都和第一圈一样意外。


他把第一个网络叫做世界模型，这个说法就是从这儿来的。Schmidhuber 后来还是 LSTM 记忆单元的共同发明人，他一辈子都在坚持说这个领域总是忘记想法最早是谁提的。在这件事上，记录明明白白是他的。

同一时期，Richard Sutton 造了 Dyna。它是一个学习型智能体，一部分靠真实经验练，一部分靠自己的模型编出来的经验练。他那篇论文是《Dyna: an Integrated Architecture for Learning, Planning and Reacting》。

Sutton 和 Andrew Barto 后来写出了那本每个强化学习学生至今都要读的教科书。两人共同获得了 2024 年的图灵奖，消息是在第二年春天公布的。


JÜRGEN SCHMIDHUBER 1990

Making the World Differentiable (technical report FKI-126-90)



RICHARD SUTTON 1991

Dyna, an Integrated Architecture for Learning, Planning and Reacting



SEBASTIAN THRUN、KNUT MÖLLER 与 ALEXANDER LINDEN 1990

Planning with an Adaptive World Model




FIG. 1.12 这里是 1990 和 1991 年的那三个系统，每一个都画成一个回路。点开一张卡片放大，读一读它的模型做什么、又是谁在用它。然后打开「共同的形状」看看：世界和箭头都淡下去，每张卡片上亮起来的都是同样那两个方框。

第三个来自 Sebastian Thrun、Knut Möller 和 Alexander Linden 的《Planning with an Adaptive World Model》。从图上你能看出来，这三个都已经具备了现代那个想法的形状：一个学出来的模型说接下来会发生什么，另有别的东西拿它来做决定。

不过这个标签没能留住。1990 年的网络很小，它们的世界是迷宫和几十个数字。当时没有人能为任何带摄像头的东西学出一个有用的模型。

接下来的二十五年里，基于模型的这条线，也就是让智能体带着一个模型并且用它，大部分时间都是小众爱好。深度学习进入强化学习的时候，最抢眼的结果是 DeepMind 在 2013 年的 DQN。它从像素里学会了 Atari 游戏，而对游戏本身完全没有任何模型。势头在无模型这一边，1990 年那个两部分的设计看上去像件古董。




FIG. 1.13 这里的曲线是形状，不是测量结果。先选好走一步要花多少，再拖动预算，看看阴影区停在哪里。在仿真器里，也就是在一个模仿世界的程序里，预算能越过交叉点，于是爬得慢的那条赢。在真机器人上，预算远远到不了那里，而唯一学到了点东西的智能体，是带着模型的那个。然后打开「坏模型」，看看当模型在你会去的那些地方出错时会怎样。

让这个标签流行起来的论文，是 David Ha 与 Jürgen Schmidhuber 的《World Models》（2018）。我把它读成对那股势头的一个回应。Ha 当时在 Google Brain。这篇论文用三个部件，让 1990 年那个设计在一款赛车游戏和电子游戏 Doom 的一个关卡上跑了起来。

第一个是编码器(一个把视频帧压成一小串数字的网络)，这里是三十二个数字。第二个是动力学模型，它预测这串数字接下来往哪走。第三个是一个小控制器，也就是挑选动作的那个部件。

这个控制器几乎完全是在模型自己想象出来的推演里训练出来的，那些未来是模型自己演给自己看的。然后它被搬回真实的游戏里，居然还管用。




FIG. 1.14 Ha 与 Schmidhuber 的三个部件，画成一个回路。选中一个方框，看看什么进去、什么出来，然后按「单步」，看那三十二个数字变化。现在把开关拨到「在梦里跑」：动力学模型把自己的预测重新喂回去，游戏不再被问到。控制器在被搬回真实游戏之前，就是这样训练出来的。然后试试下面那道题。

读原论文时有一处命名容易把你带偏。Ha 与 Schmidhuber 把第三个模块叫做 controller，指的是那个挑选动作的小策略。世界模型是它旁边那个模块，是 controller 在里面做规划的那个。要是你把整个东西叫做「控制器」，那你就是拿其中明明不是世界模型的那一个部件去给它命名。

同一年还有 PlaNet，来自 Danijar Hafner 等人，作者里也有 Ha。论文是《Learning Latent Dynamics for Planning from Pixels》。它直接从像素里学到那套动力学，然后在潜在空间（latent space）里做规划（「潜在」的意思就是模型自己的压缩描述：几百个数字，而不是上百万个像素）。

每一步它都在模型里试很多条动作序列，然后走出最好那条的第一步。Dreamer（2019）出自同一组人，论文叫《Dream to Control》。它不是每一步都去搜一个计划，而是从模型里想象出来的未来中学出自己的行为。



FIG. 1.15 同一个小世界的两份拷贝。左边按「决策」：模型想象十二个未来，留下最好的那个，然后那个点走一步，于是每做一次决策就要花掉七十二次模型调用。右边先按一次「在想象里训练」，再按「决策」：行为是事先学好的，所以每走一步都不用花模型一分钱。要看的是那两个总调用次数的计数器，而不是那两个点。

它的第三个版本在 2025 年登上了《Nature》，用同一套设置跑了一百五十多个任务。不过早在 2019 年年底，这个词在强化学习里的读法就已经定下来了。

后来这个词开始迁移，而且是同时朝两个方向。2022 年，Yann LeCun 发表了《A Path Towards Autonomous Machine Intelligence》。他当时是 Meta 的首席 AI 科学家，也是图灵奖得主。他的论点是：把下一帧的每一个像素都预测出来，这个活儿本身就选错了，因为大多数像素都是谁也预测不了细节。

Meta 随后做出的那一系列模型 JEPA，改成预测下一帧的一份摘要。这样它就可以把解码器扔掉，也就是那个本来要把预测变回像素的部件。



FIG. 1.16 拖着年份走一遍，看那些部件。每个时期都会点亮一个部件、给它改个名，或者把它指向一个新目标，偶尔也会关掉一个。从来没有什么东西被替换掉，出于完全不同理由造出来的系统最后共用一个名字，就是这么来的。

另一个方向走向了你能看见、能走进去的世界。2024 年 2 月，OpenAI 发布了 Sora，配了一份题为《Video generation models as world simulators》的报告。同一个月，DeepMind 的 Jake Bruce 等人拿出了 Genie。它从互联网上没有标注的游戏视频里自己学出了一套动作，然后让你去玩它画出来的东西。

英伟达的 Cosmos 和 World Labs 的 Marble 在 2025 年跟上。与此同时，做可解释性的那批人把这个词借去了一件根本没有演示的事情上。他们的断言是：一个为某项任务训练出来的模型，在自己内部长出了一个关于世界的模型。

到 2026 年 6 月，World Labs 发表了《A Functional Taxonomy of World Models》，给这团乱做了一套分类，词典就此开始出现。四条传统各自握着同一个问题的不同一块，而从外面看，这个词显得很混乱。



FIG. 1.17 把年份往回拖到 2013，再一路往前走。这十年里大部分时间只有一条道上有东西，那些引导线要到 2022 年之后才开始拐弯。点一个圆点，可以看到谁用了这个词、他们用它指什么，以及他们的系统交给你什么。你会看到，这些线汇合在一个词上，而不是汇合在一个东西上。

这四方是等到各自的输出开始彼此相像，才发现自己原来是邻居。到那时候，每一方都已经用了这个词好些年。

本该一锤定音的那个测试

有一个测试照理说能把这五种一次分清，而且只要四秒钟。转过身走开，再转回来：还是同一个房间吗？内部持有一个世界的东西，会把家具留在你离开时的位置，而只会画画的东西做不到。我把它叫做转身测试。



FIG. 1.18 转身测试，做成了可以自己玩的。先把开关关掉，按一下「转身走开再回来」，看那根朱红色（也就是橙红色）柱子回来时落在哪里。然后把「保持世界不变」打开，再跑一次。右边那一栏会告诉你，两种情况下各自存了什么。

它不管用，上面这张图就说明了为什么。先别动开关，按一下「转身走开再回来」。你应该会看到那根柱子已经漂掉了，因为画面背后没有任何东西在把它按在原处。

现在把「保持世界不变」打开，再来一次。柱子纹丝不动，因为这次有一个存下来的坐标被读了回来。很好。

所以通过这个测试有两条路。你可以把房间存起来，等观看者转回来的时候再查出来。你也可以把「画出一个和刚才那一帧相符的房间」练到非常非常好。从外面看，这两条路一模一样，能把它们分开的只有那个开关。

一个在大量视频上训练出来的大模型，学到的是第二条路。没有人给它一个房间去保管。它变得很擅长把已经开了头的东西继续下去，而保持一致就是其中的一部分。所以 Genie 3 的持久性是真的，而转身测试从一开始就不可能抓住它。

DeepMind 对 Genie 3 报告的就是这个：场景在数分钟内不散架，你回到某处时细节还在。我会把它当作对方的报告，而不是实验室之外的人能核实的结论。




FIG. 1.19 这是通过生成学出来的持久性，放在很长一段过程里看。拖到一千步，读一读还有哪些性质撑得住：纹理和数目最后才垮，身份和物理最先垮。这里没有任何东西被存下来，全都是被继续出来的。

所以转身测试没法用来分类，但它伸手去够的那条区别是对的。当你转身背对那把椅子，它只是不再可见，并没有停止存在。这是两件不同的事。

不管你看不看得见，实际在那里的那一整套，叫做状态。其中你此刻能看到的那一部分，叫做观测。

状态是世界底层的实际情况；原则上是完整的，但对身处其中的任何智能体都不会直接可见。观测则是智能体对那份实际情况的局部视角。

World Labs 谈这套分类底下的那条区别 (A Functional Taxonomy of World Models, 2026 年 6 月)
<https://www.worldlabs.ai/blog/taxonomy-of-world-models>

你永远拿不到状态，拿到的只有观测，然后你得从它们往回推。想想你背后的椅子、镜头外还在滚的球，或者柜门是开是关。全都真实存在，全都看不见。



FIG. 1.20 用滑块转动摄像机，看那两栏。状态那一栏列出来的东西从来不变。观测那一栏只显示落在扇形范围里的东西，其余的都标上问号。现在转身背对那个球，按一两次「时间前进」，再转回来：球已经动了，而你对它的最后一次观测一直都是错的。

从看得见的那一部分推出其余部分，这件事叫做部分可观测性。

这些都不是新问题。剑桥的心理学家 Kenneth Craik 早在 1943 年就在一本叫《The Nature of Explanation》的书里描述过解法。

书出版那年他二十九岁。两年后他去世了，在剑桥的一条街上被撞下了自行车。那比 Kalman 早十七年，也远早于世上出现任何可以拿来实现它的东西。

如果有机体在头脑中携带着一个关于外部现实、以及关于自身可能行动的「小尺度模型」，它就能够试验各种不同的方案，判断其中哪一个最好，在未来的情境到来之前就作出反应……并且在方方面面都以更充分、更安全、更胜任的方式，去应对摆在它面前的紧急状况。

Kenneth Craik 谈内部模型，比任何人训练出一个早了四十年 (The Nature of Explanation, 1943)




FIG. 1.21 Craik 的小尺度模型，交给机器来跑。规划器写下一串串动作，把每一串都放进模型里演一遍，留下最好的那一串。把预算调高，你应该会看到被淘汰的那些淡下去，计划则越来越清晰。

在头脑里带着一个小世界的小模型，你就能在采取一个行动之前先试一试。地图上每一种定义，都是对「Craik 那个小尺度模型里该装什么」给出的一个不同答案。

他们争的到底是什么

有一个对象垫在全部五种定义底下。World Labs 自己那套分类也是从这同一个对象推出来的，而 Sutton 的 Dyna 早在 1990 年就在围着它转。

环境有一个状态。智能体收到只揭示了其中一部分的观测，再从观测和记忆里构造出一个内部状态。一个模型预测事情可能怎样演变。智能体采取行动，世界发生变化，新的观测到来。




FIG. 1.22 智能体与环境的回路，其中每一种定义都被显示为回路上某一段的专家。看上去互不相容的系统之所以共用一个名字，是因为每一个都占着同一个回路上的这一块。

你要是这样画这个回路，就会有三个问题从里面掉出来。自从 Kalman 在 1960 年写下一个滤波器以来，这个领域争的一直就是这三个问题。后面每一个都有自己的一章。

它该有多确定？ 把一个球扔到墙后面，然后问它现在在哪里。一个精确的位置是错误形状的答案，因为你无从知道。它可能撞到了什么东西，可能停在了路缘上，也可能还在滚。

一个把单个自信坐标交还给你的模型，把「它其实是在猜」这件事丢掉了。PlaNet 的做法是同时携带两样东西。一部分是确定性的(每次都同样的方式算出来，所以它总是从上一个状态推出)，它承载那些可靠地从先前推出的东西。

另一部分是随机性的(是采样出来的而不是算出来的，所以同样的输入可以产生好几种不同的未来)，它承载那些仍然可能往任一边走的東西。你可以把这个拆分看成模型在承认自己有哪些事不知道。



FIG. 1.23 拖着时间往前，看着球走到墙后面去。那个淡淡的点是确定性模型给出的答案：一个坐标，按已知速度往前挪。把随机性那一部分打开，模型就还会带着一片散布，球藏得越久，这片散布张得越开。继续拖过那个点重新出现的时刻，然后问问自己，哪一个答案撑住了。

动作会改变预测吗？接下来会发生什么和如果我推它一下会发生什么是两个不同的问题。只有第二个才让你在选择之前比较不同的选项。

能回答它的模型叫做以动作为条件的模型(它被告知采取了哪个动作，所以它能回答「如果」，而不只是「接下来」)。Kalman 的滤波器可以把你给它的控制输入往前推，但它从来不学动力学，也从来不把两个动作放在一起掂量。学习和选择都是后来才有的。




FIG. 1.24 一个起点，三种未来，由你按住哪个键决定。把动作输入关掉，看那三行叠成一行：没有动作，就只剩下「接下来大概会发生什么」，不再有「你这么会做什么」。

它能往前推多远？一次预测很少就够了。要做规划，模型必须把自己的答案重新喂回去，再预测一次，再一次，全都叠在它刚刚编出来的东西上面。你要求的步数叫做预测步长。

误差沿着这一段堆积起来。任何单独一步都没有出什么大事，这正是这个问题难以察觉的原因。可是第一步稍微错一点，第二十步就可能到完全不同的地方去了。

$$p(\underline{s_{t+1}} \mid s_t, a_t) \Rightarrow p(\underline{s_{t+1:t+H}} \mid \underline{s_t}, \underline{a_{t:t+H-1}})$$

把要问的东西从 下一个状态 换成 从这里到 H 的每一个状态，
而你手里仍然只有 你所处的同一个状态 以及 一整套计划。

FIG. 1.25 同一个模型，这次要求的不是一步，而是一整段未来。你要的那段未来和你交进去的那份计划都在变大，而给你的那个状态没有。

Dreamer 的存在，就是为了跨越许多想象出来的步骤去学出行为。DeepMind 把长时程连贯性列为它那些生成世界的头号开放问题。意思是一个场景能在许多步之内始终忠于自己。

Dreamer 是 2019 年的潜在动力学模型，Genie 3 是 2025 年的像素渲染器。它们分别待在地图的两端，从相反的方向对付同一个问题。




FIG. 1.26 两个点从同一个位置出发，遵循同一套规则，只不过其中一个跑的动力学差了几个百分点。拖到 8 左右，你会看到它们还在一起。继续拖，你会注意到没有任何单独一步是断裂的，可那个差距一直在往上堆。

所以六十年过去，摆在面前的开放问题是漂移，恰恰就是卡尔曼滤波器当年被造出来要纠正的那个东西。区别在于，一段想象出来的推演没有新的读数可以拿来校正。

现在回到那段短片。它是一个渲染器，而且你说得出为什么：它预测观测。它之所以能留住那个房间，是因为它学会了这么做，而它内部没有任何东西承诺底下有几何结构。

下一段划过你时间线的短片，也会被叫做世界模型。该问的是它属于五种里的哪一种，以及发帖的人说不说得出来。

希望这一章帮上了忙。下面有一个小测验，你要是想检查这些想法有没有记牢，可以做一下。如果我哪里写错了，或者你知道比我用的更好的来源，「关于」页面上有一个更正栏目。我很乐意听到你的消息。

试一试

1 它接收一张厨房的照片，输出一个可以导入游戏引擎的网格，台面上还带有碰撞体。

渲染器 · 仿真器 · 动力学模型 · 表征模型 · 内隐模型

答案 仿真器. 别的程序可以打开它并对它做计算。碰撞体就是关键线索：它们存在是为了让物理引擎去碰撞，而不是为了给你看。

2 你正在看一个房间的摄像头画面。摄像头背后有一把椅子。这把椅子在哪里？

- a. 不在状态里，因为没有任何东西看得见它
- b. 在状态里，但不在观测里
- c. 在观测里，但不在状态里
- d. 两者都不在，直到摄像头转过去

答案 b. 在状态里，但不在观测里. 转过身并不会让家具消失。椅子是存在的东西的一部分，只是不属于你此刻能看到的部分。这门课里大多数难题，都来自这两者之间的那道缝隙。

3 你按住一个键，它就一帧一帧地生成一座从未存在过的城市的视频，并根据你转向的方向作出反应。

渲染器 · 仿真器 · 动力学模型 · 表征模型 · 内隐模型

答案 渲染器. 它的输出就是画面。开车过程中画面也许一直保持一致，但底下没有任何东西必须如此，也没有一座城市可以交给别人。

4 你转过身再转回来，某个系统让房间保持了原样。这证明了什么？

- a. 它把房间存了下来
- b. 它没有把房间存下来
- c. 单凭这一点什么也证明不了
- d. 它一定是仿真器

答案 c. 单凭这一点什么也证明不了. 通过这个测试有两条路，而从外面看它们一模一样。你可以把房间保存下来，也可以把它重画得非常准。结果相同，所以结果本身没法告诉你是哪一条。

5 它只被训练来预测国际象棋对局中的下一步棋。研究者后来用探针检查，发现它在内部记录了棋子的位置。

渲染器 · 仿真器 · 动力学模型 · 表征模型 · 内隐模型

答案 内隐模型. 这里没有人造出一个下棋模型，也没有人能运行一个。这个断言讲的是在为别的任务训练出来的网络内部发现了什么结构，和其他几种断言在性质上就不同。

6 一个模型每一步都稍微错一点。你把它自己的输出重新喂回去二十次。误差会怎样？

- a. 基本保持不变
- b. 大约翻一倍
- c. 会增长，而且不均匀，最后可能到完全不同的地方
- d. 步数够多以后会互相抵消

答案 c. 会增长，而且不均匀，最后可能到完全不同的地方. 每一个想象出来的状态都会成为下一次预测的输入，于是错误被叠在错误上面。任何单独一步都没有出什么大事，这就是它难以察觉的原因。

7 它遮住视频的一部分，学着预测被遮住那部分的一个摘要。训练完成后，预测被丢掉，剩下的部分被装到一个机器人上。

渲染器 · 仿真器 · 动力学模型 · 表征模型 · 内隐模型

答案 表征模型. 那个预测只是脚手架。训练结束后留下来的，是它学会的描述事物的方式，那才是产物。

8 从预测一步变成预测 H 步，什么东西没有变大？

- a. 你要问的那一段未来
- b. 你必须提供的动作数量
- c. 你出发时手里已有的东西
- d. 可能出错的方式的数量

答案 c. 你出发时手里已有的东西. 无论你问多远，你仍然只站在一个地方，只有关于它的一次观测。问题变大了，证据没有。

9 给定一个紧凑状态（几个描述场景的数字）和一个你正在考虑的电机指令，它返回你接下来会处于的紧凑状态。一个搜索循环每做一次决定要调用它几百次。

渲染器 · 仿真器 · 动力学模型 · 表征模型 · 内隐模型

答案 动力学模型. 它交给你的是状态而不是画面，而且你可以在没人执行过的动作下把它往前推。这正是动力学模型的契约，搜索循环就是它存在的目的。如果它返回的是下一个传感器读数，你看到的就是渲染器。

10 为什么卡尔曼滤波器算作前身，而不算五种定义中的一种？

- a. 它太老了，不算数
- b. 它的动力学是给定的而不是学出来的，而且它从不比较动作来做选择
- c. 它完全不能接受控制输入
- d. 它只适用于线性系统

答案 b. 它的动力学是给定的而不是学出来的，而且它从不比较动作来做选择. 它把一半的工作做得很好：从带噪声的测量里算出隐藏状态，你给它一个控制输入，它也会往前推演。它从不做的是学习动力学，或者在两个动作之间权衡，而那正是让其余几种定义能用来做选择的东西。线性只是最初版本的一个细节，不是原因。

11 历史上有一个阶段是拿掉了一个部件，而不是加上一个。是哪一个，为什么？

- a. 编码器，因为像素不再重要了
- b. 解码器，因为预测目标从像素上移开了
- c. 控制器，因为规划被放弃了
- d. 动力学，因为它变成隐式的了

答案 b. 解码器，因为预测目标从像素上移开了。JEPA 预测的是下一帧的摘要而不是这一帧本身，所以不再需要什么东西把预测变回像素。这也正是预测可以被丢掉、特征却留下来的原因。

12 某个实验室生成高速公路驾驶的逼真视频，用来训练自动驾驶系统。它的宣传定位是机器人方向。

渲染器 · 仿真器 · 动力学模型 · 表征模型 · 内隐模型

答案 渲染器. 这就是那个陷阱。面向机器人听起来像仿真器，但它的输出仍然是视频，没有任何人可以撞上去的几何结构。一个系统是给谁用的，是比它交给你什么更弱的线索。就连这条线索也不是完整答案，因为一个大平台可以同时提供好几个接口，所以问题是你即将对着哪一个接口开发。

13 某个实验室称他们的系统能保持数分钟的一致性。你自己没法运行它。这条信息应该怎么记？

- a. 当作事实，毕竟是他们造的
- b. 当作对方的报告，而不是已经核实过的结论
- c. 在被证明之前当作假的
- d. 与分类无关，可以忽略

答案 b. 当作对方的报告，而不是已经核实过的结论. 这不是为了怀疑而怀疑。有些说法你可以自己打开验证，比如一个能加载的网格；有些你只能接收。分清哪些是哪些，是读这个领域的一部分。

FIG. 1.27 十三道题，覆盖整章。它们会让你用那些图本来就是为了讲清楚的想法，去给我从未点名的系统归类。其中有一道是陷阱，而这种错误，我宁愿你在这里犯，而不是在会议上犯。

参考资料

A Functional Taxonomy of World Models WORLD LABS, 2026 ↗

第一方给出的渲染器／仿真器／规划器三分法，是从智能体循环推出来的。

<https://www.worldlabs.ai/blog/taxonomy-of-world-models>

A New Approach to Linear Filtering and Prediction Problems KALMAN, 1960 ↗

隐藏状态这条线的祖先。需付费。

<https://doi.org/10.1115/1.3662552>

Making the World Differentiable: On Using Self-Supervised Fully Recurrent Neural Networks for Dynamic Reinforcement Learning and Planning in Non-Stationary Environments (FKI-126-90)

SCHMIDHUBER, 1990 ↗

把控制器和世界模型当作两个分开的对象，也就是这一章开头讲的那个区分。

<https://people.idsia.ch/~juergen/world-models-planning-curiosity-fki-1990.html>

World Models HA & SCHMIDHUBER, 2018 ↗

编码器、潜在动力学、紧凑控制器，还包括把策略完全放在模型生成的环境里训练、再搬回真实环境的实验。

<https://arxiv.org/abs/1803.10122>

Learning Latent Dynamics for Planning from Pixels (PlaNet)

HAFNER ET AL., 2018 ↗

从图像里学出随机潜在动力学，然后在决策时对它做搜索。图 2.4 的真实版本。

<https://arxiv.org/abs/1811.04551>

Dream to Control (Dreamer) HAFNER ET AL., 2019 ↗

在想象出来的潜在轨迹上训练 actor 和 critic，于是动手的那一刻不必再跑昂贵的搜索。

<https://arxiv.org/abs/1912.01603>

I-JEPA ASSRAN ET AL., 2023 ↗

预测被遮住区域的表征，而不是像素。

<https://arxiv.org/abs/2301.08243>

V-JEPA 2 META AI, 2025 ↗

先做无动作预训练，再做动作条件下的控制。

<https://ai.meta.com/blog/v-jepa-2-world-model-benchmarks/>

Genie: Generative Interactive Environments BRUCE ET AL., 2024 ↗

可以用动作操控的生成环境。

<https://arxiv.org/abs/2402.15391>

Genie 3 GOOGLE DEEPMIND, 2025 ↗

报告称能在多分钟的交互里回想起先前见过的细节。

<https://deepmind.google/blog/genie-3-a-new-frontier-for-world-models/>

Marble WORLD LABS, 2025 ↗

高斯泼溅加碰撞网格：一次显式的结构导出。

<https://www.worldlabs.ai/blog/marble-world-model>

Cosmos NVIDIA ↗

一个边界案例：预测式视频世界与显式仿真并置。

<https://www.nvidia.com/en-us/ai/cosmos/>

Emergent World Representations LI ET AL., 2022 ↗

在 Othello-GPT 内部找到棋盘状态，并且能对它做因果干预。

<https://arxiv.org/abs/2210.13382>

Othello-GPT has a linear emergent world representation NANDA ET AL., 2023 ↗

把这个发现进一步锐化的后续工作。

<https://arxiv.org/abs/2309.00941>

Language Models Represent Space and Time GURNEE & TEGMARK, 2023 ↗

探针从一个大语言模型里读出了地点和日期，关于这一层意思的争论就是围绕这篇论文形成的。

<https://arxiv.org/abs/2310.02207>

FIG. 1.28 我的排序是给要在这上面接着做事的人用的，而不是为了历史完整性，并且全程优先采用第一手材料。