

# 03 预测即学习

作者 NILUSHANAN KULASINGHAM

阅读约 12 分钟 · 可交互


让一个东西去预测接下来会发生什么，它就不得不把「下一刻取决于什么」造出来。同一个循环换个角度读，原来就是压缩。

这是一张球在半空中的照片。下一刻它在哪里？

你说不出来。往上、往下、往旁边，或者几乎没在动：每一种情况下这张照片看起来都一样。回答这个问题所需要的一切，都不在这张照片里。

现在拍两张照片，相隔零点几秒。答案在你还没问完的时候就已经到了。

变的不是细节的多少。两张照片一样清晰。变的是：两帧里装着一帧装不下的东西，一个方向和一个速度。没有人把它们画在图上。它们不在任何一张照片里。它们只存在于两张照片之间的关系中，而你没被要求就把它抽了出来。



**FIG. 3.1** 那把扇形是与「已经看到的東西」仍然相容的所有未來。一幀什麼都排除不了。第二幀定下方向和速度。第三幀定下路徑會不會彎。多出來的每一幀都不是更多細節，而是多一樣你能推出來、卻從來不在任何單張畫面里的東西。

這就是這一章要講的那個把戲。讓一個東西去預測接下來會發生什麼，它就不得不把「下一刻取決於什麼」這些東西造出來。不是因為你要求了，而是因為不造它就不可能猜對。

# 猜，檢驗，修正

這個循環就跟它聽起來一樣小。

看看你手裡有什麼。說出你覺得接下來會是什麼。等着。把真正到來的和你說的比一比。朝着「本來會少錯一點」的方向把自己改一點點。然後再來一遍。

讓它有力量的不是哪一步有多聰明，而是正確答案本來就在那兒。沒有人需要去標注任何東西，因為你要預測的對象就是這段記錄的下一小段，而記錄裡已經有它了。

这就是自监督的意思。说它是有监督的，是因为模型确实被明确告知了自己错了多少；只不过告诉它的是数据本身，而不是一个拿着表格的人。

这听起来像是一件行政上的小便利。它其实是这套做法吞掉整个领域的全部原因。标注是机器学习里最贵的那部分：得有人看一百万张图，再把里面有什么写下来。预测把这一步跳过了。任何东西的任何一段记录，本身就已经是一个训练集，因为里面的每一刻都是上一刻的答案。



FIG. 3.2 一个预测器根据前两个数猜下一个数，每猜一次就被修正一点点。它从零开始，什么都不知道。看着虚线一点点爬到实线上，然后看看它学到了什么：两个没有任何人提供过的数字，只靠「猜错了再调」得出来。

那个演示里没有任何东西告诉过它规则。它被告知的，是两百二十次「你刚才差了多少」。每一次它都把自己的那两个数 (也就是权重：模型内部可调的那些数字，也是学习唯一会改动的东西) 朝着对的方向挪一点。这就够了。

---

# 猜测逼着你造出什么

从这里开始，它就不只是个把戏了。

要预测得好，你就得把「下一刻取决于什么」随身带着。如果序列是一个球，那就是位置和速度。如果序列是语言，那要带的东西就多得多，而且没有一样是被直接要求过的。

1990 年，Jeffrey Elman 训练了一个小网络，只做一件事：读一个词，预测下一个词。然后他去它内部看了看。那些内部状态自己分成了几组，而这些组恰好是名词和动词、有生命的和无生命的、能吃东西的和能被吃的。没有人给过它任何一个类别。它之所以走到这些类别上，是因为一个词的类别正是它的下一个词所依赖的东西。

这个结果的现代版本更让人意外。拿一个只被训练去预测黑白棋（一种棋，通过把对方的棋子夹在自己两枚棋子之间来把它们翻过来）合法着法的网络，它从没见过棋盘，也没被告知规则。用探针去读它的内部激活（训练一个小的独立分类器，专门从网络内部的数字里读出某一个具体事实），你会在里面找到棋盘的状态。然后去改动这个内部棋盘，看着它接下来走的棋跟着一起变。这一点才让它成为一个发现，而不是一件趣闻。棋盘不是碰巧躺在那些数字里的，它是网络正在用的东西。

这两件事底下的规律值得直说：预测并不奖励「描述」。它奖励的是任何能让下一刻更不意外的东西，而有时候，让自己不那么意外最省事的办法，就是把真正在生成这些数据的那个东西造出来。

---

是有的时候。不是永远，也不是靠魔法。预测器很乐意退而求其次，用一条在它见过的数据上管用的捷径糊弄过去，而这门课剩下的大部分内容，讲的就是怎么把这两者分开。

---

## 预测下一个「什么」？

这个循环说的是预测下一个东西。它从来没说什么才算一个东西，而这个选择决定了你最后拿到的是什么。

预测下一个像素，你会得到一个非常擅长树叶的系统。树叶确实很难预测，而且它们也确实占了大部分像素，所以容量就花在那儿了（容量就是一个模型能装多少。花在一件事上，就不在另一件事上了）。预测下一个词，你会得到语法，还有出乎意料的一大堆关于世界的知识，因为那正是下一个词所取决于的东西。预测某个紧凑描述的下一个状态，你会得到一个规划器用得上的东西。

同一个循环，三台不同的机器。唯一变的，是被放在这个猜测右边的东西。

所以预测下一个东西不是一种方法，而是一个家族；而挑选目标，是其中最要紧的那个设计决定。


---

## 猜得准就等于说得短

看待这整件事还有第二种方式，而它最后被证明就是同一种方式。

假设你要往一根线上发一条消息，而且按符号收费。你和接收方共享同一个预测器。每发一个符号之前，你们各自跑一遍预测器，得到一份「接下来大概会是什么」的清单。于是你只需要发出足够从这份清单里挑出正确那一个的信息就行了。

如果预测器既自信又猜对了，这几乎不花钱。如果它既自信又猜错了，那就很贵。香农把这件事写精确了：一个你给了二分之一概率的符号花一个比特（一个比特就是一次「是或否」的回答，所以八个比特能从 256 个选项里挑出一个），四分之一概率花两个，千分之一概率大约花十个。



**FIG. 3.3** 同一个句子，由质量越来越高的预测器写下来。这里的「每字符比特数」是关于英文的公开估计值，而不是这幅图自己算出来的东西。最下面一行大致是香农测出的人类逐字母猜英文的水平，也是今天好的语言模型所在的位置。

所以，你能写出的最短消息的长度，就是对你预测得有多好的一次测量。更好的预测器就是更好的压缩器；反过来读也成立：把你的数据压得最狠的那个东西，就是对它理解得最多的那个。

这不是比喻。有一个长期悬赏，奖励把一份维基百科快照压得更小，理由正是：不知道文本的意思，你就没法把它挤得更小。到目前为止的每一位获奖者，本质上都是一个语言模型。

这也解释了为什么预测的价值远比它看起来大。你不是在要求一个系统去背。背是那个贵的选项：一张把发生过的一切都记下来的查找表，既庞大又对新东西毫无用处。便宜的那个选项，也就是真正能让消息变短的那个，是把产生这些数据的规律找出来，然后只留下它。

---

# 它在哪里就不够用了

两个诚实的限制，因为到这里为止的论证顺利得有点可疑。

预测得好，不等于有用。一个系统可以非常擅长把一段记录接下去，却仍然给不了你任何可以据以行动的东西。说出接下来会发生什么，和说出「如果你做了别的事、接下来会发生什么」，不是一回事。只有后者才撑得起一个决定。

不感到意外，不等于是对的。一个只见过好天气的预测器不会被好天气惊到，而这一点完全没告诉你它在暴风雨里会怎么样。在你碰巧录下来的东西上误差很低，是一个比它听起来要弱得多的论断。

这些都推翻不了这一章。预测确实足以把结构从原始经验里拽出来，也确实是目前找到的最便宜的信号。它只是不免费，而且它不会自己瞄准。

# 试一试

1 一张球在飞行中的照片。有什么是你从它推不出来的？

- a. 球在哪里
- b. 球有多大
- c. 它往哪个方向走、走得多快
- d. 它是什么颜色

**答案** c. 它往哪个方向走、走得多快. 方向和速度不在任何单独一帧里。它们存在于帧与帧之间的关系中，而这正是预测器不得不自己造出来的那类东西。

2 为什么「预测下一个东西」比用标注数据训练便宜那么多？

- a. 模型更小
- b. 答案本来就在记录里，没有人需要写标注
- c. 它需要的计算时间更少
- d. 它收敛需要的步数更少

**答案** b. 答案本来就在记录里，没有人需要写标注. 每一刻都是上一刻的答案。这把任何东西的任何记录都变成了训练集，也去掉了「得有人标注一百万个样本」这一步。

3 Elman 的网络只被训练去预测下一个词，而它的内部状态自己分成了名词、动词、有生命与无生命。为什么？

- a. 这些类别本来就在训练标注里
- b. 架构里每个类别有一个单元
- c. 一个词的类别正是它的下一个词所依赖的东西，所以这些类别是「少犯错」最省事的办法
- d. 它把语料背了下来

**答案** c. 一个词的类别正是它的下一个词所依赖的东西，所以这些类别是「少犯错」最省事的办法. 没有任何东西提供过这些类别。预测奖励的是任何能让下一刻更不意外的东西，而语法类别恰好就是这样的东西。

4 探针在一个只用合法黑白棋着法训练的网络里找到了棋盘状态。是什么让它从一件趣闻变成一个发现？

- a. 探针非常准
- b. 网络很大
- c. 改动那个内部棋盘，网络接下来走的棋也跟着变
- d. 棋盘可以画成一张图

**答案** c. 改动那个内部棋盘，网络接下来走的棋也跟着变. 光是准，有可能只是数字里的巧合。对表征做干预、再看到行为跟着改变，才说明网络确实在用它。

5 在一个好的预测器下，一个你很有把握而且猜对了的符号，发送起来几乎不花钱。为什么？

- a. 它可以从消息里省掉
- b. 一个符号的代价由你给它的概率决定
- c. 常见符号被存在一张表里
- d. 接收方自己猜就行，不需要消息

答案 b. 一个符号的代价由你给它的概率决定. 香农把这个价格写精确了。概率高就意味着码长短，这也是为什么更好的预测器字面意义上就是更好的压缩器。

6 从压缩的角度看，「把训练数据背下来」是怎么回事？

- a. 这是能用的最好策略
- b. 这是贵的那个选项：把一切都记下来的查找表既庞大又对新东西没用
- c. 它比任何规律压得都好
- d. 所有学习做的都是这件事

答案 b. 这是贵的那个选项：把一切都记下来的查找表既庞大又对新东西没用. 短消息来自「找出生成数据的规律，然后只留下它」。背，恰恰是压缩要惩罚的东西。

7 同一个循环，不同的目标：预测下一个像素、下一个词，或者下一个紧凑状态。这个选择改变了什么？

- a. 什么也没变，重要的是那个循环
- b. 只改变训练要多久
- c. 改变这个系统最后擅长什么，以及它的容量花在哪里
- d. 改变这套方法算不算自监督

答案 c. 改变这个系统最后擅长什么，以及它的容量花在哪里. 去预测每一个像素，容量大半会花在树叶上，因为那里才是大部分像素。挑目标是这里最要紧的设计决定。

8 一个模型在预测某段记录的下一帧时误差非常低。单凭这一点，什么是它没告诉你的？

- a. 它见过这段记录
- b. 如果你做了别的动作它会预测什么，以及它在录下来的范围之外会怎么样
- c. 误差是不是量对了
- d. 这段记录是不是够长

答案 b. 如果你做了别的动作它会预测什么，以及它在录下来的范围之外会怎么样. 对你碰巧录下来的东西不感到意外，是个比听起来弱得多的论断；而说出接下来会发生什么，也不等于说出在另一个动作下会发生什么。

FIG. 3.4 八道关于这个循环以及它产出什么的题。最后两道分开的是「一个好的预测器」和「一个有用的预测器」。

---

这里的一切都悄悄假设了被预测的那个东西很小：一个球两个数，语言一次一个词。而一台摄像机一秒钟给你三十次、每次两百万个数字，其中几乎全是树叶。

多谢阅读。第 4 章讲的是中间那道收窄口：一个系统怎么从「世界看起来是什么样」走到「世界处在什么状态」，以及为什么那个窄口做的事，比它两边的预测加起来还多。

---

## 参考资料

### A Mathematical Theory of Communication SHANNON, 1948 ↗

一个符号的代价在这里变成了「你给它的概率」。预测与压缩是同一件事，一切都从这儿开始。

<https://people.math.harvard.edu/~ctm/home/text/others/shannon/entropy/entropy.pdf>

### Prediction and Entropy of Printed English SHANNON, 1951 ↗

香农让人坐下来，一个字母一个字母地猜英文。图 3.3 最下面那一行大致就是他测出来的。

<https://doi.org/10.1002/j.1538-7305.1951.tb01366.x>

### Finding Structure in Time ELMAN, 1990 ↗

训练一个小网络去预测下一个词，然后往里看：名词、动词、有生命与无生命，没有一样是被要求过的。

[https://doi.org/10.1207/s15516709cog1402\\_1](https://doi.org/10.1207/s15516709cog1402_1)

### Emergent World Representations LI ET AL., 2022 ↗

在 Othello-GPT 内部找到棋盘状态，并且能对它做因果干预。

<https://arxiv.org/abs/2210.13382>

### Othello-GPT has a linear emergent world representation NANDA ET AL., 2023 ↗

把这个发现进一步锐化的后续工作。

<https://arxiv.org/abs/2309.00941>

### Language Models are Unsupervised Multitask Learners RADFORD ET AL., 2019 ↗

把「预测下一个词」放大之后，长出了没有人训练过的能力。这是「目标选择才是那个设计决定」最有力的证据。

[https://cdn.openai.com/better-language-models/language\\_models\\_are\\_unsupervised\\_multitask\\_learners.pdf](https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf)

### The Hutter Prize HUTTER, ONGOING ↗

一项压缩维基百科快照的现金悬赏，理由是：不建模文本的含义，你就压不动它。

<http://prize.hutter1.net/>

### Representation Learning: A Review and New Perspectives

BENGIO, COURVILLE & VINCENT, 2013 ↗

这篇综述梳理了「一个好的学出来的表征是拿来干什么的」，写在预测彻底赢下这场争论之前。

<https://arxiv.org/abs/1206.5538>

Formal theory of creativity, fun, and intrinsic motivation SCHMIDHUBER, 2010 ↗

把压缩进展本身当作一种驱动力：它不只是衡量模型的尺子，也是跑去看点什么的理由。

<https://people.idsia.ch/~juergen/creativity.html>

**FIG. 3.5** 排序是给要在这上面接着做事的人用的，而不是为了历史完整性。