

03 为什么预测就是学习？

作者 NILUSHANAN KULASINGHAM

阅读约 16 分钟 · 可交互

让一个东西去预测接下来会发生什么，它就不得不把「下一刻取决于什么」造出来。Jeffrey Elman 在 1990 年用词语证明了这一点，而在那之前，Claude Shannon 已经证明同一个循环换个角度读就是压缩。

本章的图都是可交互的。请到 worldmodels101.com/zh/chapters/prediction 在线按一按、拖一拖。

拿一张球在半空中的照片，再问它下一刻会在哪里。你说不出来。往上、往下、往旁边，或者几乎没在动，每一种情况下这张照片看起来都一样。回答这个问题所依赖的一切，都不在单独这一帧里。

现在拍两张照片，相隔零点几秒。这一次，答案在你还没问完的时候就到了。两张照片一样清晰，所以变的不是细节。

两帧里装着一帧装不下的东西：一个方向和一个速度。它们哪一张照片上都没画着。它们只活在两张之间的关系里，而你没被要求，就把它抽了出来。




FIG. 3.1 把「已看到的帧数」从一拖到三，看那把扇形。扇形是与已经看到的东西仍然相容的所有未来。一帧什么都排除不了。第二帧定下方向和速度，第三帧定下路径会不会弯。多出来的每一帧，都是多一样你能推出来的量，而它们没有一样在任何单张画面里。

让一个东西去预测接下来会发生什么，它就不得不把下一刻所依赖的东西造出来。这些东西从来没有人要求过，可没有它们，它就不可能猜对。我把它们叫作偷渡客：预测器不得不载着走、却没有人写进舱单的那些量。方向和速度是头两个。

从那以后，人们一直在找出更大的偷渡客，而且每一次用的仪器都更好。最先动手的是 Claude Shannon，1948 年，*A Mathematical Theory of Communication*。他证明了：你能把一条消息预测得多准，定下了发送它的价钱。

1990 年轮到 Jeffrey Elman，*Finding Structure in Time*。他在一个只被要求猜下一个词的网络里，找到了语法。接着在 2022 年，Kenneth Li 及同事写了 *Emergent World Representations*，在一个只被要求猜落子的网络里，找到了一整张棋盘。

年份与人	开篇：那只球
被要求做	说出球会在哪里
仪器	两张照片
不得不携带	在货舱里
年份与人	1948，克劳德·香农
被要求做	便宜地发出一条消息
仪器	一支铅笔和一些概率（信息的数学）
不得不携带	在货舱里
年份与人	1990，杰弗里·埃尔曼
被要求做	猜下一个词
仪器	查看网络的内部状态，并把它们分组
不得不携带	在货舱里
年份与人	2022，Kenneth Li 及同事
被要求做	猜下一步合法的黑白棋落子
仪器	一个训练来从激活里读出一条事实的探针
不得不携带	在货舱里
已打开的行	
4 行中的 0 行	

FIG. 3.2 我们接下来要走一遍的三个发现，摆成一张账本。每一行写着这个系统被要求做什么，以及人们用什么仪器去看。按一下「打开货舱」，第三列就会填上它为了把活干成而不得不携带的东西。这些没有一样写在舱单上。

「预测就是学习」这句话被说得很多，通常是当口号说的，很少有人交代预测器到底学到了什么，也很少有人交代是谁怎么核对的。

猜，检验，修正

这个循环就跟它听起来一样小。看看你手里有什么，说出你觉得接下来会是什么。等一等，再把到来的和你说的比一比。朝着「本来会少错一点」的方向把自己改一点点，然后再来一遍。

没有哪一步算得上聪明。它的力量在于这个循环不需要什么：没有人需要标注任何东西，因为目标就是这段记录的下一小段。我们来看它跑一遍。




FIG. 3.3 按一下「运行」。预测器根据前两个数猜下一个数，每猜一次就被修正一点点。它从零开始，什么都不知道。看着虚线一点点爬到实线上，然后看看「它学到的东西」：两个没有任何人提供过的数字，全靠猜错了再调得出来。

那幅图里没有任何东西告诉过它规则。它被告知的，是两百二十次「你刚才差了多少」。每一次它都把自己的那两个数 (也就是权重：模型内部可调的那些数字，也是学习唯一会改动的东西) 朝着对的方向挪一点，这就够了。漂亮。

自监督的意思全在这里了。说它有监督，是因为模型每猜一次都被告知自己错了多少。说它是自，是因为告诉它的是数据本身，而不是一个拿着表格的人。

这个领域的大部分历史里，模型都是从别人标注好的样本里学的。一百万张图，意味着有个人把每一张里有什么都写下来。标注是贵的那一部分，一个数据集有多大，就是某人的预算有多大。预测把这张账单跳过去了，因为任何东西的任何一段记录，本身就已经是一个训练集。

2013 年这件事还在争论中。那一年 Yoshua Bengio、Aaron Courville 与 Pascal Vincent 写了 *Representation Learning: A Review and New Perspectives*。这是一篇综述，读起来像是一个还在被辩护的主张。真正定下胜负的是数据不要钱，而正是这份便利，而不是某一个具体成果，让预测吞下了整个领域。




FIG. 3.4 在两种训练方式之间扳一下开关。左边这种，每个样本都要有个人在旁边写下答案，标签账单跟着数据一起涨。右边这种，答案就是同一段记录的下一帧，没有人为任何事收钱。把「数据量」往上拖，看哪一边的账单在长。数字仅作示意。

猜测逼着你造出什么

Elman 是加州大学圣迭戈分校的一位认知科学家，他是从语言研究这条路走到网络上来的。1990 年，他训练了一个小网络，只干一件事：读一个词，预测下一个词。

然后他往里面看。那些内部状态自己分成了几组。这些组是名词和动词，有生命的和无生命的，能吃东西的和能被吃掉的。

没有人给过这个网络任何一个类别。它之所以走到这些类别上，是因为一个词的类别正是它的下一个词所依赖的东西。*Finding Structure in Time* 这个标题是照字面说的：结构是被找到的，不是被装进去的。




FIG. 3.5 每一个点是一个词，位置由网络内部对它的状态决定。开关停在「训练前」，这些词是散着的。扳到「训练后」，看它们自己排好：动词到一边，名词到另一边，名词里有生命的又和无生命的分开。悬停或点按一个点，可以读出这个词。这里没有任何东西被标注过，点的位置仅作示意。


很长一段时间里，事情就停在这儿。网络很小，那套语法是个玩具，而玩具算不上一个关于世界的论断。这个发现等了三十二年，才等到能把它变成论断的仪器。

2022 年，Li 和同事们，也就是可解释性研究者（把网络拆开来看、而不是训练网络的那批人），拿了一个后来被叫作 Othello-GPT 的网络。它只被训练去预测黑白棋（一种在八乘八格子上下的棋。你把对方的棋子夹在自己两枚棋子中间，就能把它们翻过来）里的合法着法。它从没见过棋盘，也没被告知过规则。


他们用探针去读它的激活值（训练一个小的独立分类器，专门从网络内部的数字里读出某一个具体事实）。棋盘的状态就在里面，而光是这一点，还只能算一件趣闻。

把它变成一个发现的，是那一步干预。改动这个内部棋盘，网络接下来走的棋就跟着变。所以棋盘在那里，是因为网络正在用它。这两步值得分开来看，因为只有第二步才真的定得下什么。

靠棋盘落子



探针自己算出来



观察到 还没有任何结果

测试

还没有做任何测试

还站得住的说法

2

排除靠的是什么

还没有

FIG. 3.6 关于同一个网络的两种说法，差别只在一根线上。先按「读出棋盘」，两种说法都活得下来，因为两种都认为棋盘读得出来。再按「改动其中一格」，看接下来的合法着法：在一种说法里它们跟着变，在另一种说法里下游根本没有东西可跟着变。那几串着法仅作示意。

2023 年，Neel Nanda 和同事们又研究了同一个网络，写成 *Othello-GPT has a linear emergent world representation*。Li 用的探针本身是一个小网络，因为一条直线试过、没成。Nanda 证明了只要问对问题，一条直线就够用。这个网络存每一格用的是「我方还是对方」，而不是「黑还是白」，而且每走一手就把视角翻一次。

隔着三十二年的这两个结果，底下是同一条规律。预测只奖励一件事：让下一刻更不意外。而有时候，让自己不那么意外最省事的办法，就是把正在生成这些数据的那个东西本身造出来。

预测器很乐意退而求其次，用任何一条在它见过的数据上管用的捷径糊弄过去。把这条捷径和它所替代的那个真实过程分开，才是大部分工作所在。

预测下一个「什么」？

这个循环说的是预测下一个东西。它从来没说什么才算一个东西，而这个选择就是那个设计决定。我们一个一个来看三种选法。

预测下一个像素，你会得到一个非常擅长树叶的系统。树叶很难预测，而且它们也占了大部分像素，所以容量就花在那儿了（容量就是一个模型能装下多少。花在一件事上，就不在另一件事上了）。我把这个叫作树叶问题，第 4 章整章都是围着它建起来的。



FIG. 3.7 同一个循环，三个目标。挑一挑放在这个猜测右边的是什么。先停在「像素」上，看容量条落在哪儿：落在树叶上，它们占了画面的大半，也是最难说准的部分。切到「词」，条子就移到语法和事实上。切到「紧凑状态」，你得到的是一个规划器可以在里面搜索的东西。条子的长短仅作示意。循环里别的什么都没变。

预测下一个词，你会得到语法，还有出乎意料的一大堆关于世界的知识，因为下一个词就取决于这些。2019 年，OpenAI 的 Alec Radford 和同事们展示了这条路在大规模上能走多远。他们的论文是 *Language Models are Unsupervised Multitask Learners*。

他们的模型是 GPT-2。它的训练内容只有一件事：在一大堆网络文本上预测下一个词。出来以后，它会回答问题、会做摘要、还能翻译一点，而这几样没有一样是有人专门训练过的。OpenAI 是分阶段把它放出来的，他们对一台能写出流畅文本的机器会被拿去干什么，心里不踏实。

模型之所以学会这些任务，是因为下一个词有时候取决于它们。这是我们手上最清楚的证据，说明目标决定了什么东西会被造出来。

法国的首都是 ____。

先在心里把空填上，再按「揭晓」。

GPT-2 只被训练做一件事：预测下一个词。

句子	下一个词取决于什么
第 1 句，共 5 句	先自己试试

FIG. 3.8 一句一句走过去，先自己把空填上，再按「揭晓」。每一句都挑得让下一个词取决于另外一样东西：一个事实、一次翻译、对前文的一段概括。没有人需要把这些当成任务去教。它们只是下一个词有时候所取决于的东西。

预测某个紧凑描述的下一个状态，你会得到一个规划器用得上的东西。紧凑的意思是一小串数字，而不是一张画面。

所以同一个循环给出了三台不同的机器，唯一变的，是被放在这个猜测右边的东西。预测下一个东西是一族方法，而不是一种。挑选目标是最要紧的那个设计决定，所以任何关于预测的论证，都该说清楚被预测的到底是什么。

猜得准就等于说得短

看待这件事还有第二种方式，它比 Elman 的结果早了四十年，而结论是同一个。Shannon 是贝尔实验室的数学家，那是美国电话公司的研究部门，他们的生意就是往同一根线上多塞几通电话。假设你要往一根线上发一条消息，而且按符号收费。

你和接收方共享同一个预测器。每发一个符号之前，你们各自跑一遍，得到一份「接下来大概会是什么」的清单，于是你只需要发出足够从这份清单里挑中正确那一个的东西。既有把握又猜对了，几乎不花钱；既有把握又猜错了，就很贵。




FIG. 3.9 拖动「预测器给它的概率」，设定共享预测器认为实际到达的那个符号有多大可能，然后读出发送这个符号要花多少。拖到中间，二分之一，花一个比特。往左端推，那里是预测器有把握却猜错了的情形，看价钱怎么往上爬。往右推，它几乎不要钱。

1948 年，Shannon 把这件事写精确了。一个你给了二分之一概率的符号花一个比特 (一个比特就是一次「是或否」的回答，所以八个比特能从 256 个选项里挑出一个)，四分之一概率花两个，千分之一概率大约花十个。那篇论文开创了信息论，「比特」这个词也是头一回印在纸上。

三年后，他把这套论证掉过头来对准了英文本身。在 *Prediction and Entropy of Printed English* 里，他让人一个字母一个字母地去猜一段文字。人猜得出来的语言，发起来就便宜，而这个实验量出了到底有多便宜。这就把一个活人放到了图 3.10 的最下面一行。

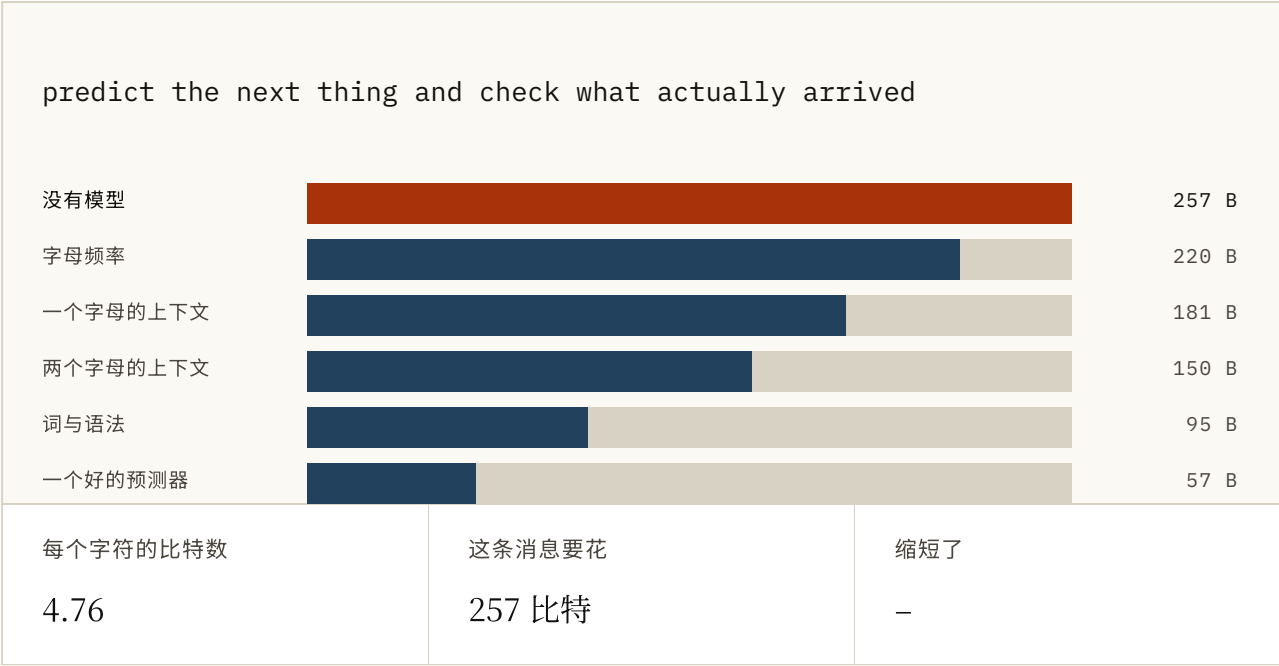


FIG. 3.10 把预测器从「没有模型」一档一档升到「一个好的预测器」，看同一个句子的价钱怎么往下掉。这里的每字符比特数是关于英文的公开估计值，不是这幅图自己算出来的。最下面一行大致就是 Shannon 1951 年那个实验里逐字母猜的人所在的位置，也是今天好的语言模型所在的位置。

所以，你能写出的最短消息的长度，度量的就是你预测得有多好。这让更好的预测器成了更好的压缩器。反过来读：把你的数据压得最狠的那个东西，就是对它理解得最多的那个。

Marcus Hutter 是一位在抽象层面研究完美学习者的理论家，他把这个读法当真了。Hutter 奖是一项长期悬赏，奖给能把一份维基百科快照压得更小的人。它依据的论证是：不知道文本的意思，你就没法把它再挤小多少。到今天为止的每一位获奖者，本质上都是一个语言模型。

2010 年，Jürgen Schmidhuber 又往前走了一步。Schmidhuber 在瑞士带着一个实验室，他是 LSTM 的共同发明人之一，那是一种记忆网络，很多年里一直是语音识别的主力。2018 年，他会与人合写这门课名字所出自的那篇论文。他 2010 年的论文是 *Formal theory of creativity, fun, and intrinsic motivation*。

他提出，应该奖励学习者取得压缩进展。所谓压缩进展，就是它发现自己现在能把数据压得比刚才更狠。于是「压得更好」本身变成了一种驱动力，一个跑去看新东西的理由。




FIG. 3.11 学习者可以去看的三样东西：静态噪声、它已认识的图案、它正在学的图案。挑一样，按「观看」。那根条是学习者能把目前看到的東西写得有多短，而每一步的奖励，就是它刚刚又短了多少。静态噪声从不会变短，已认识的图案本来就很短，所以这两样都不给钱。所有奖励都在中间那一样上。数字仅作参考。

同一个读法也说明了为什么那些偷渡客从来就不是可选项。背下来是贵的那条路。一张把发生过的一切都记下来的查找表，既庞大，又对任何新东西都没用。

便宜的那条路，也就是能让消息变短的那条，是把产生这些数据的规律找出来，然后只留下这条规律。规律就是那个偷渡客。

目前所见



表

1	0.00
2	0.31
3	0.59
4	0.81
5	0.96
6	1.02
7	0.99
8	0.87
9	0.67
10	0.41
11	0.12
12	-0.18

.....还有 12 个

存储: 24 个值

规则

规则: 两个数 (示意)

a 1.90 b -0.99

下一个 = a × 上一个 + b × 再上一个

存储: 2 个数

已见的值

24

表存储

24 个值

规则存储

2 个数

遇到新数据

还没有新数据

FIG. 3.12 把「数据量」往上拖，看那两个框。表把见过的每一个值都存下来，跟着数据一起长。规则是两个数，正是图 3.3 里那个预测器找到的那两个，而它一点都不长。然后按「新数据」，看这两样里哪一个还说得出来。

它在哪里就不够用了

有两个限制。

预测得好，不等于有用。一个系统可以非常擅长把一段记录接下去，却仍然给不了你任何可以据以行动的东西。说出接下来会发生什么，和说出「如果你做了别的事，接下来会发生什么」，是两个不同的问题。只有后一个撑得起一个决定。Li 那个网络身上带着一张棋盘，可它从头到尾被问到的，也只是哪些着法合法。




FIG. 3.13 在这段记录上拖动，挑一个时刻。按「接下来会怎样」，答案就是紧挨着的下一格，本来就摆在那儿。再按「如果我推它一下会怎样」：除非那个时刻正好有人推过，否则没有哪一格可读，答案只能从别的时刻借过来，也就是球大致在同一位置、而且确实有人推了的那些时刻，有时候一个都没有。这段记录仅作示意。

不感到意外，不等于是对的。一个只见过好天气的预测器，不会被好天气惊到。这一点完全没有告诉你它在暴风雨里会怎么样。

在你碰巧录下来的东西上误差很低，是一个比它听起来弱得多的论断，而大多数被拿出来当标题的数字，做的正是这个论断。我们换成球来看，不看天气。




FIG. 3.14 在模型训练时见过的那段速度范围里拖动「发射速度」，它落得离真实值很近，所以任何在这里做测试的人都会说它掌握了这条规律。继续往范围外面拖，看那道缺口张开。好天气就是这段范围，而它从来没见过暴风雨。

这两个限制都推翻不了这个论证。预测足以把结构从原始经验里拽出来，也是目前找到的最便宜的信号。从 Shannon 经 Elman 到 Othello-GPT 这条线，是一群人拿着一代比一代好的仪器，把这件事一次次证明出来。

这里的一切都假设了被预测的那个东西很小：一个球两个数，语言一次一个词。而一台摄像机一秒钟给你三十次、每次两百万个数字，其中几乎全是树叶。这就是树叶问题以完整尺寸登场的样子，而第 4 章正是从这里接下去。

希望这一章对你有帮助。下面有一个简短的小测验，如果你想检查一下这条链子在你这儿有没有扣住，可以做一做。如果我哪里写错了，或者你知道比我用的更好的来源，「关于」页面有一个更正板块，很欢迎你来找我。

试一试

1 一张球在飞行中的照片。有什么是你从它推不出来的？

- a. 球在哪里
- b. 球有多大
- c. 它往哪个方向走、走得有多快
- d. 它是什么颜色

答案 c. 它往哪个方向走、走得有多快. 方向和速度不在任何单独一帧里。它们存在于帧与帧之间的关系中，而这是预测器不得不自己造出来的那类东西。

2 为什么「预测下一个东西」比用标注数据训练便宜那么多？

- a. 模型更小
- b. 答案本来就在记录里，没有人需要写标注
- c. 它需要的计算时间更少
- d. 它收敛需要的步数更少

答案 b. 答案本来就在记录里，没有人需要写标注. 每一刻都是上一刻的答案。这把任何东西的任何记录都变成了训练集，也去掉了「得有人标注一百万个样本」这一步。

3 Jeffrey Elman 的网络只被训练去预测下一个词，而它的内部状态自己分成了名词、动词、有生命与无生命。为什么？

- a. 这些类别本来就在训练标注里
- b. 架构里每个类别有一个单元
- c. 一个词的类别正是它的下一个词所依赖的东西，所以这些类别是「少犯错」最省事的办法
- d. 它把语料背了下来

答案 c. 一个词的类别正是它的下一个词所依赖的东西，所以这些类别是「少犯错」最省事的办法. 没有任何东西提供过这些类别。预测奖励的是任何能让下一刻更不意外的东西，对词来说，那就是语法类别。

4 探针在一个只用合法黑白棋着法训练的网络里找到了棋盘状态。是什么让它从一件趣闻变成一个发现？

- a. 探针非常准
- b. 网络很大
- c. 改动那个内部棋盘，网络接下来走的棋也跟着变
- d. 棋盘可以画成一张图

答案 c. 改动那个内部棋盘，网络接下来走的棋也跟着变. 光是准，有可能只是数字里的巧合。对表征做干预、再看到行为跟着改变，才说明网络在用它。

5 在一个好的预测器下，一个你很有把握而且猜对了的符号，发送起来几乎不花钱。为什么？

- a. 它可以从消息里省掉
- b. 一个符号的代价由你给它的概率决定
- c. 常见符号被存在一张表里
- d. 接收方自己猜就行，不需要消息

答案 b. 一个符号的代价由你给它的概率决定. 香农把这个价格写精确了。概率高就意味着码长短，这也是为什么更好的预测器就是更好的压缩器。

6 从压缩的角度看，「把训练数据背下来」是怎么回事？

- a. 这是能用的最好策略
- b. 这是贵的那个选项：把一切都记下来的查找表既庞大又对新东西没用
- c. 它比任何规律压得都好
- d. 所有学习做的都是这件事

答案 b. 这是贵的那个选项：把一切都记下来的查找表既庞大又对新东西没用. 短消息来自「找出生成数据的规律，然后只留下它」。背，恰恰是压缩要惩罚的东西。

7 同一个循环，不同的目标：预测下一个像素、下一个词，或者下一个紧凑状态。这个选择改变了什么？

- a. 什么也没变，重要的是那个循环
- b. 只改变训练要多久
- c. 改变这个系统最后擅长什么，以及它的容量花在哪里
- d. 改变这套方法算不算自监督

答案 c. 改变这个系统最后擅长什么，以及它的容量花在哪里. 去预测每一个像素，容量大半会花在树叶上，因为那里才是大部分像素。挑目标是这里最要紧的设计决定。

8 一个模型在预测某段记录的下一帧时误差非常低。单凭这一点，什么是它没告诉你的？

- a. 它见过这段记录
- b. 如果你做了别的动作它会预测什么，以及它在录下来的范围之外会怎么样
- c. 误差是不是量对了
- d. 这段记录是不是够长

答案 b. 如果你做了别的动作它会预测什么，以及它在录下来的范围之外会怎么样. 对你碰巧录下来的东西不感到意外，是个比听起来弱得多的论断；而说出接下来会发生什么，也不等于说出在另一个动作下会发生什么。

FIG. 3.15 八道关于这个循环以及它产出什么的题。最后两道分开的是「一个好的预测器」和「一个有用的预测器」，也是我最希望你答对的两道。

参考资料

A Mathematical Theory of Communication SHANNON, 1948 ↗

一个符号的代价在这里变成了「你给它的概率」。预测与压缩是同一件事，一切都从这儿开始。

<https://people.math.harvard.edu/~ctm/home/text/others/shannon/entropy/entropy.pdf>

Prediction and Entropy of Printed English SHANNON, 1951 ↗

香农让人坐下来，一个字母一个字母地猜英文。图 3.10 最下面那一行大致就是他测出来的。

<https://doi.org/10.1002/j.1538-7305.1951.tb01366.x>

Finding Structure in Time ELMAN, 1990 ↗

训练一个小网络去预测下一个词，然后往里看：名词、动词、有生命与无生命，没有一样是被要求过的。

https://doi.org/10.1207/s15516709cog1402_1

Emergent World Representations LI ET AL., 2022 ↗

在 Othello-GPT 内部找到棋盘状态，并且能对它做因果干预。

<https://arxiv.org/abs/2210.13382>

Othello-GPT has a linear emergent world representation NANDA ET AL., 2023 ↗

把这个发现进一步锐化的后续工作。

<https://arxiv.org/abs/2309.00941>

Language Models are Unsupervised Multitask Learners RADFORD ET AL., 2019 ↗

把「预测下一个词」放大之后，长出了没有人训练过的能力。这是「目标选择才是那个设计决定」最有力的证据。

https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf

The Hutter Prize HUTTER, ONGOING ↗

一项压缩维基百科快照的现金悬赏，理由是：不建模文本的含义，你就压不动它。

<http://prize.hutter1.net/>

Representation Learning: A Review and New Perspectives

BENGIO, COURVILLE & VINCENT, 2013 ↗

这篇综述梳理了「一个好的学出来的表征是拿来干什么的」，写在预测彻底赢下这场争论之前。

<https://arxiv.org/abs/1206.5538>

Formal theory of creativity, fun, and intrinsic motivation SCHMIDHUBER, 2010 ↗

把压缩进展本身当作一种驱动力：它不只是衡量模型的尺子，也是跑去看点什么的理由。

<https://people.idsia.ch/~juergen/creativity.html>

FIG. 3.16 排序是给要在这上面接着做事的人用的，而不是为了历史完整性。