

04 什么是潜在空间？

作者 NILUSHANAN KULASINGHAM


阅读约 11 分钟 · 可交互

摄像机测量几万个数字，而这个决定只需要两三个。中间那道收窄口发生了什么，以及为什么那个窄点给它后面的一切定了上限。

本章的图都是可交互的。请到 worldmodels101.com/zh/chapters/latents 在线按一按、拖一拖。

站在门口往房间里看。你的眼睛每秒钟大概在接收一亿次测量。现在决定要不要往前走。为了这个决定，那一亿次里你几乎一次都用不上。

远处那面墙有多远？有没有能过去的口子，大概在哪儿？这就是两三个数字，而你的眼睛收集到的其余一切，对这个决定来说都是装饰。



这两个数解码出来的房间

这个空间本身。在里面任意拖动 墙有多远0.45 能过去的口子在哪儿0.62	
画面里的数字个数	描述里的数字个数
74,800	2

FIG. 4.1 先玩玩这个再往下读。在右边那个方块里随便拖。它里面的每一个点都解码成一个房间，而这个房间是从那两个数字算出来的，不是查出来的。留意一下：只要拖一点点，你会做的事就变了。画面是几万个数字，而产生它的那份描述只有两个。

这两三个数字有个名字。它们是这个场景的**潜在** (latent 的意思是隐藏的、不直接可见的：这些数字从来不会展示给你看，也没有任何东西给它们贴标签，但画面之所以长成那样，是因为它们) 描述。从这里往后，几乎每一篇论文里你都会碰到「潜在空间 (latent space)」这个说法。

在摄像机和决定之间，某个地方必须有一道收窄口，而从另一头出来的东西，就是系统其余部分能拿到的全部。这是支持潜在表示的理由，而同一个事实也是反对它的理由。

那道收窄口

这个架构就是在系统中间开一个窄口。一半把画面变成一串短短的数字，另一半拿着这串数字，试着把画面重建出来。把这两半一起训练，能成功的办法只有一个：这串短数字必须装下画面是由什么构成的。




FIG. 4.2 这就是那个窄口，上面装了一个旋钮。场景由六个数字生成，而这道口子只留下最前面的几个。把「允许通过的数字个数」从零往上拖，看底下那两行读数。放进去两个数，决定就已经定下来了。再往后的都是碎石和传感器噪点，它们是真实的，但和这件事无关。

这幅图动过手脚：决定所取决于的那两个因素，正好占着最前面两个位置。学出来的系统不会白拿到这个顺序。


2006 年，Geoffrey Hinton 与 Ruslan Salakhutdinov 在 *Reducing the Dimensionality of Data with Neural Networks* 里为这道收窄口做了论证。Hinton 在多伦多教书，在神经网络最不景气、大部分同行都已经转投别处的那些年里一直没放

弃。Salakhutdinov 是他的学生。他们把这篇论文投给了 *Science*，而不是某本机器学习期刊，你从这里就看得出他们想说服的是谁。

这两半各有名字，每篇论文都在用，我们先把它们记下来。把画面拿进来的那一半叫**编码器**，把画面重建出来的那一半叫**解码器**，中间那段窄的叫**瓶颈**。这两半合起来就是一个**自编码器**：它把自己的输入编码，再解码回来。

此后的一切，都是同一个论证换上了更好的装备。但瓶颈只制造压力，并不说出答案。许多同样短的数字串都能重建同一批画面，没有什么能让其中一个数字表示距离、另一个表示光照。要做到那一点，你得有一个偏置，来自架构、来自数据，或者来自任务。

2016 年，Google 在伦敦的实验室 DeepMind 的 Irina Higgins 与同事为这样一个偏置做了论证，论文是 *Early Visual Concept Learning with Unsupervised Deep Learning*。他们主张，好的表示是每个方向各自只表示一件事的表示：拧动一个数字，变的只有光照。



由两个数重新画出的房间




FIG. 4.3 这就是 Higgins 的检验，外加下一段要讲的那个旋钮。先把「压力 (beta)」放低，在方块里拖那个点：墙和光会一起变，所以两根轴都叫不出名字。再把压力调高，重新拖一次。一个方向挪墙，另一个方向改光，而房间变糊了。这里的一切仅作示意。

一年后他们的 *beta*-VAE 就是这个形状的自编码器，外加一个旋钮。这个旋钮（名字里的 beta）把瓶颈上的压力调大，超过 1 以后，坐标轴就开始对上一些叫得出名字的东西，比如一张脸转向哪边、一个形状有多大。同一篇论文也给出了代价，就是你刚才看

到的：压得越狠，画面越糊。

到 2018 年，这道收窄口已经装进了一个能跑的智能体里。那一年 David Ha 与 Jürgen Schmidhuber 发表了 *World Models*，那是一个通过赛车游戏的模型来学会这个游戏的智能体。每一帧都被压成三十二个数字，而负责预测和做选择的部件从来没见过一个像素。

同一年，Danijar Hafner 与同事做出了 PlaNet，作者里也有 Ha。论文是 *Learning Latent Dynamics for Planning from Pixels*。它用同样的方式压缩原始像素，然后就在压出来的东西里做规划，从头到尾没有为了做决定而重建过任何一帧。到了要做决定的时候，它手上只有那串短数字，这是两种设计里更大胆的一种。



FIG. 4.4 赛车游戏里的一帧，以及它被压成的那三十二个数字。按一个改动，看哪些数字动了，以及方向盘会不会跟着动。挪弯道或者挪车，就有好几个数字会动。把砂石重新洗一遍，或者把云换个形状，画面明明白白变了，却一个数字都没动，所以收窄口后面的任何东西都不会听说这件事。这些数字仅作参考。

接着在 2019 年，Francesco Locatello 与同事把 Higgins 打开的这个问题关上了。把隐藏的因素一根轴一个地拆开，这件事叫解耦（disentanglement）。他们证明：没有标签、也没有内建偏置的话，这件事做不到。对任何一道坐标轴有含义的收窄口，总有另一道口子能同样好地画出一样的画面，而它的坐标轴什么含义都没有。

他们随后训练了几千个模型，而你拿到什么样的坐标轴，基本上取决于随机种子。论文是 *Challenging Common Assumptions in the Unsupervised Learning of Disentangled Representations*，拿了那一年 ICML 会议的最佳论文奖。很多讲潜在空间的文字还没跟上它。





FIG. 4.5 按几次「重新训练」。每按一次就是一个新的随机种子，每一次都会在同一批房间上给你一对不一样的坐标轴。读一读底下那两行：画面每次都一模一样地回来，而第一根轴表示什么则每次都不一样。这就是 Locatello 的结果，也是图 4.2 为什么非得动手脚。数字仅作参考。

看看谁没受影响。Ha 与 Schmidhuber 的智能体从来不需要那三十二个数字表示什么人能叫得出名字的东西，PlaNet 的规划器也不需要。这道收窄口照样用了下去，因为建在它上面的那些智能体，一直只要求它留住下一步所取决于的东西。


它是一个地方，不是一份清单

那些数字是坐标。在一个被训练塑造得好的潜在空间里，它们指定的那个点会有有用的邻居、方向和距离。这一点没有任何保证：一个普通自编码器完全可能学出一张扭曲的查找表。


一旦它被塑造好，你就可以在那里做一些在像素上根本讲不通的事。你可以问附近有什么，可以朝某个方向走、看着世界沿着某一种方式平滑地变化，也可以拿两个房间，然后站到它们中间。最后这一件就是下面这幅图。




一个房间



把两张画面平均一下



另一个房间



把两个数字平均一下，再解码

混出来的画面是个房间吗？

不是。它是两个房间同时叠在一起，而那不是你走进去的東西。

解码出来的那个是房间吗？

是，滑块上每一处都是。那个空间里的每一个点都解码成一个房间。

FIG. 4.6 两行都是这个刻意构造出来的解码器的真实输出。拖动「在两者之间走了多远」这个滑块，看中间那两格。把两张画面平均，你会同时得到两个淡淡叠在一起的房间；把两个坐标平均再解

码，结果始终落在解码器学会画的那些房间之中。真实的潜在空间只有在训练让样本之间的区域也有了意义之后，才会这样。

两张画面的中点是一个幽灵，而两份描述的中点是一个房间。这件事要紧，是因为预测、规划和搜索都要走到你没去过的地方，如果每一步落下去的都是没有意义的东西，那它们一个都跑不起来。

这也是为什么变分自编码器（也就是 beta-VAE 所依托的那个 VAE）里的噪声是故意加的。它由 Diederik Kingma 与 Max Welling 在 2013 年的 *Auto-Encoding Variational Bayes* 里造出来，Kingma 当时是 Welling 的博士生。它把每张画面的落点弄模糊，好让相邻的点解码出相似的东西。这就是让这个空间能被走通的原因，也是五年后 Ha 与 Schmidhuber 拿它当智能体眼睛的原因。

什么样的才算好

小本身不是目标。一个数字非常小，也非常没用。你想要的是：要紧的东西容易拿到，不要紧的东西已经没了。2013 年，Yoshua Bengio、Aaron Courville 与 Pascal Vincent 在一篇叫 *Representation Learning: A Review and New Perspectives* 的综述里把这一点写了下来。

这三个人当时是蒙特利尔的同事。Bengio 在和 Hinton 同样不景气的那些年里一直撑着一个神经网络实验室，后来与 Hinton、Yann LeCun 共同获得图灵奖。关于「学出来的表示到底是干什么用的」，这篇综述到今天仍然是最好的一份陈述。我们就从里面拿三个检验，大致按它们有多常出问题来排。

它有没有留住未来所取决于的东西？拿两种会导向不同结果、却落在同一个点上的情形：后面的任何东西都没法把它们分开。这种失败最不显眼，因为它发生的时候，重建看上去还挺好。Ha 与 Schmidhuber 的那三十二个数字只被训练去把画面重画出来，作者自己也提示过这个风险。




FIG. 4.7 两条走廊，唯一的差别是球往哪边滚。挨个按一下「按下 A」和「按下 B」，看它们落在方块里的什么位置：同一个点，因为一道按「能不能把这一帧重画出来」打分的收窄口，在那几个像素的运动里没找到什么值得留下的东西。再看那个重画，它没什么问题，再看底下那个问题，它答不上来。把评分依据切到「预测下一帧」，两者就落到不同的地方了。仅作示意。

相邻的点意味着相邻的东西吗？一个走一小步就可能落到任何地方的空间，只是一张查找表。平滑，才是让你能有目的地在里面移动的东西，而 VAE 的噪声就是为它造的。就像你在图 4.6 里看到的，它也是让你能站在两个房间中间的东西。

它容易往前推吗？一份描述可以完全忠实，同时又是个在时间上往前推的噩梦。当初要压缩，图的就是拿到一个能便宜地往前滚动展开的东西。

这道收窄口的代价

重建画面是一个替身，而替身会跑偏。这个检验问的是：这串短数字能不能把摄像机看到的東西重画出来。而你想知道的是：它有没有留住这个决定所取决于的东西。

占像素最多的那些东西，通常不是要紧的那些。一份按「能不能重建像素」打分的描述，会把自己花在纹理和天气上，然后丢掉那个你需要避开的、又小又快的东西。图 4.2 动过手脚，正是为了盖住这一点，我们现在把手脚拆掉。




FIG. 4.8 和图 4.2 同一种收窄口，只不过这一次，位置归谁由「谁占的像素多」决定，而这正是重绘得分奖励的东西。把「放行的数字个数」往上拖，看东西通过的顺序：墙、天空、光线、碎石，最后才轮到那个骑车的人。再读底下那两行。早在你真正需要的那一样东西出现之前，重绘得分就已经很高了。仅作参考。

第二个代价更隐蔽，我觉得也更严重。这道口子丢掉的任何东西，从那一刻起就永远找不回来了。瓶颈之后的一切都只靠这串短数字工作，别的什么都没有。

这个选择做得很早，做它的那个部件完全不知道接下来是什么任务，而它给它后面的一切定了上限。

这也是为什么此后的争论一直围着管子的中段打转。PlaNet 把这道收窄口和前向模型放在一起训练，而 LeCun 的 JEPA 路线（第 7 章）问的是：到底还要不要重建像素。

希望这一章对你有帮助。下面有一个小测验，想确认这些想法有没有记住，可以做一下。如果我哪里写错了，或者你知道比我用的更好的来源，「关于」页面有一个勘误区，我很乐意收到你的来信。

试一试

1 摄像机每一帧交给你几万个数字，而决定要不要往前走只需要两三个。瓶颈是干什么用的？

- a. 把模型做小，让它跑得更快
- b. 逼着所有东西挤过一个窄口，于是活下来的正是画面真正由什么构成的
- c. 去掉摄像机的噪点
- d. 把文件在硬盘上压小

答案 b. 逼着所有东西挤过一个窄口，于是活下来的正是画面真正由什么构成的。速度和体积都是副作用。之所以要挤，是因为想挤过去就必须把「一开始生成这张画面的那些东西」还原出来。

2 没有人手工挑选那串短数字里该装什么。为什么它最后还是装了对的东西？

- a. 架构里每个概念有一个单元
- b. 如果这些画面本来就由少数几样东西的变化产生，那么还原这几样就是重建它们最省事的办法
- c. 训练标注里写了
- d. 解码器被告知了答案

答案 b. 如果这些画面本来就由少数几样东西的变化产生，那么还原这几样就是重建它们最省事的办法。这个排序是被压力逼出来的，不是设计出来的。这既是它吸引人的地方，也是为什么这个排序只是「大致」是你想要的那个。

3 把两个不同房间的两张画面平均一下。你会得到什么？

- a. 一个介于两者中间的房间
- b. 两个房间同时淡淡地叠在一起，那不是房间
- c. 第一个房间
- d. 一张空白画面

答案 b. 两个房间同时淡淡地叠在一起，那不是房间。这就是像素空间里做混合得到的结果。它也是最能说明「为什么你想要一个『两个有效点之间也有效』的空间」的理由。

4 改成把两份简短描述平均一下，再解码。你会得到什么？

- a. 同一个幽灵
- b. 一个房间，因为那个空间里的每个点都解码成一个房间
- c. 什么都没有，这些数字加不起来
- d. 一张两个房间并排的画面

答案 b. 一个房间，因为那个空间里的每个点都解码成一个房间。预测、规划和搜索都要走到没去过的地方。只有当中间那些位置是有意义的，这件事才成立。

5 变分自编码器里的噪声，为什么不只是个麻烦？

- a. 它让训练更快
- b. 它把训练数据藏起来
- c. 把每张画面的落点弄模糊，会逼着相邻的点解码出相似的东西
- d. 它减少了参数量

答案 c. 把每张画面的落点弄模糊，会逼着相邻的点解码出相似的东西. 平滑是让这个空间能被走通的那个性质。没有它，你手上就是一张多绕了几道弯的查找表。

6 以下哪一条**不是**「一份好的紧凑描述」的标准？

- a. 它留住了未来所取决于的东西
- b. 相邻的点意味着相邻的东西
- c. 它尽可能地小
- d. 它容易在时间上往前推

答案 c. 它尽可能地小. 一个数字非常小，也非常没用。小是「留住了对的东西」的结果，从来不是目标本身。

7 一份描述是按「它能多好地重建摄像机画面」来打分的。这会出什么问题？

- a. 不会出问题，这正是对的检验
- b. 它会把自己花在占像素最多的东西上，而那通常不是决定所取决于的东西
- c. 它会小到没法用
- d. 它会变得不可导

答案 b. 它会把自己花在占像素最多的东西上，而那通常不是决定所取决于的东西. 重建只是个替身。纹理和天气占了大部分像素；那个你需要避开的、又小又快的东西并不占。

8 为什么「瓶颈有多宽」是一个放置重要决定的尴尬位置？

- a. 它很难调
- b. 它后面的一切都只靠那串短数字，所以被丢掉的就没了，而丢它的时候还没人知道任务是什么
- c. 它占太多内存
- d. 它必须在训练前定好

答案 b. 它后面的一切都只靠那串短数字，所以被丢掉的就没了，而丢它的时候还没人知道任务是什么. 这个损失在下游补不回来。一个完全不知道接下来是什么任务的部件，给它后面的一切定了上限。

FIG. 4.9 八道关于这道收窄口和它产生的那个空间的题。最后两道讲的是那种容易点头同意、却很难一直记着的东西。

到这里为止的一切都是一次一个瞬间。一张画面进去，一份简短描述出来，还什么都没动过。

参考资料

Challenging Common Assumptions in the Unsupervised Learning of Disentangled Representations

LOCATELLO ET AL., 2019 ↗

证明一个重要边界：没有归纳偏置，纯无监督的解耦在一般情况下不可识别。瓶颈会施加压力，却不会自动给坐标轴命名。

<https://arxiv.org/abs/1811.12359>

Auto-Encoding Variational Bayes KINGMA & WELLING, 2013 ↗

变分自编码器。它加进去的噪声，正是这个空间最后能被走通、而不是变成一堆互不相干的地址的原因。

<https://arxiv.org/abs/1312.6114>

Reducing the Dimensionality of Data with Neural Networks

HINTON & SALAKHUTDINOV, 2006 ↗

在有现代机器撑腰之前的瓶颈论证。需付费。

<https://doi.org/10.1126/science.1127647>

World Models HA & SCHMIDHUBER, 2018 ↗

编码器、潜在动力学、紧凑控制器，还包括把策略完全放在模型生成的环境里训练、再搬回真实环境的实验。

<https://arxiv.org/abs/1803.10122>

Learning Latent Dynamics for Planning from Pixels (PlaNet)

HAFNER ET AL., 2018 ↗

从图像里学出随机潜在动力学，然后在决策时对它做搜索。图 2.4 的真实版本。

<https://arxiv.org/abs/1811.04551>

Neural Discrete Representation Learning (VQ-VAE) VAN DEN OORD ET AL., 2017 ↗

当那份简短描述被强制变成少数几个离散符号、而不是连续数字时，会发生什么。

<https://arxiv.org/abs/1711.00937>

beta-VAE HIGGINS ET AL., 2017 ↗

把瓶颈上的压力调大，坐标轴就开始对上一些你叫得出名字的东西。这篇也很好地展示了那样做的代价。

<https://openreview.net/forum?id=Sy2fzU9gl>

Early Visual Concept Learning with Unsupervised Deep Learning

HIGGINS ET AL., 2016 ↗

「一个好的表征，是它的各个方向都有含义」这个主张，写在这个领域还不拥挤的时候。

<https://arxiv.org/abs/1606.05579>

Representation Learning: A Review and New Perspectives

BENGIO, COURVILLE & VINCENT, 2013 ↗

这篇综述梳理了「一个好的学出来的表征是拿来干什么的」，写在预测彻底赢下这场争论之前。

<https://arxiv.org/abs/1206.5538>

FIG. 4.10 我把它排了个序，是给要在这上面接着做事的人用的，而不是为了历史完整性。