

06 在梦里学习

作者 NILUSHANAN KULASINGHAM

阅读约 12 分钟 · 可交互

如果练习发生在模型里面，一个月的机器人时间就变成一天。这笔汇率真正的代价是什么，以及为什么「智能体在利用自己的梦」的解法是故意把梦弄差。

一条机械臂学会把东西拿起来之前，会先把它掉在地上几十万次。

这里面每一次尝试都要付出真实的代价。挂钟上的秒数。关节的磨损。旁边还得有个人，在它把箱子撞翻的时候把场景摆回去。按一秒一次算，几十万次就是一个月里什么的都不干。

所以让这整套做法值得折腾的，是下面这笔交易：拿这个月里的一部分去收集经验，用它拟合一个模型，然后让这东西在模型里面练。



FIG. 6.1 固定更新步数，再拖动它们来自哪里。接触世界往往是稀缺预算；模型计算也仍然是一份预算。这本账先把真实与想象的转移同样计数，本章接下来会撤掉这个方便的假设。

每一步真实对应二十步想象，接触时间这本账会把一个月变成大约一天半。这就是卖点。它只有在想象出来的转移仍然有用到足以计数时才成立。

那个循环

四步，转着圈。

在世界里行动一阵子，把发生的事留下来。用它拟合一个模型。在那个模型里训练策略（真正挑选动作的那一部分，也就是这里被训练的东西，而不是模型）。这些步骤花的是算力，不是机器人接触。然后把策略带回世界里去，它在那里能收集到比以前更好的经验，而这让下一个模型更好。

「转着圈」这件事在摘要里总是被跳过。一个拟合在「未经训练的智能体乱扑腾」之上的模型，只在未经训练的智能体会去的地方管用。它之所以变好，是因为智能体变好了，反过来也一样。

注意第二圈修好了第一圈修不了的什么。第一个模型是拟合在「一个没用的策略碰巧撞上的东西」上的，所以它对地板知道得很多，对目标附近会发生什么一无所知。改进后的策略会去新的地方，那产生了关于那些地方的数据，而那恰恰是模型原本缺的那份数据。

这也是为什么图里那个比例不能白白往上调。想象出来的步数只有在模型还能诚实地供得上时才值钱，而模型只在它去过的地方才做得到这一点。

想象经验不是同一种货币

训练日志可以把一次真实转移和一次模型生成的转移记成两行，学习者却不能这样算。合成经验会继承模型的盲点，而推演离真实状态越远，这份折扣就累积得越重。




FIG. 6.2 一本刻意简化的账。提高想象数据占比或每步模型误差：名义批次始终是 100 次转移，有效经验却往下掉。折扣不是估计器，只是把「生成数据和观测数据可以互换」这个隐藏假设露出来。

MBPO 最强的结果来自很短的模型推演，而且每段都从真实回放数据里的状态出发。短推演牺牲一些数量，也让生成状态留在观测数据附近。只有当每一步都按它离证据多远来定价时，多想象才有用。

做梦的人在里面找到了什么

现在讲比卖点更有意思的那部分。

一个在模型里面训练出来的策略，是被那个模型打分的。不是被世界。它在整个训练过程中完全接触不到世界。所以它没有办法把「一个真正好的动作」和「一个只是在批改者眼里好看的动作」分开。

于是它会去找后面那一种。不是因为出了什么岔子，而是因为那些是里面最便宜的分数，而它是个非常彻底的学生。

Ha 与 Schmidhuber 就直接撞上了这件事。他们那个完全在一场学出来的游戏梦境里训练的智能体，发现了一种移动方式，能让梦里干脆不再产生火球。在模型里面，这是个出色的策略。在真正的游戏里，它一文不值，因为真正的游戏并没有同意停火。

值得把它和规划器版本的同一个问题分开。一个在决策时做搜索的规划器可以被抓住、被否决，方案就摆在那儿可以查。而一个在梦里训练出来的策略，走出来的时候已经把那个漏洞焊进自己的权重里了。

把梦弄得比世界还难

解决办法不是一个更好的模型。是一个故意更差的。

如果策略在利用某个怪癖，那就让这个怪癖变得不可靠。在训练时把模型预测里的不确定性调高 (这个旋钮通常叫 *温度*：低表示模型只把它最可能的那一个猜测交给你，高表示它采样得更散)，于是同一个动作不再总是产生同一个方便的结果。一个只有在模型碰巧那样掷一次时才管用的把戏，就不再值得往上搭房子了。




FIG. 6.3 这两条曲线复现报告中的形状，不对应某个具体系统。底下的发现是真的。智能体在梦里的得分远高于游戏里，而提高不确定性缩小了差距。有用的设置是一个峰，不是一个方向。

那个滑块的两端都会失败，而且失败得不一样。一个笃定的梦会被利用。一个噪声太大的梦里已经没有任务可学了。中间那个设置不是两种好处之间的折中，而是那条「两种失败都还没占上风」的窄带。

这是件挺奇怪的事。你花了那么大力气把模型做准，然后又故意把它弄糊，好让下游的任何东西都不能太用力地靠在这份准确上。

这买到了什么，没买到什么

在模型里学习，是「造一个模型」这件事最大的实际理由。那些从想象出来的推演里学习行为的系统，能在惊人广的一批任务上达到胜任水平，而用掉的环境交互只是直接学习所需的一小部分。在一台真实机器人上，那一小部分就是「做得到」和「做不到」的差别。

三件它没买到的事。

它没有消除对真实经验的需要。它改变的是汇率。总得有东西出去弄清楚实际会发生什么，而模型也只在那件事被做过的地方才值得信任。

它没有让打分变诚实。策略自始至终都由模型批改，而这一章里的每一道防护，都是让这份批改更难被钻空子，而不是让它变正确。

它没有让迁移变免费。一个在梦里管用的策略，是一个关于世界的假设；在有人把它拿到外面跑之前，它一直只是个假设。

试一试

1 在模型里面训练，改变的是哪种资源的汇率？

- a. 所需的参数量
- b. 内存，它变便宜了
- c. 和世界的接触；其中一部分改由模型计算来付
- d. 模型精度，它免费变好了

答案 c. 和世界的接触；其中一部分改由模型计算来付. 学习者仍然需要它那份经验。变的是这些步从哪儿来，以及由哪份预算付账。

2 一个仪表盘把 90 次想象转移和 10 次真实转移记成 100 个训练样本。这本账漏了什么？

- a. 要按模型误差以及离真实状态多远，给可靠性打折
- b. 策略的参数量
- c. 两种来源必须使用同样的批量大小
- d. 想象转移没法保存

答案 a. 要按模型误差以及离真实状态多远，给可靠性打折. 对日志来说每一行都一样，对学习者不是。合成经验继承模型的盲点，而且这笔债会沿推演累积。

3 循环的第二圈修好了第一圈修不了的什么？

- a. 它去掉了解码器的需要
- b. 它缩短了推演
- c. 它把模型变小了
- d. 更好的策略会去新的地方，产生的恰好就是第一个模型缺的那份数据

答案 d. 更好的策略会去新的地方，产生的恰好就是第一个模型缺的那份数据. 拟合在「未训练的智能体乱扑腾」之上的模型，只在那种智能体会去的地方管用。模型变好是因为策略变好，反过来也一样。

4 一个在模型里面训练的策略，是被什么打分的？

- a. 世界
- b. 模型，而且整个训练过程中只有模型
- c. 来自真实环境的一份留出测试集
- d. 一位人类评估者

答案 b. 模型，而且整个训练过程中只有模型. 它在训练期间接触不到世界，所以没法把「真正好的动作」和「只是在批改者眼里好看的动作」分开。

5 Ha 与 Schmidhuber 的智能体找到了一种移动方式，让它的梦不再产生火球。这是哪一类失败？

- a. 探索不足
- b. 训练代码里的 bug
- c. 策略在最大化模型交给它的分数，而这正是它被要求做的事
- d. 模型太小了

答案 c. 策略在最大化模型交给它的分数，而这正是它被要求做的事. 什么岔子都没出。那些是模型里面最便宜的分数，而这个策略很彻底。

6 这和「规划器在决策时利用模型」有什么不同？

- a. 方案可以被查看和否决；而训练出来的策略走出来时，漏洞已经在它的权重里了
- b. 规划器不受模型误差影响
- c. 策略事后更容易纠正
- d. 是同一个问题换了个名字

答案 a. 方案可以被查看和否决；而训练出来的策略走出来时，漏洞已经在它的权重里了. 正是这个差别让梦里那个版本更难被抓住。没有一份摆在那儿可以看的方案。

7 为什么要给一个你费劲做准的模型故意加上不确定性？

- a. 为了减少内存占用
- b. 为了把模型做小
- c. 为了加快训练
- d. 好让一个只有在模型碰巧那样掷一次时才管用的把戏，不再值得往上搭房子

答案 d. 好让一个只有在模型碰巧那样掷一次时才管用的把戏，不再值得往上搭房子. 如果策略在利用某个怪癖，解法是让这个怪癖变得不可靠，而不是把模型做得更好。

8 不确定性旋钮的两端都会失败。怎么个失败法？

- a. 两端都让训练不稳
- b. 笃定的梦会被利用；噪声太大的梦里已经没有任务可学了
- c. 低端慢，高端快
- d. 只有高端会失败

答案 b. 笃定的梦会被利用；噪声太大的梦里已经没有任务可学了. 有用的设置是一个峰而不是一个方向：那条「两种失败都还没占上风」的窄带。

FIG. 6.4 八道关于这个循环以及住在里面的东西的题。最后三道分开的是「卖点」和「你实际拿到的东西」。

到这里为止的一切，都默认了模型应该预测东西看起来是什么样：帧、像素、场景，也就是你人在那儿会看到的東西。

多谢阅读。第 7 章讲的是这样一个主张：这件事从一开始就错了；以及如果你干脆拒绝预测外观，你会换来什么。

参考资料

World Models HA & SCHMIDHUBER, 2018 ↗

编码器、潜在动力学、紧凑控制器，还包括把策略完全放在模型生成的环境里训练、再搬回真实环境的实验。

<https://arxiv.org/abs/1803.10122>

Dream to Control (Dreamer) HAFNER ET AL., 2019 ↗

在想象出来的潜在轨迹上训练 actor 和 critic，于是动手的那一刻不必再跑昂贵的搜索。

<https://arxiv.org/abs/1912.01603>

Mastering Atari with Discrete World Models (DreamerV2) HAFNER ET AL., 2020 ↗

同一个循环，做到了它开始打败那些直接从环境里学的智能体的规模。

<https://arxiv.org/abs/2010.02193>

Mastering diverse control tasks through world models (DreamerV3)

HAFNER ET AL., NATURE 2025 ↗

同一个算法、同一套超参数，跑了 150 多个任务。这是想象这一支目前最强的证据。

<https://www.nature.com/articles/s41586-025-08744-2>

Dyna: an Integrated Architecture for Learning, Planning and Reacting

SUTTON, 1991 ↗

把规划定义成在学出来的模型上做计算，以及那个把它和真实经验交织起来的循环。

<https://mlanthology.org/icml/1990/sutton1990icml-integrated/>

When to Trust Your Model: Model-Based Policy Optimisation

JANNER ET AL., 2019 ↗

从真实状态出发的短推演，直接回应累积误差和模型利用。标题就是这一章的问题。

<https://arxiv.org/abs/1906.08253>

Domain Randomization for Transferring Deep Neural Networks

TOBIN ET AL., 2017 ↗

同一个想法从机器人学那边过来：让模拟器的变化比现实还大，于是没有任何东西能依赖它的某一个版本。

<https://arxiv.org/abs/1703.06907>

Solving Rubik's Cube with a Robot Hand OPENAI ET AL., 2019 ↗

把随机化推到足以把策略从模拟搬到真实硬件上，以及对这件事代价的一份诚实交代。

<https://arxiv.org/abs/1910.07113>

FIG. 6.5 排序是给要在这上面接着做事的人用的，而不是为了历史完整性。