

07 什么是 JEPA？为什么不预测像素？

作者 NILUSHANAN KULASINGHAM

阅读约 12 分钟 · 可交互

当确定性像素预测器遇上开放的未来，最优解可能是一张不可能发生的画面。Yann LeCun 对生成式做法的那套指控、采样修好什么、嵌入避开什么，以及两者各自欠下的账。

本章的图都是可交互的。请到 worldmodels101.com/zh/chapters/jepa 在线按一按、拖一拖。

如果你在网上追过关于世界模型的争论，那多半撞见过一句口号：别再预测像素了。这句话出自 Yann LeCun。他当时是 Meta 的首席 AI 科学家，也是图灵奖得主，还是把卷积网络真正做成的人之一，也就是那种专门用来读图像的网络。


2022 年，他发表了 *A Path Towards Autonomous Machine Intelligence*。这是一篇立场论文，意思是它给出的是「机器应该怎么学」的主张，而不是一个结果。文章里有一条指控，冲着当时主导学习式世界模型的那个条件反射去：拿不准的时候，就去预测下一张画面。

他那条比较小的指控，从一台对着马路的摄像机开始。问它下一秒看起来是什么样：画面边缘的一片叶子会动，而它往哪边动是没法知道的。这同时也是所有信息里最没用的一条，因为你对这条路可能做的任何事，都不取决于它。可一个被要求预测画面的模型，还是得把那片叶子预测出来。


叶子是由像素构成的，而像素正是模型被打分的東西。把这件事乘以每一片叶子、每一道涟漪、每一次光在湿沥青上的闪动。大部分容量就这么花在了那些既难预测、又不要紧的东西上。这就是叶子问题，两条指控里比较小的那条。



模型预测的画面



下一秒实际的画面




误差落在哪里

每格按平方误差着色

司机在意的像素

前车、路缘



占误差的 10%

占画面的 15%

没有任何决定依赖的像素

树叶、水洼、光影



占误差的 90%

占画面的 30%

大部分误差，也就是对权重的大部分推力，都落在没有任何决定依赖的像素上。

色调、误差和份额均为示意

第几秒

落在前车和路缘上的误差份额

落在树叶和水上的份额

1	10%	90%
---	-----	-----


FIG. 7.1 一个路面场景，按像素损失打分的方式来打分。按一下「下一秒」，看误差落在哪里：前车按模型预期的样子移动，而树叶和水洼的闪动谁都预料不到。现在把「画面里的树叶和水」那个滑块往上拖，读右边那张账单。误差里落在司机真正在意的东西上的那一份一直在缩小，而那些像素每一个拉扯权重的力气都一样大。数字仅作参考。

JEPA 是 Meta 出的一个模型家族。它不预测像素，而是预测「它看不见的那部分」的一份描述。在接下来的所有内容里，嵌入指的就是一小串代表一张画面的数字。


两个未来的平均，哪一个都不是

更大的那条指控是一辆车正开到一个路口。它会左转，或者右转。你不知道是哪一个，而且再怎么盯着当前这一帧看也看不出来。

现在我们来问一个确定性模型，也就是每次只给一个答案的模型，让它预测一张下一帧。用像素平方误差给它打分，也就是把每个像素上的差距平方之后加起来。数学上最好的答案，是两次转向的条件平均，也就是把左转和右转这两个未来按各自的概率混在一起，而不是其中任何一个。



一种可能的未来 (50%)



可能最好的像素预测




FIG. 7.2 中间那一格就是那两个未来按各自概率画出来的结果，而平方误差奖励的正是这个平均值。把概率拖到任意一端，你应该会看到最优解落到某一次转向上；让它停在中间，最好的预测就变成一张不可能发生的画面。

看一下中间那一格。它的得分比两个真实未来都好。一个笃定预测左转的模型有一半时间会挨罚；而中间那个幽灵是一直挨一点点罚，在平方误差下，「一直挨一点点」赢了。

所以这个训练信号要的是平均值，而不是一个说得通的未来。当未来还没定下来时，平均值就是一团从不发生的糊影。

用求平均的像素损失训练出来的确定性预测器，会恰好在有意思的事快要发生时变糊。现代生成器靠抽样而不是瞄准平均值，绕开了这个失败。

这个幽灵的答案，五年前就有了

不过这里有个麻烦。像素这一派早在 2017 年就把幽灵问题处理掉了，比那篇立场论文早五年。SV2P 是 *Stochastic Variational Video Prediction* 的缩写，是 Mohammad Babaeizadeh 和同事那一年的视频模型，Emily Denton 与 Rob Fergus 也造了一个类似的。两者都学出一整片未来，再从中随机抽一个出来。

诀窍是一个隐变量，也就是几个数字，用来代表画面本身说不清的那部分，比如车会往哪边转。先抽这个变量，再画出与它相配的那一帧。即使模型完全不知道会往哪边转，每一次抽到的结果都可以是清晰的。




FIG. 7.3 从平均值切换到同样这两个未来的采样，中间那一帧就消失了。多按几次「重新采样」。不确定性以「每次抽到的都不一样」的形式保留了下来。模型仍然没说的是世界最终会选中哪一次，所以规划器还得给整片分布里的风险定价。


这一下把模糊这条反对意见解决了，但没有解决其余的论证。

采样修好的是输出的形式。它不会让无用的纹理变便宜，不会让罕见的未来被估准，也不会告诉决策者哪个可能的未来最要紧。随机生成保留了像素这个目标，而嵌入预测换掉了它。


改成预测那份描述

LeCun 的提议是别再预测画面。把你能看到的東西编码成一份紧凑描述 (也就是嵌入: 一小串数字, 用来代表一个更大的东西)。相似的东西会在这串数字里落到彼此附近。你要预测的那部分, 也照样编码成一份。

然后训练模型从第一份描述去预测第二份。整个过程里没有任何东西被解码回像素。I-JEPA 是最简单的例子: 一个 2023 年的图像模型, 来自 Mahmoud Assran 和他在 Meta、LeCun 组里的同事。把图片挡住一块, 去预测那块缺失部分的嵌入。目标一换, 什么才算「预测得差」也就跟着换了。



实际发生的



模型说的


像素误差

70



描述距离

4




两把尺子都仅为示意		
改动	像素误差	描述距离
叶子	70	4

FIG. 7.4 两帧路面画面，之间只差一处改动。挑一个改动往上拖，然后读那两把尺子。把每一片叶子都挪那个地方，或者把整帧画面横着平移，像素这把尺子会为一件跟任何决定都无关的事开出天价。而把前面那辆车挪进你的车道，几百个像素就改变了你会怎么做，像素这把尺子却几乎察觉不到。两把尺子都仅作示意。



V-JEPA 2 是 Meta AI 2025 年的模型，对视频做同样的事。它先在普通视频上训练，不带动作。之后再用机器人的动作训练一遍，用于控制。

由此有两件事跟着发生。叶子的问题没了，因为那份描述从来就没有义务记下叶子往哪边动。如果某个细节没能挺过编码这一关，后面就没有任何东西会因为它被打分。



幽灵也变小了，因为你不再是在平均画面。汽车左转的描述和右转的描述可以共享大部分条目。仍然没定下来的那部分，要么被明确留下，要么当作无关信息丢掉。有一点要提醒：一个描述空间照样可以同时装下两个不同的答案，换一种表征并不会消灭不确定性。



向左转



向右转



平均图像，它从不会发生

列表仅为示意

两个未来共有的条目
8 个里的 7 个

仍未定的条目
8 个里的 1 个，明确保留

作为无关项丢掉
无

FIG. 7.5 还是图 7.2 那个路口，这次是描述出来的，不是画出来的。每个未来都是一小串数字，其中大部分条目是一致的：路面、车速、路口有一辆车。把开关留在「像素」上，预测出来的又是那个幽灵。把它拨到「描述」，看看会发生什么：共享的那些条目直接被预测出来，而唯一不同的那个条目，就是两个未来仅剩的分歧所在。这几串数字仅作参考。

这就是 JEPA 这一家族，而这个名字说的就是它的架构：联合嵌入，因为两边都被嵌入；预测式，因为训练信号是一个嵌入去预测另一个嵌入。

为此要付的账

预测像素有一个大优点，而 JEPA 这一边把它放弃了。目标是固定的，模型没法让下一帧变得更好预测。改成预测嵌入，这一点就不成立了。

现在目标由编码器产生，也就是那个把画面变成描述的网络，而这个网络自己也在被训练。它可以什么都不学就拿满分：让所有描述都变成同一份就行。这样预测就永远正确，损失掉到零，而这些描述关于任何事情都什么也没说。这种失败叫做坍缩。



FIG. 7.6 一个很小的编码器，进去两个数、出来两个数，在四对样本上用梯度下降训练。先不打开防护，把步数往前拖：你应该会看到损失和「表征还说得出多少东西」一起掉到零。现在把防护打开，再拖一遍。损失再也接近不了零，而这一次运行才是你想要的。

这些方法里绝大部分的难处都在于防住这件事，而各种对策连成了一条谱系。2020 年，学习无标签描述的通行做法是对比式的，也就是靠比较成对的样本来学。把同一张图的两个视角拉近。把其他所有东西推开，这样描述就不会全都堆到一个地方去。

BYOL 是 *Bootstrap Your Own Latent* 的缩写，是 DeepMind 的 Jean-Bastien Grill 和同事 2020 年的方法。它把「推开」这一步去掉了。取而代之的是保留一份缓慢更新的编码器副本 (通常叫 *目标编码器*：它跟在被训练的那个后面)，然后去预测这份副本的输出。目标没法从预测器那里跑掉。

按当时的标准说法，它本该坍缩。它没有，这让人们相信：不用把任何东西推开，也能避免坍缩。

VICReg 是 Adrien Bardes、Jean Ponce 与 LeCun 2021 年的方法，走的是另一条明确的路。这个名字把它的三项直接写了出来：方差 (variance)、不变性 (invariance)、协方差 (covariance)。它会惩罚那些各个分量已经坍缩、或者在互相抄袭的描述。这就是图 7.6 里那个防护的正经做法。






FIG. 7.7 三种阻止「堆到一起」的做法，各自跑在同一小团描述点云上。挑一种，多按几次「走一步」。对比式把每一对都推开。BYOL 什么都不推开，而点云仍然保持着形状，因为它追的那个目标是跟在后面的。VICReg 不动这些点，而是在点云的离散度下降、或者两条坐标轴互相抄袭时，去惩罚点云本身。点云仅作示意，请看「离散度」那个读数。

Randall Balestriero 和同事在 2023 年写了一篇综述，*A Cookbook of Self-Supervised Learning*。它很坦白：这个领域里很大一部分工作，都是为了不让那个平凡解赢下来而搭起来的机器。

损失也不再是一个你能直接读懂的数字了。像素损失为零，意味着模型把那一帧预测出来了。嵌入损失为零，可能意味着它什么都懂，也可能意味着它什么都不懂。那个数字不会告诉你是哪一种。



曲线为示意

最终的像素损失

这个零告诉你什么

0	尚未揭示
最终的嵌入损失	这个零告诉你什么
0	尚未揭示

FIG. 7.8 两次训练，最后损失都是零。在像素那一次上按「揭示像素那一组」，其实没什么可揭示的：零就意味着那一帧被预测出来了。在嵌入那一次上按「揭示嵌入那一组」，同样一个零会分成两种情况，一种是这些描述还分得清左和右，另一种是它们已经全都长成了同一份。只有下面那个探针能告诉你你拿到的是哪一种。曲线仅作示意。

于是 Quentin Garrido 和同事去检验这些嵌入到底能做什么。他们 2024 年的论文是 *Learning and Leveraging World Models in Visual Representation Learning*。

这没有解决的事

这些都不意味着生成是个错误。把这个论证读成「生成是个错误」，就是过度解读。那些预测像素的系统，正是造出了你能在里面走动的世界的那些，而且它们管用。不管它们在叶子上浪费了多少，它们交付了一张画面，而没有任何嵌入能做到这一点。

最难堪的反例来自 LeCun 自己的实验室。Kaiming He 最为人所知的是 ResNet，也就是计算机视觉靠着跑了好几年的那个网络设计，而他 2021 年就在那个实验室。他那一年的论文是 *Masked Autoencoders Are Scalable Vision Learners*。它把一张图的大部分挡住，再把这些像素重建出来，而这正是 JEPA 拒绝做的事。




FIG. 7.9 把遮挡拖到整张图的四分之三，按「重建」。解码器会把被挡住的小块大致重画出来，而这正是上一节说浪费的那件活。然后按「测试编码器」。它学到的那些描述照样能把形状干净地分开，下次再听到那句口号时，请把这个结果记在心里。全部仅作参考。

它学出来的描述照样非常好。而且它比那篇立场论文还早一年出来。

这个论证站得住的版本，比那句口号窄得多，但它是对的。预测外观会把大部分容量花在没有任何决定依赖的东西上。而当未来还没定下来时，一个确定性预测器会被训练着去画一张不会发生的图。

如果你要的是一个可以据以行动的紧凑状态，那这是个糟糕的拿法。如果你要的是一张画面，那这是目前唯一的拿法。这个领域这个角落里大部分的混乱，都来自拿为不同目标造出来的系统互相比较。

希望这一章对你有帮助。下面有一个简短的小测验，你可以用它检查这个论证有没有真的记住，也包括「它没有解决什么」那一部分。如果我写错了什么，或者你知道比我用的更好的来源，「关于」页面有一个更正板块。很欢迎你来找我。

试一试

1 一个确定性预测器使用像素平方误差，而汽车以相同概率左转或右转。它的最优解是什么？

- a. 两者的平均，也就是一张哪个都不是的画面
- b. 训练里更常见的那一个
- c. 左转
- d. 右转

答案 a. 两者的平均，也就是一张哪个都不是的画面。在一组结果上的平方误差由它们的均值最小化。笃定地选一边有一半时间会被重罚；糊影是一直被罚一点点，而后者赢了。

2 一个随机视频模型现在能分别采样清晰的左转和右转，不再输出糊影。它修好了什么，又没修好什么？

- a. 它不再需要像素目标
- b. 它证明了嵌入预测没有必要
- c. 它已经知道真实汽车会选哪边
- d. 它修好了不可能的平均画面，但仍要表达概率与决策风险

答案 d. 它修好了不可能的平均画面，但仍要表达概率与决策风险。采样是对模糊问题的真正解法：每次抽样都可以合理。但它不会指出现实会选哪一次，也不会替规划器给整个分布定价。

3 画面边缘一片叶子的动向无法预测。为什么预测像素的模型还要在它身上花容量？

- a. 叶子对理解场景很重要
- b. 叶子是由像素构成的，而像素正是模型被打分的东西
- c. 它分不清叶子和汽车
- d. 编码器逼它这么做

答案 b. 叶子是由像素构成的，而像素正是模型被打分的东西。没有任何东西告诉这个目标哪些像素才要紧。「难预测又不相关」是最糟的组合，而它占了画面的大部分。

4 改成预测嵌入而不是画面，对叶子问题有什么影响？

- a. 没有影响，叶子还在输入里
- b. 它让叶子更好预测了
- c. 如果某个细节没挺过编码，后面就没有东西会因为它被打分
- d. 它把问题挪给了解码器

答案 c. 如果某个细节没挺过编码，后面就没有东西会因为它被打分。那份描述从来没有义务记下叶子往哪边动，所以模型也不会因为说不出而被罚。

5 预测像素有一个大优点，是预测嵌入放弃掉的。是什么？

- a. 目标是固定的：模型没法让下一帧变简单
- b. 需要的数据更少
- c. 泛化更好
- d. 算得更快

答案 a. 目标是固定的：模型没法让下一帧变简单. 一旦目标是由一个同样在被训练的网络产生的，目标就会动，而且存在一条把它挪到非常方便的位置的路。

6 什么是塌缩？

- a. 模型忘掉了早先的训练
- b. 深层里梯度消失
- c. 损失发散到无穷
- d. 所有输入都编码成同一份描述，于是预测永远正确，而表征什么也没说

答案 d. 所有输入都编码成同一份描述，于是预测永远正确，而表征什么也没说. 那是一个「什么都没学」换来的满分，而且除非有东西专门去拦，它才是最省事的那个解。

7 图 7.6 里，开了防护的那一次损失更差。这说明了什么？

- a. 防护没调好
- b. 嵌入损失已经不再是一个可以直接当成质量读出来的数字
- c. 模型还需要更多训练
- d. 训练稳定之后就该把防护去掉

答案 b. 嵌入损失已经不再是一个可以直接当成质量读出来的数字. 像素损失为零意味着那一帧被预测出来了。嵌入损失为零可能意味着什么都懂，也可能什么都不懂，而这个数字说不清是哪种。

8 这个论点是不是说明了「生成像素」是个错误？

- a. 不是，因为塌缩让嵌入没法用
- b. 是，它严格更差
- c. 不是。想拿一个可以据以行动的紧凑状态，它是个糟糕的办法；而想拿一张真正的画面，它是目前唯一的办法
- d. 是，除了很短的视频以外

答案 c. 不是。想拿一个可以据以行动的紧凑状态，它是个糟糕的办法；而想拿一张真正的画面，它是目前唯一的办法. 这两个目标从来就不是同一个目标，而这里大部分的混乱都是有人在拿为不同目标造出来的系统互相比较。

FIG. 7.10 八道关于这个论证和它那张账单的题。最后两道是为了不让这个论证被读成一锤定音的判决，而这正是我最希望你避开的误解。

参考资料

Stochastic Variational Video Prediction (SV2P) BABAEIZADEH ET AL., 2017 ↗

像素预测对模糊问题的真正反驳：学习未来的分布，并从中采样清晰、各自可能的结果。

<https://arxiv.org/abs/1710.11252>

A Path Towards Autonomous Machine Intelligence LECUN, 2022 ↗

整个论点的出处，包括为什么对一个要去行动的系统来说，预测外观是错的活。

<https://openreview.net/forum?id=BZ5a1r-kVsf>

I-JEPA ASSRAN ET AL., 2023 ↗

预测被遮住区域的表征，而不是像素。

<https://arxiv.org/abs/2301.08243>

V-JEPA 2 META AI, 2025 ↗

先做无动作预训练，再做动作条件下的控制。

<https://ai.meta.com/blog/v-jepa-2-world-model-benchmarks/>

Bootstrap Your Own Latent (BYOL) GRILL ET AL., 2020 ↗

那份缓慢更新的目标副本，以及那个让大家相信「不把东西推开也能避免塌缩」的结果。

<https://arxiv.org/abs/2006.07733>

VICReg BARDES, PONCE & LECUN, 2021 ↗

显式的做法：惩罚那些各个分量已经塌掉或互相重复的表征。图 7.6 里那道防护的正经版本。

<https://arxiv.org/abs/2105.04906>

A Cookbook of Self-Supervised Learning BALESTRIERO ET AL., 2023 ↗

一份诚实的综述，包括这个领域有多大一部分是「防止平凡解获胜」的机器。

<https://arxiv.org/abs/2304.12210>

Masked Autoencoders Are Scalable Vision Learners HE ET AL., 2021 ↗

值得记住的反例：把被遮住那部分的像素重建出来，结果照样非常好用。

<https://arxiv.org/abs/2111.06377>

Learning and Leveraging World Models in Visual Representation Learning

GARRIDO ET AL., 2024 ↗

嵌入预测这个目标最后到底学到了什么，是测出来的，不是断言出来的。

<https://arxiv.org/abs/2404.08471>

FIG. 7.11 这里的排序是给要在这上面接着做事的人用的，而不是为了历史完整性，而且全程优先选了第一手材料。