

07 反对生成的理由

作者 NILUSHANAN KULASINGHAM

阅读约 12 分钟 · 可交互

当确定性像素预测器遇上开放的未来，最优解可能是一张不可能发生的画面。采样修好什么、嵌入避开什么，以及两者各自欠下的账。

把摄像机对着一条路，问它下一秒看起来是什么样。

画面边缘那棵树上的一片叶子会动。它往哪边动是没法知道的，同时也是所有信息里最无关紧要的一条。你可能做的任何决定，都不取决于它。

但一个被要求预测画面的模型必须去预测那片叶子，因为叶子是由像素构成的，而像素正是它被打分的东西。把这件事乘以每一片叶子、每一道涟漪、每一次光在湿沥青上的闪动，系统里大部分容量就已经花在那些既难预测、又不要紧的东西上了。


而这还是两个问题里比较小的那个。

两个未来的确定性平均，哪一个都不是


下面这个更大。

一辆车正开到一个路口。它会左转，或者右转。你是真的不知道是哪一个，而且再怎么盯着当前这一帧看也看不出来。

让一个确定性模型只预测一张下一帧，并用像素平方误差打分，那么存在一个数学上最好的答案。它不是左转，也不是右转，而是两者的条件平均。



一种可能的未来 (50%)



可能最好的像素预测




FIG. 7.1 中间那一格不是「模糊感」的艺术表现。它就是那两个未来按各自概率画出来的结果，也就是它们的平均值，而平方误差恰恰是被平均值最小化的。把概率拖到任意一端，最优解就清晰起来；让它停在中间，那么可能最好的预测就是一张不可能发生的画面。

再看一遍中间那一格。它的得分比两个真实未来都高。一个笃定地预测左转的模型有一半时间会被罚；而那个幽灵是一直被罚一点点，而「一直罚一点点」赢了。

这个特定的训练信号要的不是一个说得通的未来，而是平均值。当未来真的还没定时，平均值可能是一团从不发生的糊影。

用求平均的像素损失训练出的确定性预测器，会恰好在有意思的事快发生时变糊。现代生成器常用随机目标，正是为了避开这个失败。

采样是一个真正的反驳

像素预测不必只交出一个答案。SV2P、Denton 与 Fergus 的模型等随机视频模型，会学习未来的分布，再从中抽样。即使模型不知道车会往哪边转，每次抽到的结果仍然可以清晰而且合理。




FIG. 7.2 从条件平均切换到同一个两结果分布里的采样。采样消除了那个不可能的中间帧，也把不确定性保留在多次抽样之间。它不会透露世界最终选择哪一次，而规划器仍然要给整个分布里的风险定价。

这一下解决了模糊问题，却没有推翻反对生成的其余论证。采样修好了输出的形式，却不会让无关纹理变便宜、不会自动估准罕见未来，也不会告诉决策者哪个可能的未来最要紧。嵌入预测更换目标；随机生成保留目标，并更好地表达它的不确定性。

改成预测那份描述

这个提议很短：别再预测画面了。

把你能看到的東西編碼成一份緊湊描述 (也就是嵌入：一小串數字，用來代表一個更大的東西，而且排布成讓相似的東西落在附近)。把你要預測的那部分也編碼成一份。然後訓練模型從第一份描述去預測第二份，並且從頭到尾都不把任何東西解碼回像素。

這一下買到了兩樣東西。

葉子的问题沒了，因為那份描述從來就沒有義務記下葉子往哪邊動。如果某個細節沒能挺過編碼這一關，後面就沒有任何東西會因為它被打分。

平均的问题可能變小，因為你不再平均畫面。汽車左轉與右轉的描述可以共享大部分坐標，把未決定的那部分明確留下或干脆當作無關信息。特征空間仍然可能是多峰的；換一個表征不會消滅不確定性。

這就是 JEPA 這一家族，而這個名字說的就是它的架構：聯合嵌入，因為兩邊都被嵌入；預測式，因為訓練信號是一個嵌入去預測另一個嵌入。

為此要付的賬

現在講通常被跳過的那部分，而它可不小。

預測像素有一個巨大的優點：目標是固定的。下一幀就是下一幀，模型沒法讓它變簡單。

改成預測一個嵌入，這一點就不成立了，因為你要預測的那個東西是由一個同樣正在被訓練的網絡產生的。這個網絡可以什麼都不學就拿滿分。只要讓所有描述都一模一樣，預測就永遠精確正確，損失掉到零，而這份表征關於任何事情都什麼也沒說。



FIG. 7.3 一个二乘二的编码器，在四对样本上用梯度下降训练。数字直接来自算术。没有防护时，损失和表征一起掉到零。把防护打开，损失就再也接近不了零。有用的那一次运行，看起来反而更差。

这些方法里所有困难的部分，都在于防住那件事。保留一份缓慢更新的编码器副本 (通常叫 *目标编码器*：它跟在被训练的那个后面，好让被预测的东西没法从预测它的东西那里跑掉)，让目标跑不掉。把不同的输入显式地推开。惩罚那些各个分量都在说同一件事的描述。答案有好几个家族，没有一个优雅。

注意损失发生了什么变化。它不再是一个你能读出来的测量值了。像素损失为零意味着模型预测出了那一帧。嵌入损失为零则可能意味着它什么都懂，也可能什么都不懂，而那个数字不会告诉你是哪一种。分数在不再关于像素的同一刻，也不再可信了。

这没有解决的事

以「生成是个错误」收尾会很整齐。但它不是。

那些预测像素的系统，正是产出了你可以在里面走动的世界的那些，而且它们管用。不管有多少东西浪费在叶子上，它们交付了嵌入预测无论如何都交付不了的一样东西：一张真正的画面。如果你想看到未来，而不只是对它做推理，那总得有人把它画出来。

所以这个论点诚实的表述，比那句口号窄得多。预测外观会把大部分容量花在没有任何决定依赖的东西上；而当未来不确定时，它被训练着去画一张不会发生的图。如果你要的是一个可以据以行动的紧凑状态，那这是个糟糕的拿法。如果你要的是一张画面，那这是目前唯一的拿法。

这两个目标从来就不是同一个目标。这个角落里大部分的混乱，都是有人在拿为不同目标造出来的系统互相比较。

试一试

1 一个确定性预测器使用像素平方误差，而汽车以相同概率左转或右转。它的最优解是什么？

- a. 两者的平均，也就是一张哪个都不是的画面
- b. 训练里更常见的那一个
- c. 左转
- d. 右转

答案 a. 两者的平均，也就是一张哪个都不是的画面。在一组结果上的平方误差由它们的均值最小化。笃定地选一边有一半时间会被重罚；糊影是一直被罚一点点，而后者赢了。

2 一个随机视频模型现在能分别采样清晰的左转和右转，不再输出糊影。它修好了什么，又没修好什么？

- a. 它不再需要像素目标
- b. 它证明了嵌入预测没有必要
- c. 它已经知道真实汽车会选哪边
- d. 它修好了不可能的平均画面，但仍要表达概率与决策风险

答案 d. 它修好了不可能的平均画面，但仍要表达概率与决策风险。采样是对模糊问题的真正解法：每次抽样都可以合理。但它不会指出现实会选哪一次，也不会替规划器给整个分布定价。

3 画面边缘一片叶子的动向无法预测。为什么预测像素的模型还要在它身上花容量？

- a. 叶子对理解场景很重要
- b. 叶子是由像素构成的，而像素正是模型被打分的东西
- c. 它分不清叶子和汽车
- d. 编码器逼它这么做

答案 b. 叶子是由像素构成的，而像素正是模型被打分的东西。没有任何东西告诉这个目标哪些像素才要紧。「难预测又不相关」是最糟的组合，而它占了画面的大部分。

4 改成预测嵌入而不是画面，对叶子问题有什么影响？

- a. 没有影响，叶子还在输入里
- b. 它让叶子更好预测了
- c. 如果某个细节没挺过编码，后面就没有东西会因为它被打分
- d. 它把问题挪给了解码器

答案 c. 如果某个细节没挺过编码，后面就没有东西会因为它被打分。那份描述从来没有义务记下叶子往哪边动，所以模型也不会因为说不出而被罚。

5 预测像素有一个大优点，是预测嵌入放弃掉的。是什么？

- a. 目标是固定的：模型没法让下一帧变简单
- b. 需要的数据更少
- c. 泛化更好
- d. 算得更快

答案 a. 目标是固定的：模型没法让下一帧变简单。一旦目标是由一个同样在被训练的网络产生的，目标就会动，而且存在一条把它挪到非常方便的位置的路。

6 什么是塌缩？

- a. 模型忘掉了早先的训练
- b. 深层里梯度消失
- c. 损失发散到无穷
- d. 所有输入都编码成同一份描述，于是预测永远正确，而表征什么也没说

答案 d. 所有输入都编码成同一份描述，于是预测永远正确，而表征什么也没说。那是一个「什么都没学」换来的满分，而且除非有东西专门去拦，它才是最省事的那个解。

7 图 7.3 里，开了防护的那一次损失更差。这说明了什么？

- a. 防护没调好
- b. 嵌入损失已经不再是一个可以直接当成质量读出来的数字
- c. 模型还需要更多训练
- d. 训练稳定之后就该把防护去掉

答案 b. 嵌入损失已经不再是一个可以直接当成质量读出来的数字。像素损失为零意味着那一帧被预测出来了。嵌入损失为零可能意味着什么都懂，也可能什么都不懂，而这个数字说不清是哪种。

8 这个论点是不是说明了「生成像素」是个错误？

- a. 不是，因为塌缩让嵌入没法用
- b. 是，它严格更差
- c. 不是。想拿一个可以据以行动的紧凑状态，它是个糟糕的办法；而想拿一张真正的画面，它是目前唯一的办法
- d. 是，除了很短的视频以外

答案 c. 不是。想拿一个可以据以行动的紧凑状态，它是个糟糕的办法；而想拿一张真正的画面，它是目前唯一的办法。这两个目标从来就不是同一个目标，而这里大部分的混乱都是有人在拿为不同目标造出来的系统互相比较。

FIG. 7.4 八道关于这个论点和它那账单的题。最后两道会让这一章读起来不像一个板上钉钉的判决。

那就剩下那些走了另一条路、而且走得很狠的系统了。

多谢阅读。第 8 章讲的是：当你把像素预测放大到结果可以用键盘操控时，会发生什么；以及当有人对一个视频模型说「它学会了物理」时，这句话意味着什么、又不意味着什么。

参考资料

Stochastic Variational Video Prediction (SV2P) BABAEIZADEH ET AL., 2017 ↗

像素预测对模糊问题的真正反驳：学习未来的分布，并从中采样清晰、各自可能的结果。

<https://arxiv.org/abs/1710.11252>

A Path Towards Autonomous Machine Intelligence LECUN, 2022 ↗

整个论点的出处，包括为什么对一个要去行动的系统来说，预测外观是错的活。

<https://openreview.net/forum?id=BZ5a1r-kVsf>

I-JEPA ASSRAN ET AL., 2023 ↗

预测被遮住区域的表征，而不是像素。

<https://arxiv.org/abs/2301.08243>

V-JEPA 2 META AI, 2025 ↗

先做无动作预训练，再做动作条件下的控制。

<https://ai.meta.com/blog/v-jepa-2-world-model-benchmarks/>

Bootstrap Your Own Latent (BYOL) GRILL ET AL., 2020 ↗

那份缓慢更新的目标副本，以及那个让大家相信「不把东西推开也能避免塌缩」的结果。

<https://arxiv.org/abs/2006.07733>

VICReg BARDES, PONCE & LECUN, 2021 ↗

显式的做法：惩罚那些各个分量已经塌掉或互相重复的表征。图 7.3 里那道防护的正经版本。

<https://arxiv.org/abs/2105.04906>

A Cookbook of Self-Supervised Learning BALESTRIERO ET AL., 2023 ↗

一份诚实的综述，包括这个领域有多大一部分是「防止平凡解获胜」的机器。

<https://arxiv.org/abs/2304.12210>

Masked Autoencoders Are Scalable Vision Learners HE ET AL., 2021 ↗

值得记住的反例：把被遮住那部分的像素重建出来，结果照样非常好用。

<https://arxiv.org/abs/2111.06377>

Learning and Leveraging World Models in Visual Representation Learning

GARRIDO ET AL., 2024 ↗

嵌入预测这个目标最后到底学到了什么，是测出来的，不是断言出来的。

<https://arxiv.org/abs/2404.08471>

FIG. 7.5 排序是给要在这上面接着做事的人用的，而不是为了历史完整性。