

07 反对生成的理由

作者 NILUSHANAN KULASINGHAM

阅读约 10 分钟 · 可交互

当未来真的还没定时，可能最好的像素预测是一张不可能发生的画面。改成预测描述的理由，以及随之而来的那张账单。

把摄像机对着一条路，问它下一秒看起来是什么样。

画面边缘那棵树上的一片叶子会动。它往哪边动是没法知道的，同时也是所有信息里最无关紧要的一条。你可能做的任何决定，都不取决于它。

但一个被要求预测画面的模型必须去预测那片叶子，因为叶子是由像素构成的，而像素正是它被打分的东西。把这件事乘以每一片叶子、每一道涟漪、每一次光在湿沥青上的闪动，系统里大部分容量就已经花在那些既难预测、又不要紧的东西上了。


而这还是两个问题里比较小的那个。

两个未来的平均值，哪一个都不是


下面这个更大。

一辆车正开到一个路口。它会左转，或者右转。你是真的不知道是哪一个，而且再怎么盯着当前这一帧看也看不出来。

让一个模型去预测下一张画面，并且按像素有多接近来打分，那么存在一个数学上最好的答案。它不是左转，也不是右转，而是这两者的平均。



一种可能的未来 (50%)



可能最好的像素预测



FIG. 7.1 中间那一格不是「模糊感」的艺术表现。它就是那两个未来按各自概率画出来的结果，也就是它们的平均值，而平方误差恰恰是被平均值最小化的。把概率拖到任意一端，最优解就清晰起来；让它停在中间，那么可能最好的预测就是一张不可能发生的画面。

再看一遍中间那一格。它的得分比两个真实未来都高。一个笃定地预测左转的模型有一半时间会被罚；而那个幽灵是一直被罚一点点，而「一直罚一点点」赢了。

所以这个训练信号要的并不是一个说得通的未来。它要的是各个未来的平均值，而当未来真的还没定时，那个平均值就是一团从不发生的糊影。

这就是为什么生成的视频恰好在有意思的事情快要发生时变糊。糊影来自不确定性，而不确定性正集中在那些要紧的时刻。

改成预测那份描述

这个提议很短：别再预测画面了。

把你能看到的東西编码成一份紧凑描述 (也就是嵌入：一小串数字，用来代表一个更大的东西，而且排布成让相似的东西落在附近)。把你要预测的那部分也编码成一份。然后训练模型从第一份描述去预测第二份，并且从头到尾都不把任何东西解码回像素。

这一下买到了两样东西。

叶子的问题没了，因为那份描述从来就没有义务记下叶子往哪边动。如果某个细节没能挺过编码这一关，后面就没有任何东西会因为它被打分。

平均的问题也变小了，因为你不再是在平均画面。一辆车左转的描述和一辆车右转的描述可以共享几乎所有东西。被预测的那个对象可能是一个两者都靠近的点，于是这个预测有了一个合理的落脚处。

这就是 JEPA 这一家族，而这个名字说的就是它的架构：联合嵌入，因为两边都被嵌入；预测式，因为训练信号是一个嵌入去预测另一个嵌入。

为此要付的账

现在讲通常被跳过的那部分，而它可不小。

预测像素有一个巨大的优点：目标是固定的。下一帧就是下一帧，模型没法让它变简单。

改成预测一个嵌入，这一点就不成立了，因为你要预测的那个东西是由一个同样正在被训练的网络产生的。现在存在一条什么都不用学就能拿满分的路：让所有描述都一模一样。那样预测就永远精确正确，损失掉到零，而这份表征关于任何事情都什么也没说。



FIG. 7.2 一个二乘二的编码器，在四对样本上用梯度下降训练。这里没有一样东西是示意性的：这些数字就是算术产生出来的结果。没有防护时，损失掉到零，表征也跟着掉到零。把防护打开，损失就再也接近不了零，而这正是重点：有用的那一次运行，看起来是更差的那一次。

这些方法里所有困难的部分，都在于防住那件事。保留一份缓慢更新的编码器副本 (通常叫 *目标编码器*：它跟在被训练的那个后面，好让被预测的东西没法从预测它的东西那里跑掉)，让目标跑不掉。把不同的输入显式地推开。惩罚那些各个分量都在说同一件事的描述。答案有好几个家族，没有一个优雅。

注意损失发生了什么变化。它不再是一个你能读出来的测量值了。像素损失为零意味着模型预测出了那一帧。嵌入损失为零则可能意味着它什么都懂，也可能什么都不懂，而那个数字不会告诉你是哪一种。分数在不再关于像素的同一刻，也不再可信了。

这没有解决的事

以「生成是个错误」收尾会很整齐。但它不是。

那些预测像素的系统，正是产出了你可以在里面走动的世界的那些，而且它们管用。不管有多少东西浪费在叶子上，它们交付了嵌入预测无论如何都交付不了的一样东西：一张真正的画面。如果你想看到未来，而不只是对它做推理，那总得有人把它画出来。

所以这个论点诚实的表述，比那句口号窄得多。预测外观会把大部分容量花在没有任何决定依赖的东西上；而当未来不确定时，它被训练着去画一张不会发生的图。如果你要的是一个可以据以行动的紧凑状态，那这是个糟糕的拿法。如果你要的是一张画面，那这是目前唯一的拿法。

这两个目标从来就不是同一个目标。这个角落里大部分的混乱，都是有人在拿为不同目标造出来的系统互相比较。

试一试

1 一辆车会以相同概率左转或右转。像素损失认为最好的预测是什么？

- a. 左转
- b. 右转
- c. 两者的平均，也就是一张哪个都不是的画面
- d. 训练里更常见的那一个

答案 c. 两者的平均，也就是一张哪个都不是的画面。在一组结果上的平方误差由它们的均值最小化。笃定地选一边有一半时间会被重罚；糊影是一直被罚一点点，而后者赢了。

2 为什么生成的视频恰好在有意思的事情快要发生时变糊？

- a. 模型的容量用完了
- b. 有意思的时刻正是未来不确定的时刻，而不确定性就是糊影的来源
- c. 帧率掉了
- d. 编码器太小

答案 b. 有意思的时刻正是未来不确定的时刻，而不确定性就是糊影的来源。这份糊不是渲染问题。是训练目标在要求各个可能未来的均值，而在结果最开放的地方，这个均值最不像其中任何一个。

3 画面边缘一片叶子的动向无法预测。为什么预测像素的模型还要在它身上花容量？

- a. 叶子对理解场景很重要
- b. 叶子是由像素构成的，而像素正是模型被打分的东西
- c. 它分不清叶子和汽车
- d. 编码器逼它这么做

答案 b. 叶子是由像素构成的，而像素正是模型被打分的东西。没有任何东西告诉这个目标哪些像素才要紧。「难预测又不相关」是最糟的组合，而它占了画面的大部分。

4 改成预测嵌入而不是画面，对叶子问题有什么影响？

- a. 它让叶子更好预测了
- b. 如果某个细节没挺过编码，后面就没有东西会因为它被打分
- c. 它把问题挪给了解码器
- d. 没有影响，叶子还在输入里

答案 b. 如果某个细节没挺过编码，后面就没有东西会因为它被打分。那份描述从来没有义务记下叶子往哪边动，所以模型也不会因为说不出而被罚。

5 预测像素有一个大优点，是预测嵌入放弃掉的。是什么？

- a. 算得更快
- b. 目标是固定的：模型没法让下一帧变简单

- c. 需要的数据更少
- d. 泛化更好

答案 b. 目标是固定的：模型没法让下一帧变简单。一旦目标是由一个同样在被训练的网络产生的，目标就会动，而且存在一条把它挪到非常方便的位置的路。

6 什么是塌缩？

- a. 损失发散到无穷
- b. 所有输入都编码成同一份描述，于是预测永远正确，而表征什么也没说
- c. 模型忘掉了早先的训练
- d. 深层里梯度消失

答案 b. 所有输入都编码成同一份描述，于是预测永远正确，而表征什么也没说。那是一个「什么都没学」换来的满分，而且除非有东西专门去拦，它就是最省事的那个解。

7 图 7.2 里，开了防护的那一次损失更差。这说明了什么？

- a. 防护没调好
- b. 嵌入损失已经不再是一个可以直接当成质量读出来的数字
- c. 模型还需要更多训练
- d. 训练稳定之后就该把防护去掉

答案 b. 嵌入损失已经不再是一个可以直接当成质量读出来的数字。像素损失为零意味着那一帧被预测出来了。嵌入损失为零可能意味着什么都懂，也可能什么都不懂，而这个数字说不清是哪种。

8 这个论点是不是说明了「生成像素」是个错误？

- a. 是，它严格更差
- b. 不是。想拿一个可以据以行动的紧凑状态，它是个糟糕的办法；而想拿一张真正的画面，它是目前唯一的办法
- c. 是，除了很短的视频以外
- d. 不是，因为塌缩让嵌入没法用

答案 b. 不是。想拿一个可以据以行动的紧凑状态，它是个糟糕的办法；而想拿一张真正的画面，它是目前唯一的办法。这两个目标从来就不是同一个目标，而这里大部分的混乱都是有人在拿为不同目标造出来的系统互相比较。

FIG. 7.3 八道关于这个论点和它那账单的题。最后两道会让这一章读起来不像一个板上钉钉的判决。

那就剩下那些走了另一条路、而且走得很狠的系统了。

多谢阅读。第 8 章讲的是：当你把像素预测放大到结果可以用键盘操控时，会发生什么；以及当有人对一个视频模型说「它学会了物理」时，这句话意味着什么、又不意味着什么。

参考资料

A Path Towards Autonomous Machine Intelligence LECUN, 2022 ↗

整个论点的出处，包括为什么对一个要去行动的系统来说，预测外观是错的活。

<https://openreview.net/forum?id=BZ5a1r-kVsF>

I-JEPA ASSRAN ET AL., 2023 ↗

预测被遮住区域的表征，而不是像素。

<https://arxiv.org/abs/2301.08243>

V-JEPA 2 META AI, 2025 ↗

先做无动作预训练，再做动作条件下的控制。

<https://ai.meta.com/blog/v-jepa-2-world-model-benchmarks/>

Bootstrap Your Own Latent (BYOL) GRILL ET AL., 2020 ↗

那份缓慢更新的目标副本，以及那个让大家相信「不把东西推开也能避免塌缩」的结果。

<https://arxiv.org/abs/2006.07733>

VICReg BARDES, PONCE & LECUN, 2021 ↗

显式的做法：惩罚那些各个分量已经塌掉或互相重复的表征。图 7.2 里那道防护的正经版本。

<https://arxiv.org/abs/2105.04906>

A Cookbook of Self-Supervised Learning BALESTRIERO ET AL., 2023 ↗

一份诚实的综述，包括这个领域有多大一部分是「防止平凡解获胜」的机器。

<https://arxiv.org/abs/2304.12210>

Masked Autoencoders Are Scalable Vision Learners HE ET AL., 2021 ↗

值得记住的反例：把被遮住那部分的像素重建出来，结果照样非常好用。

<https://arxiv.org/abs/2111.06377>

Learning and Leveraging World Models in Visual Representation Learning

GARRIDO ET AL., 2024 ↗

嵌入预测这个目标最后到底学到了什么，是测出来的，不是断言出来的。

FIG. 7.4 排序是给要在这上面接着做事的人用的，而不是为了历史完整性。