

# 08 视频作为世界模拟器

作者 NILUSHANAN KULASINGHAM

阅读约 12 分钟 · 可交互

给视频模型加上动作输入，只是让它原则上可以被操控。怎样区分条件与控制、放大买到了什么，以及为什么拟合物理不等于掌握规律。

拿一个预测视频下一帧的模型，给它加上一个输入。

除了它已经看过的那些帧之外，再告诉它现在按住的是哪个键。模型于是有能力让同一个开头在按左时走向一种续接、按右时走向另一种。动作输入是交互世界的必要条件，但它本身不能证明模型会听话。




FIG. 8.1 一个模型，一个起点，三个未来。前两帧是给定的，其余都是编出来的。把动作输入关掉，三行会变得一模一样。没有它，就只有一个未来可选，也就是模型认为最可能的那一个。

架构上的动作就是这个。它是否真的变成控制，是个实证问题。

# 有动作输入，不等于能控制

一个模型可以收到动作，却仍然忽略它、反应很弱，或者只让动作改变外观而不改变真正的轨迹。要测可控性，就得固定起点，只改变指令，再检查生成的未来是否按要求分开。




FIG. 8.2 每一行都从同一帧出发，收到不同指令。把动作保真度拖向零。输入仍然存在，实际轨迹却收拢到一起。「条件里有动作」描述接口；保真度才描述模型是否照做。

画面质量可以掩盖控制很弱的事实。如果三段漂亮的续接全都直行，系统生成了视频，却没有生成规划器要求的反事实。

# 放大买到了什么

比大多数人预期的要多，包括造它的大多数人。

据报道，Genie 3 能以 720p、每秒 24 帧生成可交互的视频。据报道，它能让一个场景在数分钟内保持连贯，还能在中途接受指令：换个天气，加一群鸟。走开，再走回来，它大致还是你离开时的样子。

把这些数字当成实验室自己的报告，而不是实验室之外任何人复现过的测量。这不是贬低；这是这个主题的状态，而第 9 章讲的大半就是目前有多少东西是没法核实的。

公开接口里没有可以检查或导出的持久几何结构和物体数据库。这不等于没有记忆。DeepMind 称 Genie 3 可以参照此前走过的轨迹，并把视觉信息保留约一分钟。支撑这种行为的内部状态仍隐含在生成器里，而不是一张可供查看的场景图。

---

## 「涌现出物理」是什么意思

你会看到有人对这里的每一个系统都下这个论断。所以值得说清楚它能意味着什么、不能意味着什么。

它背后的那个观察是真的。在足够多的视频上训练，输出就开始尊重一些没有人放进去的东西。掉落的物体会向下加速。水会积起来，而不是堆起来。被别的东西挡住的东西，在前面那个挪开之后会回来。没有人提供过任何方程。这些规律就在训练素材里，而要把素材预测好，就得把它们复现出来。

搭在这个观察上面的那个论断，才是麻烦开始的地方。「它学会了物理」暗示的是它掌握了那条规律，而这件事是有办法测的。办法不是看它在「和训练时同类的东西」上输出得对不对。




FIG. 8.3 虚线是一个模型，它被拟合在真实行为的某一段速度范围上。在那个范围里它的误差在几个百分点以内，任何在那里做测试的人都会断定它掌握了规律。把滑块拖到范围之外。它并没有那条规律，它只有一条穿过它见过那一段曲线的直线。

范围之内的一切，都与「它学会了物理」相容。它同样也与「它记住了被问过那些问题的答案」相容。这两者只有在范围之外才分得开，而范围之外恰恰是没有人去测的地方，因为那里你根本没有素材可以对照。

所以这个论断诚实的版本更窄，也更有用：这些系统在它们训练过的那一类情形里，复现了大量的物理规律。这算不算掌握了规律，你见过的任何演示都定不下来，因为那些演示全都在范围之内。

这不是视频模型独有的毛病。这是任何拟合出来的函数都会有的普通问题，而它在这里之所以感觉不一样，只是因为输出太有说服力了。一个长得像照片的错误答案，比一个错误的数字更让人信服。

# 它们是用来干什么的

说了这些，很容易变得轻蔑，而那会是个错误。

用来训练别的系统，一个生成出来的世界很有用。它避开了真实环境接触，却仍然要付加速器时间。它能瞬间重置，也能给出一千种真要搭起来得花一周的场景变体。英伟达的 Cosmos 就是照着这个造的、也是这么卖的：把有物理感的生成视频当作机器人和车辆的训练数据。

用来当一个你可以在里面走动的世界，它们已经相当好了。这件事本身就值钱，而这门课里没有别的路数能交付它。

用来让智能体在里面规划，原始视频生成器的形状很别扭。规划器可能要给一百条动作序列打分，每条都渲染出来代价很高。系统可以蒸馏出紧凑状态，或在学出的潜在空间里规划。这时做规划工作的是那个状态，不是看得见的视频。

---

## 缝隙在哪里

三条，说得简短些，因为下一章是完整的清算。

一致性是学出来的，不是被强制的。没有任何东西阻止这个房间发生变化。它通常不变，而「它通常不变」是一个训练好的系统的统计性质，不是一份保证。

有意思的时刻正是模糊的那些。一个在像素上训练的模型，在未来还开放的地方会被推向各个可能未来的平均值。而未来最开放的时候，恰恰就是有事要发生的时候。

分数没法自然合成。基准会分别测画面质量、几何、动作保真度和持久性。没有公认规则能把这些结果合成一个排序。所以任何「进步了」都只在某一项检验下成立。

# 试一试

1 哪一个改动能让视频模型具备被操控的可能，却不能证明它会听话？

- a. 更高的分辨率
- b. 更长的上下文窗口
- c. 更多参数
- d. 让每一帧的生成同时以一个动作、以及之前那些帧为条件

答案 d. 让每一帧的生成同时以一个动作、以及之前那些帧为条件. 动作条件提供的是接口。可控性仍要固定起点、只改变动作，再测所要求的未来是否真的分开。

2 你转回身，生成出来的房间还是离开时的样子。关于它的记忆，你能推出什么？

- a. 某种内部状态支撑着持久性，但这个行为看不出它是场景图、上下文还是别的机制
- b. 它一定用了单独的物体数据库
- c. 里面一定有可导出的几何结构
- d. 它没有任何形式的记忆

答案 a. 某种内部状态支撑着持久性，但这个行为看不出它是场景图、上下文还是别的机制。这个行为证明了持久性，没有证明实现方式。据称 Genie 3 会参照此前轨迹，但没有暴露可检查的持久几何结构或物体存储。

3 生成视频里掉落的物体会向下加速，而没有人提供过重力。这确立了什么？

- a. 什么也没确立
- b. 模型学会了万有引力定律
- c. 这个规律就在训练素材里，而要把素材预测好就必须复现它
- d. 模型里含着一个物理引擎

答案 c. 这个规律就在训练素材里，而要把素材预测好就必须复现它. 这个观察是真的。问题在于：在你训练过的范围里复现一个规律，算不算掌握了那条规律；而光凭这个观察定不下来。

4 图 8.3 里，模型在它训练过的那一段范围里误差只有几个百分点。为什么这不算它掌握了规律的证据？

- a. 测量不可靠
- b. 在范围里对得上，同样也与「它记住了被问过那些问题的答案」相容
- c. 几个百分点的误差太大了
- d. 那段范围太窄

答案 b. 在范围里对得上，同样也与「它记住了被问过那些问题的答案」相容。「掌握规律」和「在采样过的区域里拟合得好」只有在范围之外才分得开，而范围之外正是没人去测的地方，因为那里没有素材可以对照。

5 为什么生成视频世界的形状不适合智能体在里面做规划？

- a. 它没法以动作为条件
- b. 它没有奖励信号
- c. 它不够准
- d. 规划意味着把模型跑很多遍，而一帧画面是「紧凑状态」的反面

答案 d. 规划意味着把模型跑很多遍，而一帧画面是「紧凑状态」的反面. 规划器需要便宜地试很多条动作序列并打分。这些模型跑起来很贵，而且产出的是画面，不是一个小到可以推理的东西。

6 目前生成出来的世界，毫无争议地擅长什么？

- a. 产出训练数据，以及当一个你可以在里面走动的地方
- b. 长时程规划
- c. 压缩视频
- d. 取代物理引擎

答案 a. 产出训练数据，以及当一个你可以在里面走动的地方. 它们避开真实世界接触、能瞬间重置并产出广泛变体，但仍然要付计算代价。而且这门课里没有别的路数能给你一张真正能走进去的画面。

7 为什么这类系统给出的错误答案，比一个错误的数字更让人信服？

- a. 它通常并没有错
- b. 它的误差更小
- c. 它是以一张长得像照片的东西的形式出现的
- d. 这些模型的置信度校准得更好

答案 c. 它是以一张长得像照片的东西的形式出现的. 这里的外推问题就是任何拟合函数都会有的普通问题。不一样的地方在于：它失败的时候，输出有多有说服力。

8 一个系统的几何分数提高了，动作保真度却下降了。它综合来看更好吗？

- a. 是，几何是唯一客观尺度
- b. 除非先声明用途或给出合并各维度的规则，否则答不了
- c. 不是，动作保真度永远更重要
- d. 是，任何基准上涨都证明综合进步

答案 b. 除非先声明用途或给出合并各维度的规则，否则答不了. 现在的基准已经能测几个有用维度。没解决的是：当不同系统和用途重视不同契约时，该怎么把它们合起来。

FIG. 8.4 八道关于那个动作和那个论断的题。中间三道是在一个演示很唬人的时候，值得当心的那几道。

这就把我们带到了这个主题里通常不会写进发布公告的那部分。

多谢阅读。第 9 章是一次诚实的清算：什么会漂、什么会被忘掉、什么问不出来，以及为什么目前没有人能告诉你这些系统里哪一个最好。

# 参考资料

Genie: Generative Interactive Environments BRUCE ET AL., 2024 ↗

可以用动作操控的生成环境。

<https://arxiv.org/abs/2402.15391>

Genie 3 GOOGLE DEEPMIND, 2025 ↗

报告称能在多分钟的交互里回想起先前见过的细节。

<https://deepmind.google/blog/genie-3-a-new-frontier-for-world-models/>

Diffusion Models Are Real-Time Game Engines (GameNGen)

VALEVSKI ET AL., 2024 ↗

DOOM 被逐帧地从此前的帧和输入里生成出来，快到可以玩。最清楚地说明了这类东西是可玩的，而不只是可看的。

<https://arxiv.org/abs/2408.14837>

How Far is Video Generation from World Model: A Physical Law Perspective

KANG ET AL., 2024 ↗

图 8.3 的实测版本。视频模型在训练分布之内符合物理规律，出了这个范围就不会外推。

<https://arxiv.org/abs/2411.02385>

Video generation models as world simulators OPENAI, 2024 ↗

让「涌现出物理」这个说法进入主流的那份报告。值得读一读它究竟主张了什么、又没主张什么。

<https://openai.com/index/video-generation-models-as-world-simulators/>

Cosmos World Foundation Model Platform for Physical AI NVIDIA, 2025 ↗

把生成视频当作机器人和车辆的训练数据来造，而这正是这类系统毫无争议地擅长的用途。

<https://arxiv.org/abs/2501.03575>

Cosmos NVIDIA ↗

一个边界案例：预测式视频世界与显式仿真并置。

<https://www.nvidia.com/en-us/ai/cosmos/>

FIG. 8.5 排序是给要在这上面接着做事的人用的，而不是为了历史完整性。