

08 视频作为世界模拟器

作者 NILUSHANAN KULASINGHAM

阅读约 10 分钟 · 可交互

给一个视频模型加上一个输入，它就不再是视频了。把这件事放大买到了什么，以及为什么「在训练过的范围里符合物理」和「掌握了那条规律」不是一回事。

拿一个预测视频下一帧的模型，给它加上一个输入。

除了它已经看过的那些帧之外，再告诉它现在按住的是哪个键。于是同一个开头，按住左会给你一种续接，按住右会给你另一种。它已经不再是一段视频，而变成了一个你正身处其中的地方。




FIG. 8.1 一个模型，一个起点，三个未来。前两帧是给定的，其余都是编出来的。把动作输入关掉，三行会变得一模一样，而这正是全部的区别：没有它，就只有一个未来可选，而那是模型认为最可能的那一个。

这就是全部的架构动作。这一章剩下的内容，讲的都是把它放大之后会发生什么。

放大买到了什么

比大多数人预期的要多，包括造它的大多数人。

据报道，Genie 3 能以 720p、每秒 24 帧生成可交互的视频。据报道，它能让一个场景在数分钟内保持连贯，还能在中途接受指令：换个天气，加一群鸟。走开，再走回来，它大致还是你离开时的样子。

把这些数字当成实验室自己的报告，而不是实验室之外任何人复现过的测量。这不是贬低；这是这个主题的常态，而第 9 章讲的大半就是目前有多少东西是没法核实的。

那个系统里没有任何东西存着这个场景。画面背后没有几何结构，没有物体清单，也没有任何你能导出的东西。房间之所以还在原处，是因为模型变得极其擅长把它已经画出来的东西接着画下去，而保持一致正是「接得好」的一部分。

这件事比听起来更奇怪：一个对房间没有任何记忆的系统，靠自己此前的输出把这个房间重建出来，而且好到你在一分钟的观察里抓不到它的破绽。

「涌现出物理」是什么意思

你会看到有人对这里的每一个系统都下这个论断。所以值得说清楚它能意味着什么、不能意味着什么。

它背后的那个观察是真的。在足够多的视频上训练，输出就开始尊重一些没有人放进去的东西。掉落的物体会向下加速。水会积起来，而不是堆起来。被别的东西挡住的东西，在前面那个挪开之后会回来。没有人提供过任何方程。这些规律就在训练素材里，而要把素材预测好，就得把它们复现出来。

搭在这个观察上面的那个论断，才是麻烦开始的地方。「它学会了物理」暗示的是它掌握了那条规律，而这件事是有办法测的。办法不是看它在「和训练时同类的东西」上输出得对不对。




FIG. 8.2 虚线是一个模型，它被拟合在真实行为的某一段速度范围上。在那个范围里它的误差在几个百分点以内，任何在那里做测试的人都会断定它掌握了规律。把滑块拖到范围之外。它并没有那条规律，它只有一条穿过它见过那一段曲线的直线。

范围之内的一切，都与「它学会了物理」相容。它同样也与「它记住了被问过那些问题的答案」相容。这两者只有在范围之外才分得开，而范围之外恰恰是没有人去测的地方，因为那里你根本没有素材可以对照。

所以这个论断诚实的版本更窄，也更有用：这些系统在它们训练过的那一类情形里，复现了大量的物理规律。这算不算掌握了规律，你见过的任何演示都定不下来，因为那些演示全都在范围之内。

这不是视频模型独有的毛病。这是任何拟合出来的函数都会有的普通问题，而它在这里之所以感觉不一样，只是因为输出太有说服力了。一个长得像照片的错误答案，比一个错误的数字更让人信服。

它们是用来干什么的

说了这些，很容易变得轻蔑，而那会是个错误。

用来训练别的系统，一个生成出来的世界很有用。它跑起来不花钱。它瞬间就能重置。它能给出一千种变体，而这些场景真要搭起来得花一周。英伟达的 Cosmos 就是照着这个造的、也是这么卖的：把有物理感的生成视频当作机器人和车辆的训练数据。

用来当一个你可以在里面走动的世界，它们已经相当好了。这件事本身就值钱，而这门课里没有别的路数能交付它。

用来当一个智能体在里面做规划的东西，它们的形状不对。规划器需要试一百条动作序列并给它们打分，这意味着把模型跑一百遍，而跑这些模型很贵。它还需要一个紧凑的状态来推理，而一帧画面是「紧凑」的反面。

缝隙在哪里

三条，说得简短些，因为下一章是完整的清算。

一致性是学出来的，不是被强制的。没有任何东西阻止这个房间发生变化。它通常不变，而「它通常不变」是一个训练好的系统的统计性质，不是一份保证。

有意思的时刻正是模糊的那些。一个在像素上训练的模型，在未来还开放的地方会被推向各个可能未来的平均值。而未来最开放的时候，恰恰就是有事要发生的时候。

没有人对怎么给它们打分达成一致。目前没有公认的方法去衡量一个生成出来的世界表现得好不好，这意味着关于「进步了」的说法，大多是关于「输出在说这话的人眼里看起来怎么样」的说法。

试一试

1 哪一个改动能把一个视频模型变成你可以操控的东西？

- a. 更多参数
- b. 让每一帧的生成同时以一个动作、以及之前那些帧为条件
- c. 更高的分辨率
- d. 更长的上下文窗口

答案 b. 让每一帧的生成同时以一个动作、以及之前那些帧为条件。没有动作输入，就只有一个未来可选：模型认为最可能的那一个。有了它，同一个起点有多少种可能的做法，就有多少种续接。

2 你转回身，生成出来的房间还是你离开时的样子。是什么把它按在那里的？

- a. 画面背后存着的几何结构
- b. 内存里的一份物体清单
- c. 什么都没有。模型只是很擅长一致地接着画，而这是「接得好」的一部分
- d. 一个单独的持久化模块

答案 c. 什么都没有。模型只是很擅长一致地接着画，而这是「接得好」的一部分。那些帧背后并没有一个场景。一致性是一个训练良好的系统的统计性质，而这比「把它存下来」要奇怪得多。

3 生成视频里掉落的物体会向下加速，而没有人提供过重力。这确立了什么？

- a. 模型学会了万有引力定律
- b. 这个规律就在训练素材里，而要把素材预测好就必须复现它
- c. 模型里含着一个物理引擎
- d. 什么也没确立

答案 b. 这个规律就在训练素材里，而要把素材预测好就必须复现它。这个观察是真的。问题在于：在你训练过的范围里复现一个规律，算不算掌握了那条规律；而光凭这个观察定不下来。

4 图 8.2 里，模型在它训练过的那一段范围里误差只有几个百分点。为什么这不算它掌握了规律的证据？

- a. 测量不可靠
- b. 在范围里对得上，同样也与「它记住了被问过那些问题的答案」相容
- c. 几个百分点的误差太大了
- d. 那段范围太窄

答案 b. 在范围里对得上，同样也与「它记住了被问过那些问题的答案」相容。「掌握规律」和「在采样过的区域里拟合得好」只有在范围之外才分得开，而范围之外正是没人去测的地方，因为那里没有素材可以对照。

5 为什么生成视频世界的形状不适合智能体在里面做规划？

- a. 它不够准
- b. 规划意味着把模型跑很多遍，而一帧画面是「紧凑状态」的反面
- c. 它没法以动作为条件
- d. 它没有奖励信号

答案 b. 规划意味着把模型跑很多遍，而一帧画面是「紧凑状态」的反面. 规划器需要便宜地试很多条动作序列并打分。这些模型跑起来很贵，而且产出的是画面，不是一个小到可以推理的东西。

6 目前生成出来的世界，毫无争议地擅长什么？

- a. 取代物理引擎
- b. 产出训练数据，以及当一个你可以在里面走动的地方
- c. 长时程规划
- d. 压缩视频

答案 b. 产出训练数据，以及当一个你可以在里面走动的地方. 它们瞬间重置，跑起来不花钱，还能产出无穷的变体。而且这门课里没有别的路数能给你一张真正能走进去的画面。

7 为什么这类系统给出的错误答案，比一个错误的数字更让人信服？

- a. 它的误差更小
- b. 它是以一张长得像照片的东西的形式出现的
- c. 这些模型的置信度校准得更好
- d. 它通常并没有错

答案 b. 它是以一张长得像照片的东西的形式出现的. 这里的外推问题就是任何拟合函数都会有的普通问题。不一样的地方在于：它失败的时候，输出有多有说服力。

8 关于这些系统「在进步」的说法很难核实。为什么？

- a. 模型是闭源的
- b. 目前没有公认的方法去衡量一个生成出来的世界表现得好不好
- c. 改进幅度太小
- d. 没有人公布结果

答案 b. 目前没有公认的方法去衡量一个生成出来的世界表现得好不好. 没有一个大家认的分数，「进步了」这类说法大多就是「输出在说这话的人眼里看起来怎么样」。

FIG. 8.3 八道关于那个动作和那个论断的题。中间三道是在一个演示很唬人的时候，值得当心的那几道。

这就把我们带到了这个主题里通常不会写进发布公告的那部分。

多谢阅读。第 9 章是一次诚实的清算：什么会漂、什么会被忘掉、什么问不出来，以及为什么目前没有人能告诉你这些系统里哪一个最好。

参考资料

Genie: Generative Interactive Environments BRUCE ET AL., 2024 ↗

可以用动作操控的生成环境。

<https://arxiv.org/abs/2402.15391>

Genie 3 GOOGLE DEEPMIND, 2025 ↗

报告称能在多分钟的交互里回想起先前见过的细节。

<https://deepmind.google/blog/genie-3-a-new-frontier-for-world-models/>

Diffusion Models Are Real-Time Game Engines (GameNGen)

VALEVSKI ET AL., 2024 ↗

DOOM 被逐帧地从此前的帧和输入里生成出来，快到可以玩。最清楚地说明了这类东西是可玩的，而不只是可看的。

<https://arxiv.org/abs/2408.14837>

How Far is Video Generation from World Model: A Physical Law Perspective

KANG ET AL., 2024 ↗

图 8.2 的实测版本。视频模型在训练分布之内符合物理规律，出了这个范围就不会外推。

<https://arxiv.org/abs/2411.02385>

Video generation models as world simulators OPENAI, 2024 ↗

让「涌现出物理」这个说法进入主流的那份报告。值得读一读它究竟主张了什么、又没主张什么。

<https://openai.com/index/video-generation-models-as-world-simulators/>

Cosmos World Foundation Model Platform for Physical AI NVIDIA, 2025 ↗

把生成视频当作机器人和车辆的训练数据来造，而这正是这类系统毫无争议地擅长的用途。

<https://arxiv.org/abs/2501.03575>

Cosmos NVIDIA ↗

一个边界案例：预测式视频世界与显式仿真并置。

<https://www.nvidia.com/en-us/ai/cosmos/>

FIG. 8.4 排序是给要在这上面接着做事的人用的，而不是为了历史完整性。