

08 视频模型是世界模拟器吗？

作者 NILUSHANAN KULASINGHAM

阅读约 13 分钟 · 可交互

给视频模型加上动作输入，只是让它原则上可以被操控。从 Genie 到 Genie 3：怎样区分条件与控制、放大了什么，以及为什么拟合物理不等于掌握规律。

本章的图都是可交互的。请到 worldmodels101.com/zh/chapters/video-worlds 在线按一按、拖一拖。

最近只要看过 AI 生成的视频，你多半见过有人用方向键在一个场景里走来走去。2024 年之前，视频模型是拿来看的东西。它自己挑好自己的未来，你插不上嘴。多出一个输入，这件事就变了。

拿一个预测下一帧的模型。现在，除了那些帧之外，再告诉它此刻按住的是哪个键。同一个开头，它就能在按左时给你一种续接，在按右时给你另一种。下面这幅图你可以自己试试，留意每一帧到底是谁挑的。




FIG. 8.1 取下一帧的两种方式。开关留在「看」上，按一下「下一帧」：由模型来挑，从头再来一遍，给你的还是同一段。切到「操纵」，你按的方向键会和那些帧一起送进去，于是你拿到的就是你要的那一帧。留意下面那笔账，每一帧到底是谁挑的。片段仅作参考。

2024 年，Google DeepMind 的 Jake Bruce 和同事用 Genie 走了这一步。他们的论文叫 *Genie: Generative Interactive Environments*。Genie 是在 2D 平台游戏的录像上训练的，马里奥和它的后辈们，而它把这些录像变成了你可以操纵的世界。没有人标注过按键。

模型只能用少数几个编码去解释相邻两帧之间的每一次变化。它最后定下来的那几个编码，行为就像一个手柄。Genie 还把两支各自长大的家族凑到了一起：为智能体造的世界模型（第 5 章和第 6 章）和为观众造的视频模型。

FIG. 8.2 这就是那个把戏的缩小版。模型看到的是一对一对的帧，没有按键，它得把每一次变化归到八个编码里的某一个下面。按一下「把变化分类」，看看那几堆：一个编码收走了所有的左移，另一个收走了所有的跳跃，而没有人告诉过它哪个是哪个。然后按一个编码，看它对一张新的帧做了什么。帧和编码都仅作示意。

一个带动作输入的视频模型，是一个你可以待在里面的地方，这是新东西。它算不算仿真器，也就是它听不听你的动作、守不守世界的规矩，那是要测出来的，而发布公告往往会跳过这一段。

有动作输入，不等于能控制

一个模型可以收到动作，却照样忽略它，或者只轻轻反应一下。它也可以让动作改变画面的样子，却不改变底下那条轨迹。想象一个方向盘，转得动，但什么都没连着。

所以可控性得测。固定起点，只改指令，再检查那些未来有没有按要求分开。我把它叫作方向盘检验，下面这幅图就是把这个检验画出来。




FIG. 8.3 每一行都从同一个起点出发，收到不同的指令。把动作当成输入喂给模型，这件事叫作条件化（conditioning）；模型照做到什么程度，叫作动作保真度。把保真度拖向零，你会看到几条轨迹收拢到一起，而输入始终都在。

你可以看到，输入可以一直都在，却几乎不起作用。这种失败正是我预料中的那一种。一个在录像上训练出来的模型，奖励来自把帧画对。如果录像里大部分时候是直行，那么不管按键说什么，直行都是个不错的赌注。

画面好看，会把控制很弱这件事盖住。如果三段漂亮的续接全都直行，那你看到的就是视频。一个规划器要的是三个反事实，也就是从同一个起点出发的三个「要是会怎样」，结果拿到的是同一个东西发了三遍。

从观看，到走进去

放大带来的东西比大多数人预期的要多，包括造它的那些人里的大多数。我们来看标志着这个转变的两个系统。

GameNGen 来自 Google Research 的 Dani Valevski 和同事，2024 年。他们的论文叫 *Diffusion Models Are Real-Time Game Engines*。扩散模型（diffusion model）画一张图的办法，是从噪声出发，一步一步把它清理干净。GameNGen 用一个扩散模型跑起了 DOOM，也就是九十年代初那款第一人称射击游戏。




FIG. 8.4 这是一个扩散模型生成一帧游戏画面的过程。左边是条件：之前的几帧，还有正按住的那个键。按一下「去噪」，看着噪声一步一步变成一帧画面。然后把「每帧步数」往下拖，读一读每秒帧数：步数越少越快，也越糙，而在这个滑块的某个位置上，观看就变成了游玩。画面和耗时仅作示意。

它用之前的帧和玩家的输入生成每一帧，快到可以玩。作者报告说，看短片的人很难把它和真游戏分开。

Genie 3 是 Google DeepMind 一年后的作品，从它开始，那些数字不再像演示。据报道，它能以 720p、每秒 24 帧生成可交互的视频。

这些数字是 DeepMind 对自家系统的报告，实验室之外没有人复现过。我会说这在这里是常态，而不是在贬低谁。

据说它能让一个场景连贯地撑上好几分钟，还能在中途接受指令：换个天气，加一群鸟。从一样东西旁边走开，再走回来，它大致还是你离开时的样子。看看下面这段片子，就盯着这一点看。




FIG. 8.5 DeepMind 自己发布的 Genie 3 片段。留意镜头转开又转回来的那些时刻，然后问问自己你到底被展示了什么。场景大致还是原样，而界面里没有任何东西能让你打开看看是什么把它留在那儿的。片子里的一切都是实验室自己的报告，包括我上面引的那些数字。

公开接口里没有可供查看的场景三维布局，也没有物体清单。可是 DeepMind 说，Genie 3 能回看自己走过的路径，并把视觉信息保留约一分钟。支撑这件事的状态，不管它是什么，都藏在生成器里面。


不到两年，这个领域从操纵一个模糊的平台游戏，走到了在一个照片般真实、还记得你过去哪儿的场景里走动。放大并没有给你任何可以打开来读的东西。

涌现出物理，以及素材用完的地方

你会看到有人对这里的每一个系统都下这个论断。OpenAI 2024 年的报告 *Video generation models as world simulators* 让「涌现出物理」这个说法流行开来。它是 Sora 的说明文，Sora 是 OpenAI 自己的视频生成器。传开的主要是那个标题，而标题里的论断，把一个观察和一个结论捆在了一起。

那个观察是真的。在足够多的视频上训练，输出就开始尊重一些没有人放进去的规律。掉落的物体会越落越快，水会积起来而不是堆起来，被挡住的东西在前面那个挪开之后会重新露出来。没有人提供过任何方程；这些规律就在训练素材里，而要把素材预测好，就得把它们照抄过来。

训练片段



帧间距一帧比一帧大

一次新的下落



已给出

模型续上的

提供的方程

0

帧间距

. . . .

与素材一致

尚未

FIG. 8.6 左边是训练片段，每一段都是一样东西被放下，每一段都在下落途中越来越快。右边按一下「续上」，模型会补完一次它没见过的下落。它同样越落越快，而图里哪儿都没有方程。现在把「素材」切到编造的那一种，东西以匀速下落，再按一次「续上」。规律跟着素材走。数字仅作参考。

结论才是麻烦开始的地方。「它学会了物理」说的是模型掌握了那条规律，而这件事是可以测的。要测的从来不是它在训练素材那一类东西上输出得对不对。

Bingyi Kang 和同事在 2024 年做了一次这样的测试，论文叫 *How Far is Video Generation from World Model: A Physical Law Perspective*。他们在小球运动和碰撞的简单仿真场景上训练视频模型，然后去问素材里从没出现过的速度。图 8.7 把那个测试跑了两遍：一遍用素材覆盖到的速度，一遍用素材以外的速度。




FIG. 8.7 这就是那个测试，画成一张成绩单。每一格是一个场景，按速度排开，底色深的那几格是素材覆盖到的速度。按一下「评分」，再把测试集换成素材结束之后的那些场景，重新评一次。同一个模型，同一套流程，变的只有场景是从哪儿取的。速度和误差仅作参考。

范围之内的一切，都跟「它学会了物理」相容。它跟「它学会了被问到的那些问题的答案」同样相容，而 Kang 那一组的结论是，他们的模型做的是后者：把每个新场景匹配到最像它的那些训练场景，再把那里发生的事照搬过来。没有人去范围之外测，因为那里素材已经用完了。我把这个叫作范围问题。

所以站得住脚的论断要窄得多。这些系统在它们训练过的那些情形里，复现了大量的物理规律。这算不算掌握了规律，你见过的任何演示都定不下来，因为它们全都在范围之内。

范围问题不是视频独有的，任何拟合出来的函数都有。它在这里之所以感觉不一样，只是因为一个长得像照片的错误答案能说服人，而一个错误的数字永远做不到这一点。

它们是用来干什么的

这些都不构成不用它们的理由。用「它没学会物理」推出「所以它是个玩具」，是反过来那种错误，我见到的次数几乎一样多。

用来训练别的系统，一个生成出来的世界很有用。它避开了和真实环境的接触，改成付 GPU 时间。它可以立刻重置，还能给出一千个版本的场景，而这些场景真要搭起来得花一周。下面这幅图里的按钮多按几下，你就明白我的意思了。




FIG. 8.8 同一个场景，两种拿到更多版本的办法。左边是一个真实的布景：按一下「再来一个」，一天过去，一个新版本到手。右边是一个生成的世界：按一下「再来一个」，画一帧的工夫就出来一个版本，光照、杂物和相机都换过了。两边都按一下「重置」，看看哪一个先就绪。数量和耗时仅作参考。

英伟达为这件事造了 Cosmos，而这些模型大多是在它的芯片上训练的。Cosmos 是一组视频生成器。2025 年的论文叫 *Cosmos World Foundation Model Platform for Physical AI*。它生成有物理感的视频，当作机器人和车辆的训练数据，而这两处真实数据最贵。

英伟达把 Cosmos 和自家那些显式的、手工搭建的仿真器放在同一个平台上卖，也没有宣布哪一个会取代哪一个。我会把这当成一个关于目前进展到哪一步的暗示。

用来当一个你可以在里面走动的世界，它们已经很好了。没有别的路数能让你走进画面里去。我觉得这件事比怀疑的人承认的更值钱，也比发布会暗示的更不值钱。

用来当智能体在里面做规划的模型，原始的视频生成器形状很别扭。规划器可能要给一百条动作序列打分，而把每一条都渲染出来很贵。系统可以改成蒸馏出一个学到的潜变量，也就是一小串代替那些帧的内部编码，然后就在里面规划。



FIG. 8.9 规划器得先给很多条动作序列打分，才能挑出一条。把序列数往上拖，看那两张账单。在像素里规划要把每条序列的每一帧都渲染出来，它那根条会冲出图表。在潜变量里规划，用一小串编码代替每一帧，给同样这些序列打分只花零头，而且只有选中的那一条会被画出来。开销仅作示意。

缝隙在哪里

有三条缝，演示可能在那里把你带偏。

一致性是学出来的，不是被强制的。没有任何东西阻止这个房间发生变化，而它通常不变。可是「通常」是一个训练好的系统的统计性质，而保证是一台引擎的性质。






FIG. 8.10 一个房间，一扇门，每按一次就是走开再走回来。按几次「再来一次」，门都还在原处，这就是「通常」的样子。接着按下去，总会有那么一次，门回来的时候换了地方。再把开关拨到「由引擎存着这个场景」，就没有什么还能坏了。这个失败率仅作示意。

有意思的时刻正是模糊的那些。一个在像素上训练的模型，只要未来还是开放的，就会被推向各个可能未来的平均值。第 7 章里我们看过那个平均值长什么样：一张不可能发生的事的画面。


未来最开放的时候，就是有事要发生的时候。所以方向盘检验最难通过的地方，恰恰是通过它最要紧的地方。在下面这幅图里沿着片段一个时刻一个时刻走过去，你就明白为什么了。



两者本该差多远



两者实际差多远



时刻	这里的利害	是否服从
1 / 6	几乎没有	服从了，但无关紧要

FIG. 8.11 一段中间有岔路的片段，在沿途每一个时刻都跑一遍方向盘检验。逐个时刻走过去，读那两根条：两个指令本该差出多远，实际又差出了多远。在走廊里它听话，而那里也没什么可争的。到了岔路口，两个指令给出的结果叠在了一起。时刻和数字都仅作示意。

分数没法合起来。基准会分别测画面质量、几何、动作保真度和持久性。没有公认的规则能把它们合成一个排名。

所以我不会告诉你 Genie 3 是不是比 GameNGen 强。一个关于进步的说法，只属于某一项具体的检验。把下面这几个尺度点一遍，看着赢家换来换去。



FIG. 8.12 分数是编的，系统也不是真的，但这种彼此打架是真的。把四个尺度点一遍，看着赢家换来换去。没有公认的办法把它们合成一个排序，所以「更好」永远只意味着在其中某一项上更好。

那么，视频模型是世界仿真器吗？我的答案是：它们是一个你可以待在里面的地方，这是新的，也是真的。它听不听你的，以及它守的是规律还是素材，是两次分开的测量，而你看到的那个演示，两次都没做。要求做方向盘检验，然后问一句范围之外是什么。

希望这一章对你有帮助。下面有一个小测验，想检查一下这些想法有没有留住，可以做一做。如果我哪里写错了，或者你知道比我用的更好的来源，「关于」页有一节讲更正，我很乐意收到你的消息。

试一试

1 哪一个改动能让视频模型具备被操控的可能，却不能证明它会听话？

- a. 更高的分辨率
- b. 更长的上下文窗口
- c. 更多参数
- d. 让每一帧的生成同时以一个动作、以及之前那些帧为条件

答案 d. 让每一帧的生成同时以一个动作、以及之前那些帧为条件. 动作条件提供的是接口。可控性仍要固定起点、只改变动作，再测所要求的未来是否真的分开。

2 你转回身，生成出来的房间还是离开时的样子。关于它的记忆，你能推出什么？

- a. 某种内部状态支撑着持久性，但这个行为看不出它是场景图、上下文还是别的机制
- b. 它一定用了单独的物体数据库
- c. 里面一定有可导出的几何结构
- d. 它没有任何形式的记忆

答案 a. 某种内部状态支撑着持久性，但这个行为看不出它是场景图、上下文还是别的机制。这个行为证明了持久性，没有证明实现方式。据称 Genie 3 会参照此前轨迹，但没有暴露可检查的持久几何结构或物体存储。

3 生成视频里掉落的物体会向下加速，而没有人提供过重力。这确立了什么？

- a. 什么也没确立
- b. 模型学会了万有引力定律
- c. 这个规律就在训练素材里，而要把素材预测好就必须复现它
- d. 模型里含着一个物理引擎

答案 c. 这个规律就在训练素材里，而要把素材预测好就必须复现它. 这个观察是真的。问题在于：在你训练过的范围里复现一个规律，算不算掌握了那条规律；而光凭这个观察定不下来。

4 图 8.7 里，模型在它训练过的那一段范围里误差只有几个百分点。为什么这不算它掌握了规律的证据？

- a. 测量不可靠
- b. 在范围里对得上，同样也与「它记住了被问过那些问题的答案」相容
- c. 几个百分点的误差太大了
- d. 那段范围太窄

答案 b. 在范围里对得上，同样也与「它记住了被问过那些问题的答案」相容。「掌握规律」和「在采样过的区域里拟合得好」只有在范围之外才分得开，而范围之外正是没人去测的地方，因为那里没有素材可以对照。

5 为什么生成视频世界的形状不适合智能体在里面做规划？

- a. 它没法以动作为条件
- b. 它没有奖励信号
- c. 它不够准
- d. 规划意味着把模型跑很多遍，而一帧画面是「紧凑状态」的反面

答案 d. 规划意味着把模型跑很多遍，而一帧画面是「紧凑状态」的反面. 规划器需要便宜地试很多条动作序列并打分。这些模型跑起来很贵，而且产出的是画面，不是一个小到可以推理的东西。

6 目前生成出来的世界，毫无争议地擅长什么？

- a. 产出训练数据，以及当一个你可以在里面走动的地方
- b. 长时程规划
- c. 压缩视频
- d. 取代物理引擎

答案 a. 产出训练数据，以及当一个你可以在里面走动的地方. 它们避开真实世界接触、能瞬间重置并产出广泛变体，但仍然要付计算代价。而且这门课里没有别的路数能给你一张真正能走进去的画面。

7 为什么这类系统给出的错误答案，比一个错误的数字更让人信服？

- a. 它通常并没有错
- b. 它的误差更小
- c. 它是以一张长得像照片的东西的形式出现的
- d. 这些模型的置信度校准得更好

答案 c. 它是以一张长得像照片的东西的形式出现的. 这里的外推问题就是任何拟合函数都会有的普通问题。不一样的地方在于：它失败的时候，输出有多有说服力。

8 一个系统的几何分数提高了，动作保真度却下降了。它综合来看更好吗？

- a. 是，几何是唯一客观尺度
- b. 除非先声明用途或给出合并各维度的规则，否则答不了
- c. 不是，动作保真度永远更重要
- d. 是，任何基准上涨都证明综合进步

答案 b. 除非先声明用途或给出合并各维度的规则，否则答不了. 现在的基准已经能测几个有用维度。没解决的是：当不同系统和用途重视不同契约时，该怎么把它们合起来。

FIG. 8.13 八道关于那个动作和那个论断的题。如果你刚被一个演示唬住，直接看中间那三道。

参考资料

Genie: Generative Interactive Environments BRUCE ET AL., 2024 ↗

可以用动作操控的生成环境。

<https://arxiv.org/abs/2402.15391>

Genie 3 GOOGLE DEEPMIND, 2025 ↗

报告称能在多分钟的交互里回想起先前见过的细节。

<https://deepmind.google/blog/genie-3-a-new-frontier-for-world-models/>

Diffusion Models Are Real-Time Game Engines (GameNGen)

VALEVSKI ET AL., 2024 ↗

DOOM 被逐帧地从此前的帧和输入里生成出来，快到可以玩。最清楚地说明了这类东西是可玩的，而不只是可看的。

<https://arxiv.org/abs/2408.14837>

How Far is Video Generation from World Model: A Physical Law Perspective

KANG ET AL., 2024 ↗

图 8.7 的实测版本。视频模型在训练分布之内符合物理规律，出了这个范围就不会外推。

<https://arxiv.org/abs/2411.02385>

Video generation models as world simulators OPENAI, 2024 ↗

让「涌现出物理」这个说法进入主流的那份报告。值得读一读它究竟主张了什么、又没主张什么。

<https://openai.com/index/video-generation-models-as-world-simulators/>

Cosmos World Foundation Model Platform for Physical AI NVIDIA, 2025 ↗

把生成视频当作机器人和车辆的训练数据来造，而这正是这类系统毫无争议地擅长的用途。

<https://arxiv.org/abs/2501.03575>

Cosmos NVIDIA ↗

一个边界案例：预测式视频世界与显式仿真并置。

<https://www.nvidia.com/en-us/ai/cosmos/>

FIG. 8.14 排序是给要在这上面接着做事的人用的，而不是为了历史完整性。Kang 那篇和 OpenAI 的报告放在一起，一个是论断，一个是测量。