

09 哪些地方还不行

作者 NILUSHANAN KULASINGHAM

阅读约 13 分钟 · 可交互

场景不是一下子全垮的，不同系统也会在不同契约下失败。该测什么、哪些基准结论能合起来、哪些不能：到这里做一次总整理。

到这里为止，每一章的结尾都留下了一件还做不到的事。

这一章把它们收拢起来。这些系统能做到的和那些发布公告暗示的之间的差距，正是这个主题里大部分混乱的所在。而知道什么是坏的，就是「在读一篇论文」和「正在被推销」之间的区别。

推演不是一下子全垮的

整段推演的平均误差，会把不同的失败压成一个数。身份可以在纹理仍清晰时坏掉；动作保真度可以在两者看起来都正常时坏掉。顺序取决于系统和任务，所以有用的报告不是一个时程，而是一组针对不同性质的时程。




FIG. 9.1 这是诊断性的思想实验，不是基准结果。图中的顺序只是一种可能的失败轮廓，用来暴露平均值藏掉的东西。另一个模型可能先丢物理、后丢身份，也可能把布局保留更久。拖动时程，留意「看起来还好」和「仍能支撑任务」不是同一句话。

在这个构造出来的轮廓里，颜色和纹理比身份与物理行为活得久。这个顺序并不普遍。逐帧损失会直接奖励表面和光，而持久性必须跨时间推断。

这跟你想要的顺序正好相反，而且这不是巧合。一个逐帧计算的损失，奖励的是把大部分像素弄得大致正确，而大部分像素是表面和光。那个损失里没有任何东西在盯着你刚走过的那把椅子是不是同一把。

所以一段推演可以在越过「还能用」这条线一百步之后，单看任何一帧都还完全没问题。这就是这个主题里最容易骗到自己的那种方式。

反复出现的那三件事

东西不再是它自己了。物体恒存是大家都会注意到的那一个。对于没有暴露物体存储的渲染器，身份由预测器的隐藏状态携带，而不是由持久记录强制。它会逐渐退化，椅子变成另一把椅子时也不会报错。结构化仿真器可以显式保存物体；代价是那份结构必须先被正确定义或学出来。

「如果」其实拿不到。模型能告诉你接下来大概会发生什么。问「如果你当时做了别的会怎样」是另一个问题，而你拿到的答案，是在模型内部为真，而不是关于世界为真。在模型有数据的地方，两者很接近。在它没有数据的地方就不接近，而答案本身不会提示你现在是哪一种情况。

这一条容易被低估，因为模型总会给你一个答案。一个会说「我从没见过类似的东西」的系统会更有用，也更不唬人，而没有人会因为造出它而得到奖励。

长时程仍然是那个卡住一切的约束。这门课里的每一个技巧，往刻薄了读，都是「让你不需要模型正确太久」的办法：短推演、重新规划、从真实状态出发。它们管用。它们同时也等于一句承认：这东西撑不住；而它能撑住的那段时程，正是决定你能造出什么的那个数字。

没有公认的综合赢家

这是最该让你不安的部分，而它得到的关注最少。

基准现在会直接检验生成世界是否正常工作。2026 年 8 月发布的 PlayWorld 用 171 个场景分别检验几何、交互保真度，以及物体离开和重返视野时发生什么。另一些套件更重视感知视频质量。仍然缺少的，是把这些不同契约变成一个总排序的公认办法。



FIG. 9.2 这些分数是编的，这些系统也不是真的。分歧是真的，而且没有公认的办法把这几种尺度合成一个排序。把四个都点一遍，看着赢家换来换去。

画面质量是可测的，也是演示的用料。世界在一千步里撑不撑得住，是智能体需要的，而没有任何演示长到能展示它。你给的动作是不是它执行的动作，是世界模型和视频之间的差别，而这几乎从来没人报告。开销决定了有没有东西负担得起在里面做搜索，而它被报告得最少。

下游任务成功率看起来像是那个诚实的答案，而它有自己的问题。它把模型和策略一起打分。一个好的策略能盖住一个差的模型，而那个数字不会告诉你你手里是哪一个。

进步是真的。在说清尺度和系统契约之前，「更好」这句话还没说完。

让失败检验匹配系统

这个词底下是五种不同的机器，它们不该参加同一场考试。渲染器的命门是持久性和动作保真度。仿真器是最好查的那一个，因为它导出的结构别的程序能打开核对。紧凑动力学模型的命门是推演时程，以及规划搜索能否钻它的漏洞。一个表征可以很稳定，却丢掉任务需要的变量。内隐模型则需要一种真能证伪「里面有模型」这个说法的探针。



FIG. 9.3 五种系统契约，交叉五类失败问题。格子的强弱是编辑判断，不是基准分数。选择一行，看看哪道题最常卡住这类系统。把「世界模型质量」压成一根轴，会把这五类问题全藏掉。

下面四个问题仍然能应付大部分论文：

它输出什么？ 一张画面、一份结构、一个紧凑状态，还是一个嵌入。这决定了它被用来干什么，而不先问清这个，后面几乎什么都推不出来。

你能不能在没人执行过的动作下把它往前推？ 如果不能，那不管它看起来多好，它都撑不起一个决定。

它能撑住多长的时程，以及是谁测的？ 这个数字比架构更要紧，而它通常是缺的。

这个说法用的是哪个尺度，而那个尺度忽略了什么？ 没有一个综合分数。任何暗示有的人，都是挑了一个，并且没告诉你。

这几道题会逼一篇论文说清输出、证据，以及结论能撑住多长的时程。只知道架构名字，做不到这些。

试一试

1 为什么一个平均误差不足以报告长推演？

- a. 不同性质可能在不同的时程坏掉，而平均值藏住了丢掉的是哪份契约
- b. 误差的单位不对
- c. 推演太短，平均不出来
- d. 平均值总是误导人的

答案 a. 不同性质可能在不同的时程坏掉，而平均值藏住了丢掉的是哪份契约. 不存在普遍的失败顺序。重点是分别报告身份、物理、控制和外观的时程，不让一个强项遮住另一个弱项。

2 一段推演单看任何一帧都还完全没问题。这说明了什么？

- a. 还没到时程上限
- b. 它还能用
- c. 说明不了多少。大部分像素是表面和光，而逐帧损失里没有任何东西在盯着物体有没有还是它自己
- d. 模型学会了物理

答案 c. 说明不了多少。大部分像素是表面和光，而逐帧损失里没有任何东西在盯着物体有没有还是它自己. 这正是这个主题里最容易骗到自己的方式，也是为什么演示作为证据比它给人的感觉要弱。

3 为什么物体恒存对没有暴露物体存储的渲染器格外脆弱？

- a. 遮挡的计算开销很大
- b. 训练数据里缺少被遮挡的物体
- c. 模型太小了
- d. 身份由预测器状态隐式携带，而不是由持久记录强制

答案 d. 身份由预测器状态隐式携带，而不是由持久记录强制. 结构化仿真器可以显式存物体；对渲染器来说，持久性是推断出的行为而不是可检查的记录，所以身份可能逐渐漂掉。

4 你问模型「如果当时做了别的会怎样」。你拿到的是什麼？

- a. 一个关于世界的事实
- b. 一个在模型内部为真的答案，而且里面没有任何东西提示模型在那里有没有数据
- c. 一个证明
- d. 什么也没有，模型答不了这种问题

答案 b. 一个在模型内部为真的答案，而且里面没有任何东西提示模型在那里有没有数据. 在模型有数据的地方两者接近，没数据的地方就不接近，而模型两种情况下都同样自信地作答。

5 短推演、重新规划、从真实状态出发，这些都管用。它们的共同点是什么？

- a. 它们都是「让你不需要模型正确太久」的办法
- b. 它们只适用于机器人
- c. 它们去掉了对策略的需要
- d. 它们让模型更准

答案 a. 它们都是「让你不需要模型正确太久」的办法. 往刻薄了读，这整套工具就是一句承认。模型能撑住的那段时程，正是决定你能造出什么的那个数字。

6 为什么下游任务成功率定不了「哪个模型更好」？

- a. 它只在模拟里有效
- b. 任务太简单
- c. 它把模型和策略一起打分，于是一个好策略能盖住一个差模型
- d. 它没法可靠地测量

答案 c. 它把模型和策略一起打分，于是一个好策略能盖住一个差模型. 它看起来像是那个诚实的答案，而它恰好把你本想分开的那两样东西混在了一起。

7 一个基准赢家的几何最好，动作保真度却一般。第一句该问什么？

- a. 它跑在什么硬件上
- b. 它训练了多久
- c. 它有多大
- d. 用的是哪个尺度，而那个尺度忽略了什么

答案 d. 用的是哪个尺度，而那个尺度忽略了什么. PlayWorld 一类基准会把有用维度分开。它们不会替你决定具体用途重视哪份契约，也不会自动给互相竞争的维度一个合并规则。

8 面对一个不熟悉的系统，整门课里哪一个问题最顶用？

- a. 它有多少参数
- b. 它输出什么，以及你能不能在没人执行过的动作下把它往前推
- c. 它开不开源
- d. 它用不用 transformer

答案 b. 它输出什么，以及你能不能在没人执行过的动作下把它往前推. 前半句决定了它能被用来干什么，后半句决定了它撑不撑得起一个决定。几乎其他一切都由此而来，而这两者都不需要你知道架构。

FIG. 9.4 八道关于「诚实现状」的题。如果你读完了整门课，最后一道应该很容易，而且有点让人不爽。

这门课到这里就结束了。

九章之前，这个词指着五种不同的东西，而没有人说清是哪一种。现在仍然如此。变了的是：你已经能分辨出摆在桌上的是哪一种，以及要让那个说法成立需要什么。还有当对方不说的时候，该问什么。

多谢阅读。如果这里有哪里写错了，而且总会有，欢迎指正，并且一定会署名致谢。

参考资料

PlayWorld: A Benchmark for Interactive World Models ZHANG ET AL., 2026 ↗

面向可交互世界模型的新基准：171 个场景，分别测试几何、交互保真度，以及物体离开和重返视野时的演化。

<https://arxiv.org/abs/2608.13552>

How Far is Video Generation from World Model: A Physical Law Perspective

KANG ET AL., 2024 ↗

图 8.3 的实测版本。视频模型在训练分布之内符合物理规律，出了这个范围就不会外推。

<https://arxiv.org/abs/2411.02385>

VBench: Comprehensive Benchmark Suite for Video Generative Models

HUANG ET AL., 2023 ↗

对这个测量问题一次认真的尝试，也很适合用来看清：要拆到多少个互相独立的维度之后，排序才会变得不再显然。

<https://arxiv.org/abs/2311.17982>

Benchmarking Model-Based Reinforcement Learning WANG ET AL., 2019 ↗

基于模型的方法到底在哪里赢、在哪里输，以及「往前看多远」这个两难在哪里被命名和度量。

<https://arxiv.org/abs/1907.02057>

When to Trust Your Model: Model-Based Policy Optimisation

JANNER ET AL., 2019 ↗

从真实状态出发的短推演，直接回应累积误差和模型利用。标题就是这一章的问题。

<https://arxiv.org/abs/1906.08253>

Emergent World Representations LI ET AL., 2022 ↗

在 Othello-GPT 内部找到棋盘状态，并且能对它做因果干预。

<https://arxiv.org/abs/2210.13382>

Genie 3 GOOGLE DEEPMIND, 2025 ↗

报告称能在多分钟的交互里回想起先前见过的细节。

<https://deepmind.google/blog/genie-3-a-new-frontier-for-world-models/>

A Path Towards Autonomous Machine Intelligence LECUN, 2022 ↗

整个论点的出处，包括为什么对一个要去行动的系统来说，预测外观是错的活。

<https://openreview.net/forum?id=BZ5a1r-kVsf>

FIG. 9.5 排序是给要在这上面接着做事的人用的，而不是为了历史完整性。