

09 哪些地方还不行

作者 NILUSHANAN KULASINGHAM

阅读约 10 分钟 · 可交互

场景不是一下子全垮的，而活得最久的那些性质，恰好是逐帧打分会奖励的那些。什么会坏、按什么顺序坏，以及为什么没有人能告诉你这些系统里哪一个最好。

到这里为止，每一章的结尾都留下了一件还做不到的事。

这一章把它们收拢起来。这些系统能做到的和那些发布公告暗示的之间的差距，正是这个主题里大部分混乱的所在。而知道什么是坏的，就是「在读一篇论文」和「正在被推销」之间的区别。

推演不是一下子全垮的

报告一个模型能撑多久，通常的做法是给出整段推演的平均误差。这个数字几乎没用，因为一个场景的各种性质是按顺序坏掉的，而这个顺序不是你会猜到的那个。




FIG. 9.1 这些横轴刻度是对「顺序」的示意，而不是对任何具体系统的测量。不是示意的是它的形状：东西大致就按这个次序坏掉，而活得最久的那些，恰好是逐帧打分会奖励的那些。把滑块拖到几百步，然后读右下角。

颜色和光照几乎能一直稳住。纹理也撑得不错。最先没的，是「那还是刚才那个物体吗」，以及「东西的行为还像是有质量的吗」。

这跟你想要的顺序正好相反，而且这不是巧合。一个逐帧计算的损失，奖励的是把大部分像素弄得大致正确，而大部分像素是表面和光。那个损失里没有任何东西在盯着你刚走过的那把椅子是不是同一把。

所以一段推演可以在越过「还能用」这条线一百步之后，单看任何一帧都还完全没问题。这就是这个主题里最容易骗到自己的那种方式。

反复出现的那三件事

东西不再是它自己了。物体恒存是大家都会注意到的那一个，而值得说清楚它为什么难。这些系统里没有任何东西在存着一个物体。一致性是一个训练良好的预测器的性质，所以它会像预测退化那样退化：逐渐地、而且不打招呼。椅子变成另一把椅子的时候，不会有报错。

「如果」其实拿不到。模型能告诉你接下来大概会发生什么。问「如果你当时做了别的会怎样」是另一个问题，而你拿到的答案，是在模型内部为真，而不是关于世界为真。在模型有数据的地方，两者很接近。在它没有数据的地方就不接近，而答案本身不会提示你现在是哪一种情况。

这一条容易被低估，因为模型总会给你一个答案。一个会说「我从没见过类似的东西」的系统会更有用，也更不唬人，而没有人会因为造出它而得到奖励。

长时程仍然是那个卡住一切的约束。这门课里的每一个技巧，往刻薄了读，都是「让你不需要模型正确太久」的办法：短推演、重新规划、从真实状态出发。它们管用。它们同时也等于一句承认：这东西撑不住；而它能撑住的那段时程，正是决定你能造出什么的那个数字。

没有人能告诉你哪一个最好

这是最该让你不安的部分，而它得到的关注最少。

目前没有公认的办法去衡量一个生成出来的世界表现得好不好。有好几种互相不一致的办法，而一个在某一项上赢的系统，在另一项上经常就输了。



FIG. 9.2 这些分数是编的，这些系统也不是真的。真实的是这个结构：这几种尺度确实互相不一致，而且没有公认的办法把它们合成一个排序。把四个都点一遍，看着赢家换来换去。

画面质量是可测的，也是演示的用料。世界在一千步里撑不撑得住，是智能体需要的，而没有任何演示长到能展示它。你给的动作是不是它执行的动作，是世界模型和视频之间的差别，而这几乎从来没人报告。开销决定了有没有东西负担得起在里面做搜索，而它被报告得最少。

下游任务成功率看起来像是那个诚实的答案，而它有自己的问题：它把模型和策略一起打分。一个好的策略能盖住一个差的模型，而那个数字不会告诉你你手里是哪一个。

这些都不意味着没有进步。它们意味着：目前关于「进步了」的说法，都是关于「说这话的人挑了哪个尺度」的说法。

拿这些做什么

四个问题，它们合起来能应付你将要读到的大部分东西。

它输出什么？一张画面、一份结构、一个紧凑状态，还是一个嵌入。这决定了它能被用来干什么，而不先问清这个，后面几乎什么都推不出来。

你能不能在没人执行过的动作下把它往前推？如果不能，那不管它看起来多好，它都撑不起一个决定。

它能撑住多长的时程，以及是谁测的？这个数字比架构更要紧，而它通常是缺的。

这个说法用的是哪个尺度，而那个尺度忽略了什么？没有一个综合分数。任何暗示有的人，都是挑了一个，并且没告诉你。

这就是全部的工具。它不华丽，但它能带你读完一篇论文，比知道任何一种具体架构都管用。

试一试

1 为什么「整段长推演的平均误差」作为一份报告几乎没用？

- a. 平均值总是误导人的
- b. 场景的各种性质是按顺序坏掉的，而活得最久的恰好是逐帧打分会奖励的那些
- c. 误差的单位不对
- d. 推演太短，平均不出来

答案 b. 场景的各种性质是按顺序坏掉的，而活得最久的恰好是逐帧打分会奖励的那些。颜色和纹理几乎能一直稳住，物体身份最先没。所以在推演早已不能用之后很久，平均值仍然很低。

2 一段推演单看任何一帧都还完全没问题。这说明了什么？

- a. 它还能用
- b. 说明不了多少。大部分像素是表面和光，而逐帧损失里没有任何东西在盯着物体有没有还是它自己
- c. 模型学会了物理
- d. 还没到时程上限

答案 b. 说明不了多少。大部分像素是表面和光，而逐帧损失里没有任何东西在盯着物体有没有还是它自己。这正是这个主题里最容易骗到自己的方式，也是为什么演示作为证据比它给人的感觉要弱。

3 为什么物体恒存对这类系统格外难？

- a. 模型太小了
- b. 没有任何东西在存着一个物体；一致性是好预测器的性质，所以它会逐渐地、不打招呼地退化
- c. 遮挡的计算开销很大
- d. 训练数据里缺少被遮挡的物体

答案 b. 没有任何东西在存着一个物体；一致性是好预测器的性质，所以它会逐渐地、不打招呼地退化。椅子变成另一把椅子的时候不会有报错。这就是「一致性是学出来的、而不是被强制的」的含义。

4 你问模型「如果当时做了别的会怎样」。你拿到的是什麼？

- a. 一个关于世界的事实
- b. 一个在模型内部为真的答案，而且里面没有任何东西提示模型在那里有没有数据
- c. 一个证明
- d. 什么也没有，模型答不了这种问题

答案 b. 一个在模型内部为真的答案，而且里面没有任何东西提示模型在那里有没有数据。在模型有数据的地方两者接近，没数据的地方就不接近，而模型两种情况下都同样自信地作答。

5 短推演、重新规划、从真实状态出发，这些都管用。它们的共同点是什么？

- a. 它们让模型更准
- b. 它们都是「让你不需要模型正确太久」的办法
- c. 它们只适用于机器人
- d. 它们去掉了对策略的需要

答案 b. 它们都是「让你不需要模型正确太久」的办法。往刻薄了读，这整套工具就是一句承认。模型能撑住的那段时程，正是决定你能造出什么的那个数字。

6 为什么下游任务成功率定不了「哪个模型更好」？

- a. 任务太简单
- b. 它把模型和策略一起打分，于是一个好策略能盖住一个差模型
- c. 它没法可靠地测量
- d. 它只在模拟里有效

答案 b. 它把模型和策略一起打分，于是一个好策略能盖住一个差模型。它看起来像是那个诚实的答案，而它恰好把你本想分开的那两样东西混在了一起。

7 有人说他们的系统是目前最好的。第一句该问什么？

- a. 它有多大
- b. 用的是哪个尺度，而那个尺度忽略了什么
- c. 它跑在什么硬件上
- d. 它训练了多久

答案 b. 用的是哪个尺度，而那个尺度忽略了什么。没有综合分数。画面质量、长推演的一致性、听不听动作、开销，这几项确实互相不一致；任何暗示存在排序的人，都是挑了一个。

8 面对一个不熟悉的系统，整门课里哪一个问题最顶用？

- a. 它有多少参数
- b. 它输出什么，以及你能不能在没人执行过的动作下把它往前推
- c. 它开不开源
- d. 它用不用 transformer

答案 b. 它输出什么，以及你能不能在没人执行过的动作下把它往前推。前半句决定了它能被用来干什么，后半句决定了它撑不撑得起一个决定。几乎其他一切都由此而来，而这两者都不需要你知道架构。

FIG. 9.3 八道关于「诚实现状」的题。如果你读完了整门课，最后一道应该很容易，而且有点让人不爽。

这门课到这里就结束了。

九章之前，这个词指着五种不同的东西，而没有人说清是哪一种。现在仍然如此。变了的是：你已经能分辨出摆在桌上的是哪一种，以及要让那个说法成立需要什么。还有当对方不说的时候，该问什么。

多谢阅读。如果这里有哪里写错了，而且总会有，欢迎指正，并且一定会署名致谢。

参考资料

How Far is Video Generation from World Model: A Physical Law Perspective

KANG ET AL., 2024 ↗

图 8.2 的实测版本。视频模型在训练分布之内符合物理规律，出了这个范围就不会外推。

<https://arxiv.org/abs/2411.02385>

VBench: Comprehensive Benchmark Suite for Video Generative Models

HUANG ET AL., 2023 ↗

对这个测量问题一次认真的尝试，也很适合用来看清：要拆到多少个互相独立的维度之后，排序才会变得不再显然。

<https://arxiv.org/abs/2311.17982>

Benchmarking Model-Based Reinforcement Learning

WANG ET AL., 2019 ↗

基于模型的方法到底在哪里赢、在哪里输，以及「往前看多远」这个两难在哪里被命名和度量。

<https://arxiv.org/abs/1907.02057>

When to Trust Your Model: Model-Based Policy Optimisation

JANNER ET AL., 2019 ↗

从真实状态出发的短推演，直接回应累积误差和模型利用。标题就是这一章的问题。

<https://arxiv.org/abs/1906.08253>

Emergent World Representations

LI ET AL., 2022 ↗

在 Othello-GPT 内部找到棋盘状态，并且能对它做因果干预。

<https://arxiv.org/abs/2210.13382>

Genie 3

GOOGLE DEEPMIND, 2025 ↗

报告称能在多分钟的交互里回想起先前见过的细节。

<https://deepmind.google/blog/genie-3-a-new-frontier-for-world-models/>

A Path Towards Autonomous Machine Intelligence

LECUN, 2022 ↗

整个论点的出处，包括为什么对一个要去行动的系统来说，预测外观是错的活。

<https://openreview.net/forum?id=BZ5a1r-kVsf>

FIG. 9.4 排序是给要在这上面接着做事的人用的，而不是为了历史完整性。