

09 世界模型还有哪些地方不行？

作者 NILUSHANAN KULASINGHAM

阅读约 11 分钟 · 可交互

场景不是一下子全垮的，不同系统也会在不同契约下失败。到这里做一次总整理：该测什么、哪些基准结论能合起来、哪些不能。

本章的图都是可交互的。请到 worldmodels101.com/zh/chapters/whats-broken 在线按一按、拖一拖。

这门课里的每一个系统，讲到最后都停在一件还做不到的事上。我觉得这些失败应该放在一起看，因为围绕这个词的那些混乱，就是拿它们搭起来的。反复出现的有五件：持久性、动作、时程、目标和验证。每一件都是被一个不同的社群发现的，而每一件被测量的时间都很晚，或者根本没被测过。

第 1 章带你见过这个词可能指的五种机器：渲染器、仿真器、动力学模型、表征和内隐模型。

持久性

同一个物体离开视野再回来之后，还是它自己吗？

动作

不同指令是否稳定地产生各自对应的不同未来？

预测步长


它吃着自己的输出能跑多远，答案才不再足以支撑决策？

训练目标

训练目标允许丢掉或塌缩哪些信息？

可验证性

什么观测能证明它声称拥有的内部模型其实并不存在？



五个失败，五个社群。把日期从左读到右。

谁最先撞上它

点一张上面的卡片。

最早测量

点一张上面的卡片。

FIG. 9.1 五种失败摊开来放。点开其中一个，读它提出的问题、哪个社群最先撞上它，以及最早是什么时候有人把它测了出来。然后从左到右读一遍底下那排年份。奇怪的地方在顺序。

往下读之前，先把上面这五个都点一遍，留意每一类系统最先撞上的是哪一个。

推演不是一下子全垮的

我们先从推演说起，因为大部分失败都是在这里露头的。推演就是把模型的预测一步一步往前推，每一步都搭在上一步之上。通常报出来的是整段推演的一个平均误差。这会把好几种失败熔成一个数，也把它们发生的先后顺序藏了起来。

身份可以在纹理仍然清晰的时候就坏掉。动作保真度，也就是你给它的动作是不是它真正执行的那个动作，可以在这两样看起来都正常的时候坏掉。谁先坏，取决于系统和任务。所以有用的报告是每种性质各给一个时程：它各自撑住了多少步。



FIG. 9.2 两个模型，在一千步上的平均误差一模一样。把报告留在「一个数」上，你没有任何依据去挑其中一个。切到「每种性质各给一个时程」，读那两把尺：同一个平均值底下藏着两台不一样的机器。点开某一种性质，看它们在这一项上差多远。两条轮廓仅作示意。

在这两条轮廓里，颜色和纹理都比身份和物理行为活得久，而原因在损失函数上。逐帧计算的损失，奖励的是把大部分像素弄得大致正确，而大部分像素是表面和光。它里面没有任何东西在盯着你刚走过的那把椅子还是不是同一把。

结果就是我说的单帧不在场证明。一段推演已经越过「还能用」这条线一百步了，可你单看它的任何一帧，都还完全没问题。错误只有沿着整条序列看下去才会现形。

三件怎么修都还在的失败

东西不再是它自己了。物体恒存说的是：你回头再看的时候，一样东西还在那里，而且还是它自己。这是大家都会注意到的那一个失败，也是第 1 章那个回头测试本来想抓、却没抓住的那一个。

拿渲染器来说，它是一种输出画面的模型。它没有对象存储，所以身份是活在预测器的隐状态里的，也就是它在步与步之间带着走的那些数字。椅子变成另一把椅子的时候，是一点一点变过去的，而且不会报错。仿真器会把物体显式地存下来，但代价是那份结构得先弄对。




FIG. 9.3 拖动预测步长，然后单看其中任何一帧：边缘清晰、光照合理，挑不出毛病。现在沿着这一整条看过去。把开关留在「隐状态」上，椅子就会一点一点变成另一把椅子，而你指不出哪一帧是出错的那一帧。把它拨到「对象存储」，每一帧都是同一把椅子，因为这次是把存起来的对象读了回来。画面仅作示意。

「如果」其实拿不到。模型能告诉你接下来大概会发生什么。「要是你当时做了别的会怎样」是另一个问题，而做决定需要的恰恰是这一个。模型对这个问题给出的答案来自模型，不是来自世界。

Bingyi Kang 与合作者在 2024 年把这个差距测了出来，论文是 *How Far is Video Generation from World Model*。他们拿物理规律去考视频生成器，一部分落在训练数据之内，一部分落在训练数据之外。在数据之内，生成器守规律。在数据之外，它们破坏规律，而输出里没有任何东西告诉你，你现在处在哪一种情况。

我觉得这一条被低估了，因为模型总会给你一个答案。一个会说「我从没见过类似的东西」的系统会更有用，也更不唬人，而没有人会因为造出它而得到奖励。




FIG. 9.4 拿三个问题去问同一个生成器：一个是素材里有过的速度，一个刚刚越过它，还有一个跟素材完全不沾边。逐个走一遍，盯住那张答案卡。答案每次都给，画法一样，把握也一样，只有旁边那个石板色的结果会告诉你它什么时候错了。然后把「一个有用的系统会举的那面旗」打开，看它能拦下哪几个问题。速度和结果仅作参考。

长时程仍然是那个卡住一切的约束。基于模型的控制里，大部分技巧都是让你不需要模型正确太久的办法。时程是这五件事里最先被测出来的。测它的是那些必须照着模型的预测去行动的人，也就是强化学习那边。

Tingwu Wang 与合作者在 2019 年做了这件事，论文是 *Benchmarking Model-Based Reinforcement Learning*。他们把那些「学一个环境模型、再在里面做规划」的方法摆在一起跑。规划时程，也就是模型被信任的步数，决定了每种方法在哪里赢、在哪里输。

Michael Janner 与合作者在同一年给出了回答，标题到今天仍然就是那个问题：*When to Trust Your Model*。他们的答案是：只能信一小会儿，而且要从一个真实状态出发。短推演、每几步重新规划一次，之所以管用，是因为它们赶在模型漂掉之前就不再依赖它了。模型能撑住的那段时程，仍然决定着你能造出什么。




FIG. 9.5 Janner 的答案，做成了可以玩的。石板蓝那条路径是真实发生的事，朱红那条是模型想象出来的。把「重新规划前信任的步数」拖到三十，按一下「运行」：想象的路径离开了真实的路径，于是这个计划是为一个并不存在的世界做的。再把它拉回三，重新跑一次。这次规划器每几步就弹回真实状态，误差根本没有机会累积起来。数字仅作参考。

那张没人发得出来的排行榜

测量到来的顺序是反的，我想带你看一遍为什么。强化学习最先测了时程，因为一个信任了坏模型的智能体会输，而输会直接体现在分数上。接下来是做视频的人，他们测了自己测得了的东西，也就是帧。

VBench 出现在 2023 年，来自 Ziqi Huang 与合作者。它把生成的视频拆成几个维度分别打分，比如画面质量，还有东西动起来有多流畅。维度多到一定程度，排名就不再是显而易见的了。

去检验「你能进去动手、而不是只能在旁边看」的世界的基准，来得最晚。2026 年 8 月发布的 PlayWorld 检验 171 个场景，覆盖几何、交互保真度（一个动作有没有做到它该做的事），以及物体离开视野再回到视野时会发生什么。这就是持久性和动作，渲染器最先撞上的那两件失败，比时程晚了七年才被测。



FIG. 9.6 四个尺度，排两遍。左边按它们被报出来的频率排，右边按智能体有多需要它们排。按一个尺度，看它的连线画过去。几乎每一条线都是交叉的，我说「顺序是反的」，说的就是这件事。两份排序是我的判断，不是一次统计。

画面质量是可测的，也是演示的用料。世界在一千步里撑不撑得住，才是智能体需要的，而没有任何演示长到能展示它。动作保真度是世界模型和视频生成器之间的分界，而它几乎从来没人报告。开销被报告得最少。

这个顺序差不多正好是重要程度的倒序，因为好测的先被测了。下游任务成功率看起来像是绕开这件事的办法。但它把模型和策略一起打分，而一个好策略会盖住一个差模型。

进步是真的。Google DeepMind 2025 年的 Genie 3，据报道能保持数分钟的连贯。这是造它的实验室报出来的，用的是它自己挑的尺度。在说清尺度、以及连同尺度一起说清系统契约（也就是被主张的是五种机器里的哪一种）之前，「更好」这两个字什么都没说。

让失败检验匹配系统

这个词底下是五种机器，而在这段历史的大部分时间里，它们参加的是同一场考试。混乱就是从这儿来的。渲染器的命门是持久性和动作保真度，而它常见的失败方式就是单帧不在场证明。仿真器是最好查的那一个，因为它导出的结构，别的程序能打开来检验。

	持久性	动作保真度	长预测步长	目标质量	可验证性
渲染器					
仿真器					
动力学模型					
表征模型					
内隐模型					
面对渲染器，先问这个 同一个物体离开视野再回来之后，还是它自己吗？					
系统契约 渲染器			决定性问题 持久性		

FIG. 9.7 五种系统契约，交叉五类失败问题。格子的强弱是编辑判断，是我的判断，不是基准分数。选中一行，看看最常卡住这类系统的是哪道题，然后对着上面那一段读渲染器和仿真器这两行。接下来的三段会走完另外三行。把「世界模型质量」压成一根轴，会把这五类问题全抹平。

紧凑动力学模型预测的是一个小状态，不是像素。它取决于推演时程，也取决于规划搜索能不能钻它的漏洞。表征是一份学出来给别的东西用的嵌入，它可以看起来很稳定，却把任务需要的那个变量丢掉了。我把这个叫做目标问题：把错的东西预测得很好。

内隐模型是一个断言：在一个为别的活儿训练出来的网络内部，形成了一个模型。要检验它得用探针，也就是训练出来的第二个小网络，专门从第一个网络的内部读出某一个事实。Kenneth Li 与合作者在 2022 年演示了这需要什么，论文是 *Emergent World Representations*。

一个只被训练来预测黑白棋（Othello，一种用两面异色棋子下的棋）下一步走法的网络，在探针底下被发现，内部持有一幅棋盘的图像。探针本来完全可能什么都读不出来。



四个问题仍然能应付大部分论文，我就把它们留给你。第一个是：它输出什么？一张画面、一份结构、一个紧凑状态，还是一个嵌入，而后面三个问题都取决于这个答案。

第二个是：你能不能在没人执行过的动作下把它往前推？如果不能，那它看起来再好，也撑不起一个决定。

第三个是：它能撑住多长的时程，以及是谁测的？这个数字比架构更要紧，而它通常是缺的。

第四个是：这个说法用的是哪个尺度，而那个尺度忽略了什么？没有综合分数这种东西，所以任何暗示有的人，都是挑了一个尺度，并且没告诉你是哪一个。

Orrery

(虚构)

Orrery 只需一句提示，就能生成数分钟连贯的可探索视频。随便往哪里走，世界都跟着你。比我们发布过的任何东西都好。

☐ 它输出什么？

☐ 能不能在没人做过的动作下把它往前推演？

☐ 它能在多长的时间跨度上站得住，又是谁测的？

☐ 这个说法用的是哪种度量，又忽略了什么？

这些帖子和系统都是虚构的。

已回答	备注
0 / 4	按一个问题。

FIG. 9.9 把这四个问题拿去问三篇编出来的发布公告。先挑一篇，再挨个按下每个问题。公告答了的地方，答它的那些字会亮起来。没答的地方，你会得到「没有说明」，底下的计数器帮你记分。三篇都试一遍，你应该会发现最让人兴奋的那一篇答得最少。这些公告是编的，里面的系统也是。

Yann LeCun, 当时是 Meta 的首席 AI 科学家, 也是图灵奖得主, 他在 2022 年写下了关于这个目标最完整的陈述。那篇论文是 *A Path Towards Autonomous Machine Intelligence*, 它列出了一个世界模型要配得上这个名字得做到些什么。对着这四个问题读, 它就是一份「还缺什么」的清单, 而报出一个架构的名字, 这四个问题一个都答不了。

这门课到这里就结束了。这个词仍然指着五种不同的东西, 而用它的人仍然很少说清是哪一种。变了的是你这一边: 你现在能分辨出摆在桌上的是五种里的哪一种, 能说出要让那个说法成立需要什么, 也知道当对方不说的时候该问什么。

多谢你读到这里。希望这九章帮上了忙。下面有一个小测验, 你要是想确认这些想法有没有留下来, 可以做一下。如果这门课里哪个地方我写错了, 或者你知道比我用的更好的来源, 「关于」页面上有一节讲怎么指正。我很乐意收到你的消息。

试一试

1 为什么一个平均误差不足以报告长推演？

- a. 不同性质可能在不同的时程坏掉，而平均值藏住了丢掉的是哪份契约
- b. 误差的单位不对
- c. 推演太短，平均不出来
- d. 平均值总是误导人的

答案 a. 不同性质可能在不同的时程坏掉，而平均值藏住了丢掉的是哪份契约. 不存在普遍的失败顺序。重点是分别报告身份、物理、控制和外观的时程，不让一个强项遮住另一个弱项。

2 一段推演单看任何一帧都还完全没问题。这说明了什么？

- a. 还没到时程上限
- b. 它还能用
- c. 说明不了多少。大部分像素是表面和光，而逐帧损失里没有任何东西在盯着物体有没有还是它自己
- d. 模型学会了物理

答案 c. 说明不了多少。大部分像素是表面和光，而逐帧损失里没有任何东西在盯着物体有没有还是它自己. 这个主题就是这样骗到你的，也是为什么演示作为证据比它给人的感觉要弱。

3 为什么物体恒存对没有暴露物体存储的渲染器格外脆弱？

- a. 遮挡的计算开销很大
- b. 训练数据里缺少被遮挡的物体
- c. 模型太小了
- d. 身份由预测器状态隐式携带，而不是由持久记录强制

答案 d. 身份由预测器状态隐式携带，而不是由持久记录强制. 结构化仿真器可以显式存物体；对渲染器来说，持久性是推断出的行为而不是可检查的记录，所以身份可能逐渐漂掉。

4 你问模型「如果当时做了别的会怎样」。你拿到的是什麼？

- a. 一个关于世界的事实
- b. 一个在模型内部为真的答案，而且里面没有任何东西提示模型在那里有没有数据
- c. 一个证明
- d. 什么也没有，模型答不了这种问题

答案 b. 一个在模型内部为真的答案，而且里面没有任何东西提示模型在那里有没有数据. 在模型有数据的地方两者接近，没数据的地方就不接近，而模型两种情况下都同样自信地作答。

5 短推演、重新规划、从真实状态出发，这些都管用。它们的共同点是什么？

- a. 它们都是「让你不需要模型正确太久」的办法
- b. 它们只适用于机器人
- c. 它们去掉了对策略的需要
- d. 它们让模型更准

答案 a. 它们都是「让你不需要模型正确太久」的办法. 往刻薄了读，这整套工具就是一句承认。模型能撑住的那段时程，正是决定你能造出什么的那个数字。

6 为什么下游任务成功率定不了「哪个模型更好」？

- a. 它只在模拟里有效
- b. 任务太简单
- c. 它把模型和策略一起打分，于是一个好策略能盖住一个差模型
- d. 它没法可靠地测量

答案 c. 它把模型和策略一起打分，于是一个好策略能盖住一个差模型. 它看起来像是那个诚实的答案，而它恰好把你本想分开的那两样东西混在了一起。

7 一个基准赢家的几何最好，动作保真度却一般。第一句该问什么？

- a. 它跑在什么硬件上
- b. 它训练了多久
- c. 它有多大
- d. 用的是哪个尺度，而那个尺度忽略了什么

答案 d. 用的是哪个尺度，而那个尺度忽略了什么. PlayWorld 一类基准会把有用维度分开。它们不会替你决定具体用途重视哪份契约，也不会自动给互相竞争的维度一个合并规则。

8 面对一个不熟悉的系统，整门课里哪一个问题最顶用？

- a. 它有多少参数
- b. 它输出什么，以及你能不能在没人执行过的动作下把它往前推
- c. 它开不开源
- d. 它用不用 transformer

答案 b. 它输出什么，以及你能不能在没人执行过的动作下把它往前推. 前半句决定了它能被用来干什么，后半句决定了它撑不撑得起一个决定。几乎其他一切都由此而来，而这两者都不需要你知道架构。

FIG. 9.10 八道关于「还有什么是坏的」的题。如果你读完了整门课，最后一道应该很容易，而且有点让人不爽。

参考资料

PlayWorld: A Benchmark for Interactive World Models ZHANG ET AL., 2026 ↗

面向可交互世界模型的新基准：171 个场景，分别测试几何、交互保真度，以及物体离开和重返视野时的演化。

<https://arxiv.org/abs/2608.13552>

How Far is Video Generation from World Model: A Physical Law Perspective

KANG ET AL., 2024 ↗

图 8.7 的实测版本。视频模型在训练分布之内符合物理规律，出了这个范围就不会外推。

<https://arxiv.org/abs/2411.02385>

VBench: Comprehensive Benchmark Suite for Video Generative Models

HUANG ET AL., 2023 ↗

对这个测量问题一次认真的尝试，也很适合用来看清：要拆到多少个互相独立的维度之后，排序才会变得不再显然。

<https://arxiv.org/abs/2311.17982>

Benchmarking Model-Based Reinforcement Learning WANG ET AL., 2019 ↗

基于模型的方法到底在哪里赢、在哪里输，以及「往前看多远」这个两难在哪里被命名和度量。

<https://arxiv.org/abs/1907.02057>

When to Trust Your Model: Model-Based Policy Optimisation

JANNER ET AL., 2019 ↗

从真实状态出发的短推演，直接回应累积误差和模型利用。标题就是这一章的问题。

<https://arxiv.org/abs/1906.08253>

Emergent World Representations LI ET AL., 2022 ↗

在 Othello-GPT 内部找到棋盘状态，并且能对它做因果干预。

<https://arxiv.org/abs/2210.13382>

Genie 3 GOOGLE DEEPMIND, 2025 ↗

报告称能在多分钟的交互里回想起先前见过的细节。

<https://deepmind.google/blog/genie-3-a-new-frontier-for-world-models/>

A Path Towards Autonomous Machine Intelligence LECUN, 2022 ↗

整个论点的出处，包括为什么对一个要去行动的系统来说，预测外观是错的活。

<https://openreview.net/forum?id=BZ5a1r-kVsf>

FIG. 9.11 这个排序是给要在这上面接着做事的人用的，不是为了历史完整性：基准在前，LeCun 在最后。